
پردازش تصویر در دهه آینده

از عمق ریاضیات تا مهندس حرفه‌ای

کتاب - جزوه درس کارشناسی ارشد و آزمایشگاه پژوهش محور

پنجم فصل

بازسازی و نويز حذف تصویر، بهبود
پروگرام، روش‌های تا کلی تغییرات و آستانه‌گذاری وینر، فیلتر از
انتشار پیشین‌های و ترنسفورمرها، **Plug-and-Play**

تصميم گيري مسئله يك نيست؛ آرايشي عمليات يك نويز» «حذف فصل، اين در
پيشين اندازه‌گيري، با سازگاري ميان بايد معتبر پاسخ هر است. معكوس و آماری
کند. برقرار توازن بصری توهم خطر و عددی پایداری تصميم، هزینه تصویر،

نسخه تفصیلی درس - تابستان ۱۴۰۵ / ۲۰۲۶

قابل کامپایل با XeLaTeX + TeXstudio + TeX Live

یادداشت روش شناختی فصل پنجم

فصل چهارم به این پرسش پاسخ داد که داده تصویری چگونه تصادفی می‌شود، نویز از کدام سازوکار فیزیکی می‌آید و چرا انتخاب درست نمایی باید تابع نوع حسگر و زنجیره پردازش باشد. اکنون مسئله برعکس می‌شود: از مشاهده تخریب شده چه چیزی درباره تصویر مطلوب می‌توان استنباط کرد؟ این پرسش، هم حذف نویز ساده را دربرمی‌گیرد، هم رفع تاری، پرکردن ناحیه مفقود، بزرگ نمایی، بازسازی توموگرافی و بسیاری از مسائل تصویربرداری محاسباتی را.

سه خطای آموزشی رایج در این حوزه عبارت‌اند از:

۱. معرفی الگوریتم‌ها به صورت فهرستی از فیلترها، بدون یک مدل پیشرو و تابع خطر مشترک؛
 ۲. قضاوت درباره کیفیت تنها با نگاه کردن یا تنها با یک عدد مانند PSNR؛
 ۳. معرفی شبکه‌های عمیق به عنوان جایگزین ریاضیات، در حالی که شبکه نیز ناگزیر یک پیشین، یک هزینه و یک سازوکار سازگاری با داده را پیاده می‌کند.
- بنابراین فصل حاضر بر یک ستون فقرات واحد بنا می‌شود:

$$y = \mathcal{H}(x) + n, \quad (1)$$

که در آن x تصویر مطلوب، y مشاهده، $\mathcal{H}$ عملگر تخریب و n عدم قطعیت اندازه‌گیری است. هر روش کلاسیک یا مدرن را می‌توان با چهار پرسش بازخوانی کرد: مدل داده چیست؟ پیشین چیست؟ الگوریتم حل چیست؟ و خروجی یک برآورد نقطه‌ای است یا توزیع پسین؟


اصل معماری فصل

مطالب بر اساس «عمق مفهومی» مرتب شده‌اند، نه تاریخ ظهور. نخست تصمیم آماری و مدل خطی، سپس فیلترهای کلاسیک، نمایش تنک و غیرمحلی، روش‌های تغییراتی و بهینه‌سازی، و در ادامه یادگیری عمیق، شبکه‌های باز شده، Plug-and-Play و مدل‌های مولد بررسی می‌شوند. در هر مرحله، ارتباط دقیق با بخش‌های پیشین حفظ می‌شود.

خطای رایج

بازسازی با کیفیت ظاهری لزوماً بازسازی صادقانه نیست. به ویژه در روش های مولد، بافتی که از نظر آماری طبیعی است ممکن است در اندازه گیری وجود نداشته باشد. در پزشکی، نجوم، بازرسی صنعتی و علوم، «توهم جزئیات» یک خطای علمی است، نه صرفاً یک ضعف زیبایی شناختی.

نقشه فشرده فصل



فهرست مطالب

آ	یادداشت روش شناختی فصل پنجم
پ	نقشه فشرده فصل
۱	۵ بهبود تصویر، حذف نویز و بازسازی
۲	۱۰۵ آغاز درس: دقیقاً چه چیزی را «بهبود» می‌دهیم؟
۳	۲۰۵ صورت‌بندی یکپارچه: مدل پیشرو، درست‌نمایی و پیشین
۴	۱۰۲۰۵ شرایط هادامار و علت نیاز به منظم‌سازی
۴	۳۰۵ برآوردگر مناسب از تابع خطر می‌آید
۵	۱۰۳۰۵ مثال گاوسی خطی
۵	۴۰۵ فیلترهای خطی: از هموارسازی تا وینر
۶	۱۰۴۰۵ فیلتر خطی ناوردان نسبت به انتقال
۶	۲۰۴۰۵ استخراج فیلتر وینر از اصل تعامد
۷	۳۰۴۰۵ رابطه وینر و تیکانوف
۸	۵۰۵ فیلترهای غیرخطی محلی و حفظ لبه
۸	۱۰۵۰۵ فیلتر میانه و آمار ترتیبی
۸	۲۰۵۰۵ فیلتر دوطرفه
۸	۳۰۵۰۵ فیلتر هدایت‌شده
۹	۶۰۵ حذف نویز در حوزه تبدیل: موجک، تنکی و آستانه‌گذاری
۹	۱۰۶۰۵ آستانه سخت و نرم
۱۰	۲۰۶۰۵ آستانه جهانی و SURE
۱۰	۳۰۶۰۵ از تنکی ضرایب تا مدل فرهنگ لغت
۱۱	۷۰۵ خودشباهتی غیرمحلی: از NLM تا گروه‌بندی وصله‌ها
۱۱	۱۰۷۰۵ سوگیری فاصله وصله در حضور نویز
۱۱	۲۰۷۰۵ گروه وصله و رتبه کم

۳۰۷.۵	منطق BM3D	۱۲
۸۰.۵	بازسازی تغییراتی: هزینه داده و هندسه پیشین	۱۲
۱۰۸.۵	پیشین همواری درجه دوم	۱۲
۲۰۸.۵	تغییرات کلی	۱۳
۳۰۸.۵	ناهمواری، پلکانی شدن و مدل های مرتبه بالاتر	۱۴
۴۰۸.۵	هزینه داده باید با نویز هماهنگ باشد	۱۵
۹۰.۵	روش های پروگرام: از فرمول تا الگوریتم قابل اجرا	۱۵
۱۰۹.۵	گرادیان پروگرام و ISTA	۱۵
۲۰۹.۵	تفکیک متغیر و ADMM	۱۶
۳۰۹.۵	الگوریتم اولیه-دوگان	۱۶
۱۰۰.۵	سه مسئله بنیادین بازسازی: تاری، فقدان و تفکیک پذیری	۱۷
۱۰۱۰.۵	رفع تاری	۱۷
۲۰۱۰.۵	درون پرکردن	۱۷
۳۰۱۰.۵	ابرتفکیک	۱۸
۴۰۱۰.۵	رفع تاری کور و شناسا پذیری	۱۸
۱۱۰.۵	انتخاب پارامتر: اختلاف، اعتبارسنجی، GCV و SURE	۱۸
۱۲۰.۵	یادگیری نظارت شده: شبکه به عنوان برآوردگر داده محور	۱۹
۱۰۱۲.۵	یادگیری باقیمانده	۲۰
۲۰۱۲.۵	نقشه نویز و مدل کور	۲۰
۳۰۱۲.۵	توابع هزینه	۲۰
۴۰۱۲.۵	از کانولوشن تا ترنسفورمر	۲۰
۱۳۰.۵	شبکه های باز شده: الگوریتم تکراری به معماری قابل یادگیری	۲۱
۱۰۱۳.۵	تفکیک نقش ها	۲۱
۱۴۰.۵	Plug-and-Play و RED: حذف نویز به عنوان پیشین	۲۲
۱۰۱۴.۵	آیا هر حذف کننده یک پروگرام است؟	۲۲
۱۵۰.۵	پیشین امتیاز و مدل انتشار: از حذف نویز تا نمونه گیری پسین	۲۲
۱۰۱۵.۵	تابع امتیاز و هویت توپیدی	۲۳
۲۰۱۵.۵	پسین در مسئله معکوس	۲۳
۳۰۱۵.۵	برآورد نقطه ای در برابر نمونه پسین	۲۳
۴۰۱۵.۵	خطر توهم و قید داده	۲۴
۱۶۰.۵	مبادله ادراک-اعوجاج و معنای «جزئیات بهتر»	۲۴

۲۵	ارزیابی: از PSNR تا کار پایین دست و عدم قطعیت
۲۵	۱۰۱۷۰۵ معیارهای دارای مرجع
۲۶	۲۰۱۷۰۵ معیار سازگاری داده
۲۶	۳۰۱۷۰۵ کار پایین دست
۲۶	۴۰۱۷۰۵ هزینه و پایداری
۲۶	۵۰۱۷۰۵ پروتکل داده واقعی
۲۷	۱۸۰۵ راهنمای انتخاب خانواده روش
۲۸	۱۹۰۵ کارگاه بازتولیدپذیر فصل
۲۸	۱۰۱۹۰۵ قرارداد داده و توابع پایه
۲۹	۲۰۱۹۰۵ حل تیکانوف کانولوشنی در حوزه فوریه
۳۰	۳۰۱۹۰۵ گرادیان پروگرامال و ثبت تاریخچه
۳۰	۴۰۱۹۰۵ پروتکل مقایسه منصفانه
۳۱	۵۰۱۹۰۵ پرامپت دقیق برای Codex
۳۱	۲۰۰۵ تمرین‌های ریاضی، محاسباتی و پژوهشی
۳۳	۲۱۰۵ تقسیم پیشنهادی فصل به ویدئوهای ۱۵ دقیقه‌ای
۳۴	۲۲۰۵ پروژه پایان فصل: از مدل تا گزارش قابل داوری
۳۴	۲۳۰۵ جمع‌بندی و پل به فصل ششم

۳۶ منابع منتخب فصل

۴۰ راهنمای کامپایل، فونت و اجرای آزمایش‌ها

فصل ۵

بهبود تصویر، حذف نویز و بازسازی

اهداف یادگیری

پس از مطالعه این فصل، دانشجو باید بتواند:

۱. تفاوت بهبود، حذف نویز، بازسازی و مسئله معکوس را با زبان ریاضی توضیح دهد؛
۲. برآوردهای میانگین شرطی، میانه شرطی و MAP را از تابع خطر استخراج کند؛
۳. فیلتر وینر را هم از اصل تعامد و هم از دیدگاه بیزی به دست آورد؛
۴. آستانه گذاری موجک، حذف نویز غیرمحلی، مدل رتبه کم و BM3D را در یک چارچوب ساختاری تحلیل کند؛
۵. هزینه داده متناسب با نویز گاوسی، لاپلاس، پواسون و ضربه ای را انتخاب کند؛
۶. معادله اویلر-لاگرانژ مدل TV و گام های ISTA/FISTA/ADMM را استخراج کند؛
۷. رفع تاری، درون پر کردن و ابرتفکیک را به عنوان تغییرات عملگر H صورت بندی کند؛
۸. نقش شبکه های باقیمانده، ترنسفورمرها، شبکه های باز شده و مدل های همه کاره را نقد کند؛
۹. منطق RED، Plug-and-Play و بازسازی با پیشین انتشار را بفهمد؛
۱۰. میان دقت اعوجاجی، کیفیت ادراکی، سازگاری با داده و عدم قطعیت تمایز بگذارد؛
۱۱. یک آزمایش بازتولیدپذیر با داده واقعی، خط مبنا، تحلیل حساسیت و گزارش هزینه محاسباتی طراحی کند.


۱۰۵ آغاز درس: دقیقاً چه چیزی را «بهبود» می‌دهیم؟

فرض کنید دو خروجی از یک تصویر کم‌نور داریم. خروجی نخست صاف، کم‌نویز و دارای PSNR بالا است، اما نوشته ریز را محو کرده است. خروجی دوم بافت و لبه را بازسازی کرده، ولی مقداری دانه‌دانه بودن دارد. کدام بهتر است؟ بدون تعیین هدف، پاسخ یگانی وجود ندارد. اگر هدف مشاهده انسانی باشد، ادراک اهمیت دارد؛ اگر هدف اندازه‌گیری قطریک رگ باشد، وفاداری هندسی اهمیت بیشتری دارد؛ اگر تصویر ورودی یک سامانه تشخیص باشد، معیار نهایی ممکن است دقت تشخیص باشد.

تعریف ۱۰۵ (بهبود تصویر). بهبود تصویر *image enhancement* هر تبدیل T است که خروجی $T(y)$ را برای یک مصرف‌کننده یا وظیفه مشخص مفیدتر کند. در این تعریف الزاماً مدل فیزیکی تخریب یا تصویر حقیقت مبنا وجود ندارد.

تعریف ۲۰۵ (بازسازی تصویر). بازسازی *image restoration/reconstruction* استنباط x از مشاهده y بر پایه مدل صریح یا ضمنی $p(y | x)$ و اطلاعات پیشین درباره x است.

تعریف ۳۰۵ (حذف نویز). حذف نویز حالت ویژه‌ای از بازسازی است که در تقریب پایه $\mathcal{H} = \mathcal{I}$ و $y = x + n$ است. با این حال در داده واقعی، دموزایک، اشباع، حرکت و فشرده‌سازی ممکن است این فرض را نقض کنند.



شکل ۱۰۵: چند مسئله ظاهراً متفاوت با تغییر عملگر پیشرو $\mathcal{H}$. حذف نویز فقط حالت $\mathcal{H} = \mathcal{I}$ است.

سه محور قضاوت

- هر خروجی باید دست کم روی سه محور سنجیده شود:
۱. وفاداری به اندازه‌گیری: آیا $\mathcal{H}(\hat{x})$ با y سازگار است؟
 ۲. معقول بودن پیشینی: آیا خروجی در کلاس تصاویر مورد نظر قرار می‌گیرد؟
 ۳. فایده برای تصمیم: آیا خروجی برای مشاهده، اندازه‌گیری یا وظیفه پایین دست مناسب است؟
- هیچ معیار منفردی هر سه را کامل اندازه نمی‌گیرد.

۲.۵ صورت‌بندی یکپارچه: مدل پیشرو، درست‌نمایی و پیشین

در حالت خطی گسسته می‌نویسیم

$$y = Hx + n, \quad H \in \mathbb{R}^{m \times n}, \quad x \in \mathbb{R}^n, \quad y \in \mathbb{R}^m. \quad (1.5)$$

عملگر H می‌تواند همانی، کانولوشن تاری، ماسک نمونه‌برداری، کاهش ابعاد، تبدیل رادون یا ترکیبی از این‌ها باشد. در مدل غیرخطی، Hx با $\mathcal{H}(x)$ جایگزین می‌شود. اگر نویز گاوسی سفید باشد،

$$p(y | x) = (\pi\sigma^2)^{-m/2} \exp\left(-\frac{1}{2\sigma^2} \|y - Hx\|_2^2\right). \quad (2.5)$$

پس منفی لگاریتم درست‌نمایی، تا یک ثابت، برابر است با

$$\mathcal{D}_G(x; y) = \frac{1}{2\sigma^2} \|y - Hx\|_2^2. \quad (3.5)$$

برای شمارش پواسون $y_i \sim \text{Poisson}((Hx)_i)$ ، جمله داده به صورت واگرایی تعمیم‌یافته کالک-لایبلر درمی‌آید:

$$\mathcal{D}_P(x; y) = \sum_i [(Hx)_i - y_i \log((Hx)_i)], \quad (4.5)$$

با قرارداد مناسب برای $y_i = 0$. برای نویز لاپلاس، ℓ_1 و برای آلودگی‌های دنباله‌سنگین، هزینه‌های مقاوم مانند هیوبریا دانشجویی مناسب‌ترند.

پیشین بیزی $p(x)$ را می‌توان به صورت انرژی نوشت:

$$p(x) \propto \exp[-\lambda \mathcal{R}(x)]. \quad (5.5)$$

در نتیجه برآورد MAP برابر است با

$$\hat{x}_{\text{MAP}} = \arg \min_x \mathcal{D}(x; y) + \lambda \mathcal{R}(x). \quad (۶.۵)$$

این رابطه زبان مشترک بخش بزرگی از فصل است.

خطای رایج

پارامتر λ «مقدار هموارسازی» صرف نیست؛ نسبت اعتماد به مدل داده و پیشین را تنظیم می کند. اگر جمله داده با $1/(2\sigma^2)$ مقیاس شده باشد، تفسیر λ با حالتی که این ضریب حذف شده متفاوت است. گزارش λ بدون گزارش نرمال سازی و دامنه شدت قابل بازتولید نیست.

۱.۲.۵ شرایط هادامار و علت نیاز به منظم سازی

مسئله معکوس خوش وضع است اگر جواب وجود داشته باشد، یگانه باشد و به داده پیوسته وابسته باشد. در تجزیه مقدار منفرد

$$H = U \Sigma V^T, \quad (۷.۵)$$

معکوس کمترین مربعات، مؤلفه $u_i^T y$ را بر σ_i تقسیم می کند. اگر σ_i کوچک باشد، نویز شدیداً تقویت می شود:

$$\hat{x}_{\text{LS}} = \sum_{i: \sigma_i > 0} \frac{u_i^T y}{\sigma_i} v_i. \quad (۸.۵)$$

منظم سازی عملاً ضرایب فیلتری ϕ_i را وارد می کند:

$$\hat{x}_\lambda = \sum_i \phi_i(\lambda, \sigma_i) \frac{u_i^T y}{\sigma_i} v_i. \quad (۹.۵)$$

برای تیکانوف مرتبه صفر، $\phi_i = \sigma_i^2 / (\sigma_i^2 + \lambda)$ است؛ بنابراین جهت های بد شرط سرکوب می شوند.

۳.۵ برآوردگر مناسب از تابع خطر می آید

در نظریه تصمیم، برای مشاهده y و تصمیم a ، خطر شرطی

$$\rho(a | y) = \mathbb{E}[L(X, a) | Y = y] \quad (۱۰.۵)$$

است. برآورد بیز تصمیمی است که این خطر را کمینه کند.

قضیه ۱۰.۵ (برآوردگر MMSE). اگر $L(x, a) = \|x - a\|^2$ ، آنگاه

$$\hat{x}_{\text{MMSE}} = \mathbb{E}[X | Y = y]. \quad (11.5)$$

اثبات. با قرار دادن $m = \mathbb{E}[X | y]$ داریم

$$\mathbb{E}[\|X - a\|^2 | y] = \mathbb{E}[\|X - m + m - a\|^2 | y] \quad (12.5)$$

$$= \mathbb{E}[\|X - m\|^2 | y] + \|m - a\|^2, \quad (13.5)$$

زیرا جمله متقاطع به دلیل تعریف میانگین شرطی صفر است. پس کمینه در $a = m$ رخ می‌دهد. $\square$

برای هزینه قدرمطلق تک متغیره، میانه شرطی بهینه است. برای هزینه صفر-یک روی فضای گسسته، نما یا MAP بهینه می‌شود. از این رو MMSE و MAP عموماً یکسان نیستند. در پسین چندقله‌ای، میانگین ممکن است میان دو پاسخ معتبر قرار گیرد و تصویری مات تولید کند، در حالی که MAP فقط یک قله را انتخاب می‌کند.

۱۰.۳.۵ مثال گاوسی خطی

اگر

$$x \sim \mathcal{N}(\mu_x, C_x), \quad n \sim \mathcal{N}(0, C_n), \quad (14.5)$$

آنگاه پسین گاوسی و میانگین شرطی برابر است با

$$\hat{x} = \mu_x + C_x H^T (H C_x H^T + C_n)^{-1} (y - H \mu_x). \quad (15.5)$$

این همان برآوردگر وینر تعمیم یافته است. در مدل کاملاً گاوسی، میانگین پسین و نما یکسان اند؛ این هم‌ارزی در پیشین‌های غیرگاوسی از بین می‌رود.

پل به دهه آینده

مدل مولد مدرن تقریب پیچیده‌ای از $p(x)$ یا گرادیان لگاریتم آن می‌آموزد، اما تصمیم نهایی همچنان باید مشخص کند میانگین پسین، نمونه پسین، نما یا برآوردی با هزینه ادراکی مطلوب است. «شبکه قوی تر» این انتخاب نظری را حذف نمی‌کند.

۴.۵ فیلترهای خطی: از هموارسازی تا وینر

۱۰.۴.۵ فیلتر خطی ناوردان نسبت به انتقال

برای هسته h ، خروجی

$$\hat{x}[m, n] = (h * y)[m, n] = \sum_{k, \ell} h[k, \ell] y[m - k, n - \ell] \quad (۱۶.۵)$$

است. اگر $\sum h = 1$ ، مؤلفه ثابت حفظ می‌شود. فیلتر میانگین و گاوسی نویز فرکانس بالا را کاهش می‌دهند، ولی چون لبه نیز انرژی فرکانس بالا دارد، آن را هم تضعیف می‌کنند. این تضاد نخستین نمونه از مبادله سوگیری-واریانس است.

برای نویز سفید با واریانس σ_n^2 ، واریانس خروجی فیلتر خطی برابر است با

$$\text{Var}[(h * n)[m, n]] = \sigma_n^2 \sum_{k, \ell} h^2[k, \ell]. \quad (۱۷.۵)$$

پس پهن‌تر کردن هسته واریانس را کم می‌کند، اما سوگیری لبه‌ها را افزایش می‌دهد.

۲۰.۴.۵ استخراج فیلتر وینر از اصل تعامد

در مدل فرکانسی

$$Y(\omega) = H(\omega)X(\omega) + N(\omega), \quad (۱۸.۵)$$

برآورد خطی $\hat{X} = GY$ را می‌خواهیم که $\mathbb{E}|X - GY|^2$ را کمینه کند. اصل تعامد می‌گوید خطا با داده نامرتب است:


$$\mathbb{E}[(X - GY)Y^*] = 0. \quad (۱۹.۵)$$

بنابراین

$$G(\omega) = \frac{S_{XY}(\omega)}{S_{YY}(\omega)}. \quad (۲۰.۵)$$

اگر سیگنال و نویز نامرتب باشند،

$$G_W(\omega) = \frac{H^*(\omega)S_X(\omega)}{|H(\omega)|^2 S_X(\omega) + S_N(\omega)} = \frac{H^*(\omega)}{|H(\omega)|^2 + S_N(\omega)/S_X(\omega)}. \quad (۲۱.۵)$$



شکل ۲۰۵: پاسخ معکوس وینر. منظم سازی مانع انفجار بهره در فرکانس هایی می شود که H کوچک است.

برای حذف نویز خالص $H = 1$ ،

$$G_W(\omega) = \frac{S_X(\omega)}{S_X(\omega) + S_N(\omega)}, \quad (22.5)$$

یعنی هر فرکانس به نسبت سیگنال به مجموع سیگنال و نویز وزن می گیرد. در ناحیه ای که $S_X \gg S_N$ ، بهره نزدیک یک و در ناحیه نویز غالب نزدیک صفر است.

۳۰۴.۵ رابطه وینر و تیکانوف

مسئله

$$\hat{x} = \arg \min_x \frac{1}{2} \|Hx - y\|_2^2 + \frac{\lambda}{2} \|Lx\|_2^2 \quad (23.5)$$

معادله نرمال

$$(H^T H + \lambda L^T L) \hat{x} = H^T y \quad (24.5)$$

را دارد. اگر عملگرها کانولوشنی باشند، در حوزه فوریه

$$\hat{X}(\omega) = \frac{H^*(\omega)}{|H(\omega)|^2 + \lambda |L(\omega)|^2} Y(\omega). \quad (25.5)$$

این فرم از نظر جبری به وینر شبیه است. در دیدگاه بیزی، $\|Lx\|^2$ پیشین گاوسی با دقت متناسب با $L^T L$ القا می‌کند.

خطای رایج

فیلتر معکوس $1/H$ در صفرها یا مقادیر کوچک H ناپایدار است. افزودن یک ϵ دلتخواه مشکل را پنهان می‌کند، اما انتخاب علمی باید از سطح نویز، پیشین یا یک اصل منظم‌سازی مانند اختلاف، GCV یا SURE بیاید.

۵.۵ فیلترهای غیرخطی محلی و حفظ لبه

۱.۵.۵ فیلتر میانه و آمار ترتیبی

در پنجره $\mathcal{N}_i$ ، فیلتر میانه

$$\hat{x}_i = \text{median}\{y_j : j \in \mathcal{N}_i\} \quad (26.5)$$

است. میانه کینه‌کننده

$$\arg \min_a \sum_{j \in \mathcal{N}_i} |y_j - a| \quad (27.5)$$

است و از این رو در برابر چند مقدار پرت مقاوم‌تر از میانگین است. برای نویز نمک و فلفل، فیلتر میانه غالباً از هموارساز خطی بهتر است؛ اما در نویز گاوسی و بافت ریز الزاماً بهینه نیست.

۲.۵.۵ فیلتر دوطرفه

فیلتر دوطرفه هم نزدیکی مکانی و هم شباهت شدت را وزن می‌دهد:

$$\hat{x}_i = \frac{1}{Z_i} \sum_{j \in \mathcal{N}_i} \exp\left(-\frac{\|p_i - p_j\|^2}{2\sigma_s^2} - \frac{(y_i - y_j)^2}{2\sigma_r^2}\right) y_j, \quad (28.5)$$

که Z_i مجموع وزن‌ها است. پارامتر σ_s مقیاس مکانی و σ_r تحمل اختلاف شدت را کنترل می‌کند. اگر $\sigma_r \rightarrow \infty$ ، فیلتر به گاوسی مکانی نزدیک می‌شود؛ اگر σ_r کوچک باشد، عبور از لبه محدود می‌شود.

۳.۵.۵ فیلتر هدایت‌شده

در فیلتر هدایت‌شده فرض می‌شود خروجی در پنجره ω_k رابطه محلی خطی با تصویر راهنما I دارد:

$$q_i = a_k I_i + b_k, \quad i \in \omega_k. \quad (29.5)$$

ضرایب از کمینه سازی

$$\sum_{i \in \omega_k} (a_k I_i + b_k - p_i)^2 + \epsilon a_k^2 \quad (30.5)$$

به دست می آیند. حل بسته آن نشان می دهد که a_k با کوواریانس راهنما و ورودی و b_k با میانگین های محلی تعیین می شود. این فیلتر برای انتقال لبه از راهنما مفید است، اما اگر راهنما ساختار نامربوط داشته باشد، اثر انتقال بافت رخ می دهد.

اصل کلی فیلتر تطبیقی

هموارسازی باید در امتداد ناحیه همگن قوی و در عبور از مرز ضعیف باشد. فیلتر دوطرفه این تصمیم را با اختلاف شدت، فیلتر هدایت شده با مدل رگرسیون محلی، و روش های تغییراتی با وزن یا هندسه گرادینان اجرا می کنند.

۶.۵ حذف نویز در حوزه تبدیل: موجک، تنکی و آستانه گذاری

فرض کنید W تبدیل متعامد و

$$c = Wx, \quad d = Wy = c + \eta. \quad (31.5)$$

برای نویز سفید گاوسی و W متعامد، η نیز سفید گاوسی با همان واریانس است. اگر تصویر در این پایه تنک باشد، بسیاری از ضرایب حقیقی کوچک یا صفرند و می توان ضرایب نویز غالب را کاهش داد.


۱.۶.۵ آستانه سخت و نرم

$$\delta_{\text{hard}}(d; \tau) = d \mathbf{1}(|d| > \tau), \quad (32.5)$$

$$\delta_{\text{soft}}(d; \tau) = \text{sign}(d) \max(|d| - \tau, 0). \quad (33.5)$$

آستانه نرم پیوسته است و دقیقاً عملگر پروگزیمال نرم ℓ_1 محسوب می شود:

$$\text{prox}_{\lambda|\cdot|}(d) = \arg \min_c \frac{1}{2}(c - d)^2 + \lambda|c| = \delta_{\text{soft}}(d; \lambda). \quad (34.5)$$



شکل ۳.۵: قواعد کاهش ضرایب. آستانه سخت ناپيوسته، آستانه نرم دارای سوگیری ثابت برای ضرایب بزرگ و آستانه firm مصالحه‌ای میان آن‌ها است.

۲.۶.۵ آستانه جهانی و SURE

اگر N ضریب نویز مستقل گاوسی داشته باشیم، آستانه جهانی دونوهیو-جانستون

$$\tau_{\text{univ}} = \sigma \sqrt{2 \log N} \quad (۳۵.۵)$$

با احتمال بالا بیشینه نویز را پوشش می‌دهد، اما ممکن است بیش از حد محافظه‌کار و هموارکننده باشد. اصل برآورد بی‌طرفانه خطر استاین SURE برای $y = x + \sigma z$ و تخمین گر تقریباً مشتق‌پذیر f می‌گوید

$$\text{SURE}(f; y) = \|f(y) - y\|^2 + 2\sigma^2 \text{div } f(y) - n\sigma^2 \quad (۳۶.۵)$$

برآوردی بی‌طرف از خطر مربعی است. بنابراین پارامتر را می‌توان بدون تصویر پاک تنظیم کرد، مشروط بر درستی مدل گاوسی و محاسبه واگرایی.

۳.۶.۵ از تنگی ضرایب تا مدل فرهنگ لغت

در مدل فرهنگ لغت

$$y_i \approx D\alpha_i, \quad \|\alpha_i\|_1 \ll p, \quad (۳۷.۵)$$

هر وصله با تعداد کمی اتم بازسازی می‌شود. حل محدب رایج

$$\hat{\alpha}_i = \arg \min_{\alpha} \frac{1}{p} \|y_i - D\alpha\|_p^p + \lambda \|\alpha\|_1 \quad (38.5)$$

است. اگر D آموخته شود، داده خود پایه سازگار را تعیین می‌کند؛ اما هزینه یادگیری، خطر بیش‌برازش و وابستگی دامنه مطرح می‌شود.

۷.۵ خودشباهتی غیرمحلی: از NLM تا گروه‌بندی وصله‌ها

تصویر طبیعی در نقاط دوردست نیز وصله‌های مشابه دارد. روش میانگین غیرمحلی برای پیکسل i می‌نویسد

$$\hat{x}_i = \sum_{j \in \mathcal{S}_i} w_{ij} y_j, \quad w_{ij} = \frac{1}{Z_i} \exp \left(-\frac{\|P_i y - P_j y\|_{p,G}^p}{h^2} \right), \quad (39.5)$$

که P_i عملگر استخراج وصله و $\|\cdot\|_{p,G}$ فاصله وزن‌دار گاوسی است. بر خلاف فیلتر دوپرفه که یک یا چند شدت را مقایسه می‌کند، NLM هندسه کامل وصله را می‌سنجد.

۱۰.۷.۵ سوگیری فاصله وصله در حضور نویز

اگر دو وصله پاک p_i, p_j و نویز مستقل گاوسی داشته باشند،

$$\mathbb{E} \|(p_i + n_i) - (p_j + n_j)\|^2 = \|p_i - p_j\|^2 + 2d\sigma^2, \quad (40.5)$$

که d تعداد عناصر وصله است. پس فاصله خام دارای سوگیری وابسته به نویز است. در نویز شدید، انتخاب همسایه خطا می‌کند؛ این نکته انگیزه پیش‌فیلترکردن، تصحیح فاصله و تکرار چندمرحله‌ای است.

۲۰.۷.۵ گروه وصله و رتبه کم


وصله‌های مشابه را ستون‌های ماتریس

$$Y = [y_{i_1}, \dots, y_{i_K}] = X + N \quad (41.5)$$

قرار می‌دهیم. تکرار ساختار باعث می‌شود X تقریباً رتبه کم باشد. یک مدل پایه

$$\hat{X} = \arg \min_X \frac{1}{p} \|Y - X\|_F^p + \lambda \|X\|_* \quad (42.5)$$

است که حل آن آستانه‌گذاری نرم مقادیر منفرد است.



شکل ۴.۵: افت مقادیر منفرد یک گروه وصله مشابه. ساختار تکراری در ماتریس گروهی به رتبه مؤثر پایین منجر می‌شود.

۳.۷.۵ منطق BM3D

BM3D سه ایده را ترکیب می‌کند: جست‌وجوی بلوک‌های مشابه، چیدن آن‌ها در آرایه سه‌بعدی، و کاهش ضرایب در یک تبدیل سه‌بعدی. مرحله نخست با آستانه سخت یک برآورد پایه می‌دهد؛ مرحله دوم با گروه‌بندی بر اساس برآورد پایه و فیلتر وینر، خروجی را پالایش می‌کند. نکته مهم این است که قدرت روش فقط از یک فیلتر نیست؛ از همکاری میان خودشبهاتی، تبدیل تنک و تجمیع وزن‌دار می‌آید [۱۵].

یک تفسیر واحد

موجک تنکی را در یک پایه ثابت می‌جوید؛ فرهنگ لغت پایه را از داده می‌آموزد؛ NLM میانگین‌گیری روی منیفلد وصله انجام می‌دهد؛ و روش‌های رتبه کم وصله‌های مشابه را در یک زیرفضای کم‌بعد قرار می‌دهند. همه آن‌ها تلاش می‌کنند درجه آزادی مؤثر تصویر را از تعداد پیکسل‌ها کمتر کنند.

۸.۵ بازسازی تغییراتی: هزینه داده و هندسه پیشین

۱۰.۸.۵ پیشین همواری درجه دوم

مدل

$$\min_x \frac{1}{\gamma} \|Hx - y\|^2 + \frac{\lambda}{\gamma} \|\nabla x\|^2 \quad (۴۳.۵)$$

محدب و قابل حل است، اما لبه را نیز جریمه می کند. در یک بعد، $\|Dx\|_2^2$ تغییرات زیاد را به طور درجه دوم پرهزینه می کند و بنابراین گذار تیز را پخش می سازد.

۲۰.۸.۵ تغییرات کلی

برای تصویر پیوسته، تغییرات کلی همسانگرد

$$\text{TV}(x) = \int_{\Omega} \|\nabla x(\mathbf{r})\|_2 d\mathbf{r} \quad (۴۴.۵)$$

و در شبکه گسسته

$$\text{TV}(\mathbf{x}) = \sum_i \sqrt{(D_x \mathbf{x})_i^2 + (D_y \mathbf{x})_i^2} \quad (۴۵.۵)$$

است. مدل ROF برای نویز گاوسی


$$\hat{x} = \arg \min_x \frac{1}{2} \|x - y\|_2^2 + \lambda \text{TV}(x) \quad (۴۶.۵)$$

است [۷].

در ناحیه ای که $\nabla x \neq 0$ ، معادله اویلر-لاگرانژی رسی

$$x - y - \lambda \operatorname{div} \left(\frac{\nabla x}{\|\nabla x\|_2} \right) = 0. \quad (۴۷.۵)$$

است. عبارت واگرایی نرمال گرادیان با خمیدگی خطوط تراز ارتباط دارد و هموارسازی را درون ناحیه قوی تر از عبور از لبه می کند.



شکل ۵.۵: مقایسه همواری درجه دوم و TV. تیکانوف گذار را پخش می کند؛ TV لبه را حفظ می کند ولی ممکن است پدیده پلکانی ایجاد کند.

۳.۸.۵ ناهمواری، پلکانی شدن و مدل های مرتبه بالاتر

TV گرادیان تنک را ترجیح می دهد و تصویر را قطعه ای ثابت می بیند. در رمپ های نرم، این فرض به نواحی تخت و پرش های مصنوعی منجر می شود. راه حل ها شامل هیوبرکدن نرم گرادیان، TGV، منظم سازی هسین و ترکیب چند مقیاسی اند. برای مثال

$$\text{TGV}_{\alpha, \alpha_1}^2(x) = \min_w \alpha_1 \|\nabla x - w\|_1 + \alpha \cdot \|\mathcal{E}w\|_1 \quad (48.5)$$

می تواند نواحی قطعه ای خطی را بهتر مدل کند.

۴۰.۸.۵ هزینه داده باید با نویز هماهنگ باشد

مدل مشاهده	جمله داده	نکته
گوسی	$\frac{1}{2} \ Hx - y\ _2^2$	مناسب خطای جمع شونده با واریانس ثابت
لاپلاس	$\ Hx - y\ _1$	مقاوم تر به پرت های متقارن
پواسون	$\sum_i [(Hx)_i - y_i \log(Hx)_i]$	نیازمند مثبت بودن شدت پیش بینی شده
نمک و فلفل	ℓ_1 ، مدل ماسک یا متغیر پرت	مدل گوسی می تواند پرت را روی کل تصویر پخش کند
اسپکل	هزینه در حوزه لگاریتم یا درست نمایی گاما	تبدیل لگاریتم سوگیری و مشکل صفر ایجاد می کند

۹.۵ روش های پروگرمال: از فرمول تا الگوریتم قابل اجرا

برای

$$\min_x F(x) = f(x) + g(x), \quad (۴۹.۵)$$

که f هموار با گرادیان لیپ شیتز و g محدب ولی شاید ناهموار است، عملگر پروگرمال


$$\text{prox}_{\gamma g}(v) = \arg \min_x \left\{ g(x) + \frac{1}{2\gamma} \|x - v\|^2 \right\} \quad (۵۰.۵)$$

تعریف می شود.

۱۰.۹.۵ گرادیان پروگرمال و ISTA

$$x^{k+1} = \text{prox}_{\gamma g}(x^k - \gamma \nabla f(x^k)), \quad 0 < \gamma < 2/L. \quad (۵۱.۵)$$

برای $g(x) = \lambda \|x\|_1$ ، پروگرمال همان آستانه نرم است. FISTA با یک جمله مومنتوم نرخ تابع هدف را از مرتبه $O(1/k)$ به $O(1/k^2)$ در حالت محدب بهبود می دهد.



شکل ۵.۶: نمونه همگرایی ISTA و FISTA در یک مسئله درجه دو به علاوه ℓ_1 . شتاب در عمل می‌تواند نوسان نیز ایجاد کند.

۲.۹.۵ تفکیک متغیر و ADMM

برای

$$\min_x f(x) + g(Kx) \quad (52.5)$$

متغیر $z = Kx$ وارد می‌کنیم. نسخه مقیاس شده ADMM:

$$x^{k+1} = \arg \min_x f(x) + \frac{\rho}{2} \|Kx - z^k + u^k\|^2, \quad (53.5)$$

$$z^{k+1} = \text{prox}_{g/\rho}(Kx^{k+1} + u^k), \quad (54.5)$$

$$u^{k+1} = u^k + Kx^{k+1} - z^{k+1}. \quad (55.5)$$

در TV، یکی از زیرمسئله‌ها خطی و دیگری کاهش برداری گرادیان است. باقیمانده اولیه $r^k = Kx^k - z^k$ و باقیمانده دوگان برای توقف و تنظیم ρ اهمیت دارند.

۳.۹.۵ الگوریتم اولیه-دوگان

نمایش دوگان

$$\text{TV}(x) = \max_{\|p_i\| \leq 1} \langle \nabla x, p \rangle \quad (56.5)$$

به الگوریتم‌های اولیه-دوگان منجر می‌شود که از حل دستگاه بزرگ اجتناب می‌کنند. شرط پایه گام‌ها معمولاً

$$\tau \sigma \|K\|^2 < 1 \quad (۵۷.۰۵)$$

است. این روش‌ها برای مدل‌های ترکیبی و قیود مثبت بودن بسیار مناسب‌اند.

قرارداد میان ریاضیات و کد

در کد، باید دقیقاً مشخص شود که f ، g ، K ، پروگرامال، گام‌ها و معیار توقف کدام‌اند. نام‌گذاری تابعی مانند `restore()` بدون ثبت این قرارداد، امکان بررسی صحت علمی را از بین می‌برد.


۱۰.۰۵ سه مسئله بنیادین بازسازی: تاری، فقدان و تفکیک‌پذیری

۱۰.۱۰۰۵ رفع تاری

برای تاری ناورد

$$y = h * x + n. \quad (۵۸.۰۵)$$

شرایط مرزی اهمیت اساسی دارند. کانولوشن دوری، بازتابی و صفرگذاری سه ماتریس H متفاوت می‌سازند. استفاده از FFT اغلب کانولوشن دوری را ضمنی فرض می‌کند؛ اگر تصویر واقعی چنین مرزی نداشته باشد، حلقه‌های مرزی ایجاد می‌شود.



شکل ۷.۰۵: مسیر منظم‌سازی در رفع تاری. منظم‌سازی بسیار کم نویز و حلقه را تقویت می‌کند و منظم‌سازی زیاد جزئیات را حذف می‌کند.

۲۰.۱۰۰۵ درون‌پرکردن

اگر M ماسک قطری مشاهده باشد،

$$y = Mx + n. \quad (۵۹.۰۵)$$

در پیکسل‌های مفقود، جمله داده هیچ اطلاعات مستقیمی نمی‌دهد و تمام پاسخ از پیشین و ساختار پیرامون می‌آید. این مسئله مثال روشنی است که چرا خروجی محتمل الزاماً حقیقت تاریخی نیست.

۳.۱۰.۵ ابرتفکیک

مدل ساده

$$y = SHx + n \quad (۶۰.۵)$$

است؛ H تاری اپتیکی و S زیرگونه‌برداری است. فرکانس‌های حذف‌شده قابل بازیابی یکتا نیستند. روش اعوجاج‌محور معمولاً میانگین بافت‌های ممکن را می‌دهد؛ روش مولد یک بافت محتمل تولید می‌کند. این دو هدف باید در گزارش جدا شوند.

۴.۱۰.۵ رفع تاری کور و شناساپذیری

در تاری کور، هم x و هم هسته h مجهول‌اند:

$$y = h * x + n. \quad (۶۱.۵)$$

ابهام مقیاس $(x/c) * (ch) = h * x$ ، ابهام انتقال و جواب ضربه‌ای از مشکلات پایه‌اند. قیود

$$h \geq 0, \quad \sum_i h_i = 1 \quad (۶۲.۵)$$

و پیشین‌های متفاوت برای تصویر و هسته لازم‌اند. حل متناوب

$$x^{k+1} = \arg \min_x \mathcal{D}(h^k * x, y) + \lambda R(x), \quad (۶۳.۵)$$

$$h^{k+1} = \arg \min_h \mathcal{D}(h * x^{k+1}, y) + \gamma Q(h) \quad (۶۴.۵)$$

غیرمحدب است و به مقداردهی اولیه حساس می‌ماند.

۱۱.۵ انتخاب پارامتر: اختلاف، اعتبارسنجی، GCV و SURE

انتخاب پارامتر بخشی از الگوریتم است، نه جزئیات جانبی. چهار سناریو:

۱. تصویر پاک موجود: اعتبارسنجی روی مجموعه‌ای جدا از آزمون؛

۲. سطح نویز معلوم: اصل اختلاف موروزوف، یعنی $\|H\hat{x} - y\|^2 \approx m\sigma^2$ ؛


۳. برآوردگر خطی: اعتبارسنجی متقاطع تعمیم‌یافته؛

۰۴. نویز گاوسی و تخمین گر مشتق پذیر: SURE یا تقریب مونت کارلو واگرایی.

برای تخمین گر خطی $\hat{y} = A_\lambda y$

$$\text{GCV}(\lambda) = \frac{\|(I - A_\lambda)y\|^2 / m}{[1 - \text{tr}(A_\lambda)/m]^2}. \quad (۶۵.۵)$$

مخرج درجه آزادی مؤثر مدل را جبران می کند.



شکل ۸.۵: حساسیت روش ها به پارامتر. حتی برای یک داده ثابت، پارامتر بهینه PSNR و SSIM می تواند متفاوت باشد.

خطای رایج

انتخاب پارامتر روی همان تصویر یا همان مجموعه ای که نتیجه نهایی روی آن گزارش می شود، برآورد عملکرد را خوش بینانه می کند. در مقایسه روش ها باید بودجه جست و جوی ابرپارامتر و اطلاعات در دسترس برای همه روش ها منصفانه باشد.

۱۲.۵ یادگیری نظارت شده: شبکه به عنوان برآوردگر داده محور

مجموعه زوج های (y_i, x_i) و شبکه f_θ را در نظر بگیرید:

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N L(f_\theta(y_i), x_i). \quad (۶۶.۵)$$

با هزینه مربعی و داده کافی، تابع بهینه به میانگین شرطی $\mathbb{E}[X | Y = y]$ نزدیک می شود؛ با ℓ_1 ، به میانه شرطی مؤلفه ای نزدیک می شود. بنابراین انتخاب هزینه همچنان تصمیم آماری است.

۱۰۱۲.۵ یادگیری باقیمانده

در حذف نویز جمع شونده، شبکه می تواند نویز را تخمین بزند:

$$\hat{n}_\theta(y) \approx y - x, \quad \hat{x} = y - \hat{n}_\theta(y). \quad (۶۷.۵)$$

این ایده در DnCNN با کانولوشن عمیق، نرمال سازی دسته ای و یادگیری باقیمانده به یک خط مبنای مهم تبدیل شد [۱۸]. از نظر بهینه سازی، هدف باقیمانده اغلب نزدیک تر به صفر و از نظر آماری ساده تر از نگاشت کامل تصویر است.

۲۰۱۲.۵ نقشه نویز و مدل کور

اگر سطح نویز σ معلوم باشد، می توان آن را به شبکه داد:

$$\hat{x} = f_\theta(y, \sigma). \quad (۶۸.۵)$$

در مدل مکافی، نقشه $M_\sigma(i)$ وارد می شود. در مدل کور، شبکه باید هم تخریب را استنباط و هم تصویر را بازسازی کند؛ این انعطاف می تواند به ابهام و شکست خارج از توزیع منجر شود.

۳۰۱۲.۵ توابع هزینه

$$L_{\text{pix}} = \|\hat{x} - x\|_1 \quad \text{یا} \quad \|\hat{x} - x\|_2^2, \quad (۶۹.۵)$$

$$L_{\text{grad}} = \|\nabla \hat{x} - \nabla x\|_1, \quad (۷۰.۵)$$

$$L_{\text{perc}} = \sum_{\ell} \|\phi_{\ell}(\hat{x}) - \phi_{\ell}(x)\|_2^2, \quad (۷۱.۵)$$

$$L_{\text{adv}} = \text{هزینه خصمانه برای نزدیک کردن توزیع خروجی به تصویر طبیعی}. \quad (۷۲.۵)$$

هزینه ادراکی می تواند بافت خوشایندتر بسازد، اما تضمین اندازه گیری پیکسلی را کاهش دهد. برای کاربرد علمی باید جمله سازگاری داده مستقل حفظ شود.

۴۰۱۲.۵ از کانولوشن تا ترنسفورمر

شبکه های کانولوشنی سوگیری محلی و ناوردایی انتقال دارند. ترنسفورمرها وابستگی دوربرد را با توجه مدل می کنند، ولی توجه سراسری روی تصویر بزرگ هزینه درجه دوم دارد. SwinIR از پنجره های انتقال یافته و Restormer از طراحی توجه کارآمد برای بازسازی وضوح بالا استفاده می کنند [۲۵، ۲۶]. نکته آموزشی مهم این است که عملکرد قوی لزوماً از پیچیدگی فعال ساز نمی آید؛ NAFNet نشان داد یک خط مبنای ساده و مهندسی شده نیز می تواند رقابتی باشد [۲۷].

پل به دهه آینده

روند پژوهش از «یک شبکه برای یک تخریب معلوم» به مدل‌های کور، همه‌کاره و پایه بازسازی حرکت کرده است. مدل‌هایی مانند PromptIR از نمایش تخریب برای هدایت بازسازی استفاده می‌کنند و کارهای جدیدتر مقیاس داده و ظرفیت را افزایش داده‌اند. اما مسئله دهه آینده فقط افزایش اندازه نیست: کالیبراسیون عدم قطعیت، کنترل توهم، هزینه انرژی، سازگاری حسگر و ارزیابی خارج از توزیع تعیین‌کننده‌اند [۲۸، ۲۹].

۱۳.۵ شبکه‌های بازشده: الگوریتم تکراری به معماری قابل یادگیری

اگر یک گام گرادیان پروگرمال را بنویسیم

$$x^{k+1} = \mathcal{P}_{\theta_k} (x^k - \gamma_k H^T (Hx^k - y)), \quad (۷۳.۵)$$

می‌توان تعداد ثابتی گام را به لایه‌های شبکه تبدیل کرد و γ_k ، آستانه‌ها، تبدیل‌ها یا حتی پروگرمال را آموخت. این رویکرد algorithm unrolling سه مزیت دارد:

۱. سازگاری داده به‌طور صریح در معماری حضور دارد؛
 ۲. تعداد مراحل و هزینه محاسباتی قابل کنترل است؛
 ۳. پارامترها تفسیرپذیرتر از شبکه جعبه‌سیاه‌اند.
- با این حال، تضمین الگوریتم اصلی پس از آزادکردن پارامترها الزاماً حفظ نمی‌شود. شبکه ممکن است فقط برای توزیع آموزشی و تعداد مراحل مشخص خوب باشد.

۱۰۱۳.۵ تفکیک نقش‌ها

یک بلوک بازشده بهتر است سه جزء را جدا کند:

$$\text{حافظه/شتاب} + \text{پیشین آموخته‌شده} + \text{سازگاری داده} = \text{حالت جدید}. \quad (۷۴.۵)$$

این تفکیک در آزمایش حذف مؤلفه و انتقال میان عملگرها اهمیت دارد.

۱۴.۵ RED و Plug-and-Play: حذف نویز به عنوان پیشین

در ADMM برای مسئله $f(x) + \lambda R(x)$ ، گام z یک پروگرمال از R است. ایده Plug-and-Play آن است که این پروگرمال با یک حذف کننده نویز D_σ جایگزین شود:

$$x^{k+1} = \arg \min_x f(x) + \frac{\rho}{4} \|x - z^k + u^k\|^2, \quad (75.5)$$

$$z^{k+1} = D_\sigma(x^{k+1} + u^k), \quad (76.5)$$

$$u^{k+1} = u^k + x^{k+1} - z^{k+1}. \quad (77.5)$$

این چارچوب اجازه می دهد یک حذف کننده قوی برای مسائل مختلف H استفاده شود، بدون آموزش جداگانه برای هر عملگر.

۱۰۱۴.۵ آیا هر حذف کننده یک پروگرمال است؟

خیر. برای اینکه D پروگرمال یک تابع محدب باشد، خواص ساختاری مانند nonexpansive firmly بودن لازم است. یک شبکه عمومی ممکن است چنین خاصیتی نداشته باشد. بنابراین تفسیر PnP بهتر است به صورت نقطه ثابت یا تعادل اجماع نوشته شود:

$$x^* = F(x^*), \quad (78.5)$$

نه الزاماً کمینه ساز یک انرژی صریح.

در RED منظم ساز پیشنهادی

$$R_{\text{RED}}(x) = \frac{1}{4} x^T (x - D(x)) \quad (79.5)$$

است. تحت شرایطی مانند همگنی محلی و تقارن ژاکوبین، گرادیان آن $x - D(x)$ می شود؛ این شرایط برای شبکه های دلخواه خودکار نیستند. تحلیل های جدیدتر نشان می دهند که رفتار PnP/RED را می توان از طریق مجموعه نقاط ثابت حذف کننده و کران های بازیابی مطالعه کرد [۲۲، ۲۳، ۲۴].

چرا این بخش برای دهه آینده مهم است؟

PnP مرز «مدل محور» و «داده محور» را می شکند: عملگر فیزیکی در جمله داده باقی می ماند و پیشین با حذف کننده آموخته می شود. این الگو در تصویربرداری پزشکی، میکروسکوپی، نجومی و سنجش از دور قابل انتقال تر از شبکه انتها به انتها برای یک دستگاه ثابت است.

۱۵.۵ پیشین امتیاز و مدل انتشار: از حذف نویز تا نمونه گیری پسین

۱۰۱۵.۵ تابع امتیاز و هویت توپیدی

اگر $x \sim p_X$ و $y = x + \sigma z$ ، آنگاه برای چگالی هموارشده $p_\sigma(y)$ ، هویت توپیدی می گوید

$$\mathbb{E}[X | Y = y] = y + \sigma^2 \nabla_y \log p_\sigma(y). \quad (۸۰.۵)$$

پس حذف کننده MMSE اطلاعاتی از امتیاز $s_\sigma(y) = \nabla_y \log p_\sigma(y)$ می دهد:

$$s_\sigma(y) = \frac{D_\sigma(y) - y}{\sigma^2}. \quad (۸۱.۵)$$

مدل های مبتنی بر امتیاز این میدان برداری را در سطوح نویز مختلف می آموزند و با یک فرایند معکوس از نویز به تصویر حرکت می کنند.

۲۰۱۵.۵ پسین در مسئله معکوس

$$\nabla_x \log p(x | y) = \nabla_x \log p(x) + \nabla_x \log p(y | x). \quad (۸۲.۵)$$

این تجزیه جذاب است: مدل انتشار امتیاز پیشین را می دهد و مدل فیزیکی گرادیان درست نمایی را. در نویز گاوسی خطی

$$\nabla_x \log p(y | x) = \frac{1}{\sigma_n^2} H^T (y - Hx). \quad (۸۳.۵)$$

در عمل، اعمال این راهنمایی در زمان های نویزی نیازمند تقریب $p(y | x_t)$ است. روش هایی مانند DPS با تقریب تصویر پاک از حالت میانی، برای مسائل خطی و غیرخطی نویزی نمونه گیری تقریبی انجام می دهند. [۳۱].

۳۰۱۵.۵ برآورد نقطه ای در برابر نمونه پسین

در مسئله شدیداً کم اطلاع، یک پاسخ یگانه و انمود کردن قطعیت است. نمونه های

$$x^{(1)}, \dots, x^{(K)} \sim p(x | y) \quad (۸۴.۵)$$

می توانند تنوع پاسخ های سازگار را نشان دهند. میانگین نمونه ها، واریانس پیکسلی و بازه ویژگی های اندازه گیری شده ابزارهای عدم قطعیت اند. اما کالیبراسیون نمونه ها باید آزموده شود؛ تنوع بصری به تنهایی اثبات پسین صحیح نیست.

۴۰۱۵.۵ خطر توهم و قید داده

هر نمونه باید با داده کنترل شود:

$$\chi^2(x) = \frac{1}{\sigma_n^2} \|Hx - y\|^2. \quad (۸۵.۵)$$


اگر χ^2 به طور غیرمعقول بزرگ باشد، تصویر از اندازه‌گیری فاصله گرفته است؛ اگر بیش از حد کوچک باشد، شاید نویز را برازش کرده باشد. در کاربرد علمی، نمایش Hx ، باقیمانده و نقشه عدم قطعیت کنار تصویر بازسازی شده ضروری است.

پل به دهه آینده

پژوهش‌های ۲۰۲۴ تا ۲۰۲۶ بر کاهش هزینه نمونه‌گیری، قیدگذاری بهتر، مدل‌های پایه بازسازی و ترکیب پیشین‌های از پیش آموخته متمرکزند. برای آموزش دهه آینده، اصل پایدار این است: مدل مولد باید با درست‌نمایی، قید داده و سنجش عدم قطعیت مهار شود؛ نام معماری ممکن است عوض شود، این اصل نه.

۱۶.۵ مبادله ادراک-اعوجاج و معنای «جزئیات بهتر»

برآورد MMSE اعوجاج مربعی متوسط را کم می‌کند، اما در پسین چندحالت می‌تواند بافت‌ها را میانگین بگیرد. روش ادراکی توزیع خروجی را به توزیع تصاویر طبیعی نزدیک می‌کند، ولی ممکن است از نمونه حقیقت خاص دور شود. این تضاد با منحنی مفهومی ادراک-اعوجاج بیان می‌شود [۳۲].



شکل ۹.۵: نمای مفهومی مبادله ادراک و اعوجاج. حرکت به سوی بافت طبیعی‌تر می‌تواند خطای نمونه‌به‌نمونه را افزایش دهد.

خطای رایج

عبارت‌هایی مانند «جزئیات بازیابی شد» فقط زمانی مجازند که داده یا حقیقت مبنا از آن پشتیبانی کند. در غیر این صورت باید گفت «جزئیات محتمل تولید شد» یا «کیفیت ادراکی افزایش یافت». این تفاوت در مقاله علمی حیاتی است.

۱۷.۵ ارزیابی: از PSNR تا کار پایین‌دست و عدم قطعیت

۱۰۱۷.۵ معیارهای دارای مرجع

برای دامنه شدت $[0, L]$:

$$\text{MSE} = \frac{1}{n} \|\hat{x} - x\|^2, \quad (۸۶.۵)$$

$$\text{PSNR} = 10 \log_{10} \frac{L^2}{\text{MSE}}. \quad (۸۷.۵)$$

SSIM روشی، کنتراست و ساختار محلی را مقایسه می‌کند. معیارهای ویژگی‌محور مانند LPIPS به شباهت ادراکی نزدیک‌ترند، اما به شبکه ویژگی و داده آموزش آن وابسته‌اند.

۲۰۱۷.۵ معیار سازگاری داده

حتی با حقیقت مبنا باید

$$r = y - H\hat{x} \quad (۸۸.۵)$$

بررسی شود. برای مدل گاوسی سفید، باقیمانده باید تقریباً صفرمیانگین، با واریانس درست و بدون ساختار مکانی باشد. وجود لبه در باقیمانده نشانه حذف جزئیات؛ وجود ساختار دوره‌ای نشانه مدل تاری یا مرز اشتباه است.

۳۰۱۷.۵ کار پایین دست


اگر خروجی برای قطعه‌بندی، تشخیص یا اندازه‌گیری استفاده می‌شود، عملکرد همان وظیفه باید گزارش شود. ممکن است روش با PSNR پایین‌تر، مرزهای تشخیصی را بهتر حفظ کند. در مقابل روش مولد ممکن است تصویر زیباتر ولی ویژگی کاذب بسازد.

۴۰۱۷.۵ هزینه و پایداری

گزارش کامل شامل زمان، حافظه، تعداد پارامتر، تعداد ارزیابی شبکه، انرژی تقریبی، حساسیت به اندازه تصویر و عملکرد روی دستگاه هدف است. برای روش تکراری، تنها زمان یک تکرار کافی نیست؛ معیار توقف و تعداد واقعی تکرار باید ذکر شود.

۵۰۱۷.۵ پروتکل داده واقعی

۱. داده خام و sRGB را مخلوط نکنید؛
۲. جداسازی آموزش/اعتبارسنجی/آزمون بر اساس صحنه و دستگاه انجام شود، نه وصله تصادفی از یک تصویر؛
۳. تخریب مصنوعی باید زنجیره حسگر را تا حد ممکن بازنمایی کند؛
۴. حداقل یک آزمون انتقال به سطح نویز، دوربین یا تخریب دیده‌نشده اجرا شود؛
۵. تصاویر شکست و نه فقط بهترین نمونه‌ها منتشر شوند.



شکل ۱۰۰۵: مقایسه بازتولیدپذیر چند خط مبنای کلاسیک روی نویز گاوسی مصنوعی. عدد بهتر همیشه به معنی بافت یا لبه بهتر در همه نواحی نیست.

۱۸۰۵ راهنمای انتخاب خانواده روش

جدول ۱۰۵: راهنمای عملی انتخاب روش؛ این جدول جای آزمایش را نمی گیرد.

وضعیت	نقطه شروع مناسب	مزیت	هشدار
نویز گاوسی معلوم و نیاز به خط مبنا	وینر، موجک، TV، BM3D	قابل تفسیر و کم داده	مدل نویز واقعی ممکن است نقض شود
نویز ضربه ای	میانه، l_1 ، مدل متغیر پرت	مقاوم به پرت	بافت ریز ممکن است حذف شود
نویز وابسته به سیگنال	درست نمایی، پواسون-گاوسی یا تثبیت واریانس	سازگار با حسگر	وارون سازی تبدیل و کالیبراسیون مهم است
رفع تاری با PSF معلوم	وینر/تیکانوف، TV، PnP	قید داده صریح	مرز و خطای هسته
تخریب مجهول ولی داده زوجی زیاد	شبکه کوریا همه کاره	سرعت آزمون بالا	شکست خارج از توزیع
عملگر جدید و داده پاک کم	PnP، شبکه باز شده، پیشین امتیاز	انتقال پذیری بیشتر	همگرایی و هزینه تکرار

وضعیت	نقطه شروع مناسب	مزیت	هشدار
مسئله چند جوابی کاربرد پزشکی/علی	نمونه‌گیری پسین مدل فیزیکی + عدم قطعیت + آزمون باقیمانده	نمایش عدم قطعیت قابلیت ممیزی	کالیبراسیون و توهم تصویر زیبا معیار کافی نیست
سامانه لبه‌ای	مدل سبک، جدول جست‌وجو، فیلتر کلاسیک یا شبکه کوچک	تأخیر و انرژی کم	افت تعمیم و محدودیت دقت

۱۹.۵ کارگاه بازتولید‌پذیر فصل

کارگاه کد و آزمایش: هدف

یک آزمایش کامل باید نه فقط خروجی تصویری، بلکه مدل تخریب، سطح نویز، پارامتر انتخاب شده، معیارها، زمان، باقیمانده و نسخه نرم‌افزار را ثبت کند. بسته این فصل اسکریپت تولید شکل‌ها و فایل‌های CSV تحلیل حساسیت را شامل می‌شود.

۱۰۱۹.۵ قرارداد داده و توابع پایه

```

1 from dataclasses import dataclass
2 import numpy as np
3 from skimage.metrics import peak_signal_noise_ratio,
  structural_similarity
4
5 @dataclass(frozen=True)
6 class GaussianNoise:
7     sigma: float
8     seed: int = 1405
9
10 def apply(self, clean: np.ndarray) -> np.ndarray:
11     if clean.dtype.kind != "f":
12         raise TypeError("clean must be floating point in [0, 1]")
13     rng = np.random.default_rng(self.seed)
14     noisy = clean + rng.normal(0.0, self.sigma, clean.shape)
15     return np.clip(noisy, 0.0, 1.0)
16

```

```

17 def metrics(clean: np.ndarray, estimate: np.ndarray) -> dict[str,
18     float]:
19     return {
20         "psnr": float(peak_signal_noise_ratio(clean, estimate,
21             data_range=1.0)),
22         "ssim": float(structural_similarity(clean, estimate,
23             data_range=1.0)),
24         "mse": float(np.mean((clean - estimate) ** 2)),
25     }

```

۲۰۱۹۰۵ حل تیکانوف کانولوشنی در حوزه فوریه

```

1 import numpy as np
2 from scipy.fft import fft2, ifft2
3
4
5 def psf_to_otf(psf: np.ndarray, shape: tuple[int, int]) -> np.ndarray
6     :
7     """Embed and circularly shift a PSF to construct its OTF."""
8     canvas = np.zeros(shape, dtype=float)
9     h, w = psf.shape
10    canvas[:h, :w] = psf
11    canvas = np.roll(canvas, -(h // 2), axis=0)
12    canvas = np.roll(canvas, -(w // 2), axis=1)
13    return fft2(canvas)
14
15 def tikhonov_deblur(y: np.ndarray, psf: np.ndarray, lam: float) -> np
16     .ndarray:
17     if lam <= 0:
18         raise ValueError("lam must be positive")
19     H = psf_to_otf(psf / psf.sum(), y.shape)
20     # First-order periodic finite differences
21     dx = np.zeros(y.shape); dx[0, 0], dx[0, 1] = -1, 1
22     dy = np.zeros(y.shape); dy[0, 0], dy[1, 0] = -1, 1
23     Dx, Dy = fft2(dx), fft2(dy)
24     denominator = np.abs(H) ** 2 + lam * (np.abs(Dx) ** 2 + np.abs(Dy)
25         ** 2)
26     X = np.conj(H) * fft2(y) / np.maximum(denominator, 1e-12)
27     return np.real(ifft2(X))

```

۳۰.۱۹.۵ گرادینان پروگرمال و ثبت تاریخچه

```

1 from collections.abc import Callable
2 import numpy as np
3
4 Array = np.ndarray
5
6
7 def proximal_gradient(
8     x0: Array,
9     grad_f: Callable[[Array], Array],
10    prox_g: Callable[[Array, float], Array],
11    step: float,
12    objective: Callable[[Array], float],
13    max_iter: int = 300,
14    tol: float = 1e-6,
15 ) -> tuple[Array, list[float]]:
16     if step <= 0:
17         raise ValueError("step must be positive")
18     x = x0.copy()
19     history = [objective(x)]
20     for _ in range(max_iter):
21         x_next = prox_g(x - step * grad_f(x), step)
22         history.append(objective(x_next))
23         relative = np.linalg.norm(x_next - x) / max(np.linalg.norm(x)
24 , 1e-12)
25         x = x_next
26         if relative < tol:
27             break
28     return x, history

```

۴۰.۱۹.۵ پروتکل مقایسه منصفانه

۰۱. سه سطح نویز و دست کم پنج تصویر با ساختار متفاوت؛
۰۲. تنظیم پارامتر فقط روی اعتبارسنجی؛
۰۳. اجرای چند بذرنویز و گزارش میانگین و انحراف معیار؛
۰۴. ثبت PSNR، SSIM، زمان و معیار حفظ لبه؛
۰۵. نمایش برش بزرگ نمایی شده و باقیمانده با مقیاس ثابت؛
۰۶. آزمون حساسیت به خطای تخمین σ ؛

۰۷. یک آزمون داده واقعی یا تخریب خارج از مدل.

۵.۱۹.۵ پرامپت دقیق برای Codex

کارگاه کد و آزمایش: پرامپت

Act as a research software engineer in inverse imaging. Build a fully reproducible Python benchmark for Chapter 5. Use a clean package structure with typed functions, unit tests, fixed random seeds, configuration files, CSV outputs, and publication-quality figures. Implement: Gaussian/Poisson/impulse degradation; Gaussian and median filters; wavelet soft thresholding; non-local means; TV denoising; Tikhonov deblurring; an ISTA/FISTA solver; and one plug-and-play reconstruction using a clearly documented denoiser. For every method, separate training/tuning/test information, record runtime and memory, check data consistency, and report mean plus standard deviation over Monte Carlo trials. Do not silently clip arrays or mix uint8 and floating-point intensity scales. Add tests for adjoint consistency of H and H^T , finite-difference gradient checks, reproducibility, and boundary conditions. Produce a failure-case gallery and a Markdown report explaining where each model assumption is violated. Do not fabricate results: execute every experiment.

۲۰۰۵ تمرین‌های ریاضی، محاسباتی و پژوهشی

تمرین‌های اثباتی

۰۱. رابطه وینر (۲۱۰۵) را با مشتق‌گیری مستقیم از $\mathbb{E}|X - GY|^2$ استخراج کنید.
۰۲. نشان دهید برای پیشین گاوسی و نویز گاوسی، MAP و MMSE یکسان‌اند.
۰۳. پروگرام $\lambda|x|$ را با بررسی سه حالت $x > 0$ ، $x < 0$ و $x = 0$ به دست آورید.
۰۴. دوگان تغییرات کلی همسانگرد را استخراج کنید و قید $\|p_i\|_1 \leq 1$ را توضیح دهید.
۰۵. ثابت کنید تیکانوف مرتبه صفر در پایه بردارهای منفرد ضریب فیلتری $(\sigma_i^2/(\sigma_i^2 + \lambda))$ دارد.
۰۶. برای مدل پواسون، گرادیان و هسین جمله داده (۴۰۵) را به دست آورید و محدب بودن را بررسی کنید.
۰۷. شرطی ارائه کنید که یک نگاشت خطی $D(x) = Wx$ پروگرام یک تابع محدب باشد.
۰۸. هویت تویدی (۸۰۵) را با مشتق‌گیری از کانولوشن چگالی با گاوسی اثبات کنید.

تمرین‌های محاسباتی

۰۱. واریانس خروجی فیلترهای میانگین 3×3 ، 5×5 و گاوسی را با رابطه (۱۷.۵) پیش‌بینی و تجربی تأیید کنید.
۰۲. یک تصویر را با نویز نمک و فلفل و گاوسی تخریب کنید و میانگین و میانه را روی هر دو مقایسه کنید.
۰۳. آستانه جهانی، SURE و آستانه اعتبارسنجی را برای موجک مقایسه کنید.
۰۴. پیاده‌سازی ساده NLM بنویسید و اثر اندازه وصله، پنجره جست‌وجو و h را تحلیل کنید.
۰۵. مدل ROF را با روش اولیه-دوگان حل کنید و شکاف اولیه-دوگان را رسم کنید.
۰۶. رفع تارگی تیکانوف را با سه شرط مرزی پیاده‌سازی و مصنوعات مرزی را مقایسه کنید.
۰۷. برای یک اپراتور H آزمون عددی الحاقی $\langle Hx, y \rangle \approx \langle x, H^T y \rangle$ بنویسید.
۰۸. در یک مسئله درون‌برگردن، پنج نمونه مولد تولید کنید و واریانس نواحی مفقود و مشاهده‌شده را مقایسه کنید.

تمرین‌های پژوهشی

۰۱. یک مقاله کلاسیک مانند BM3D و یک مدل جدید مانند Restormer را از نظر فرض، داده، هزینه، پیچیدگی و نوع شکست مقایسه کنید؛ نه فقط جدول PSNR.
۰۲. بررسی کنید آیا حذف‌کننده انتخابی شما تقریباً غیرانبساطی است. نسبت $\|D(x + \delta) - D(x)\| / \|\delta\|$ را برای اغتشاش‌های مختلف تخمین بزنید.
۰۳. یک پروتکل برای تشخیص توهم در ابرتفکیک پزشکی یا ماهواره‌ای طراحی کنید.
۰۴. یک روش همه‌کاره بازسازی را روی تخریب مرکب دیده‌نشده آزمایش کنید و بازنمایی تخریب را تحلیل نمایید.
۰۵. یک روش نمونه‌گیری پسین را از نظر پوشش بازه، سازگاری داده و تنوع مؤثر ارزیابی کنید.
۰۶. هزینه انرژی و تأخیر یک شبکه بزرگ را با BM3D، TV و یک شبکه سبک روی سخت‌افزار واقعی مقایسه کنید.

۲۱۰۵ تقسیم پیشنهادی فصل به ویدئوهای ۱۵ دقیقه‌ای

تقسیم پیشنهادی ویدئوهای ۱۵ دقیقه‌ای

۱. ویدئو ۱: تفاوت بهبود، حذف نویز، بازسازی و وظیفه پایین دست.
۲. ویدئو ۲: مدل پیشرو، درست نمایی و پیشین؛ استخراج انرژی MAP.
۳. ویدئو ۳: تابع خطر و اثبات برآوردگر میانگین شرطی.
۴. ویدئو ۴: بدشرطی، SVD و معنای منظم سازی طیفی.
۵. ویدئو ۵: استخراج کامل فیلتر وینر و رابطه آن با تیکانوف.
۶. ویدئو ۶: میانگین، میانه، دوطرفه و هدایت شده؛ حفظ لبه.
۷. ویدئو ۷: موجک، تنکی، آستانه سخت و نرم و SURE.
۸. ویدئو ۸: خودشباهتی، NLM و سوگیری فاصله وصله.
۹. ویدئو ۹: گروه وصله، رتبه کم و معماری مفهومی BM3D.
۱۰. ویدئو ۱۰: مدل ROF، معادله اوایلر-لاگرانژ و پلکانی شدن.
۱۱. ویدئو ۱۱: پروگرامال و استخراج ISTA/FISTA.
۱۲. ویدئو ۱۲: ADMM، باقیمانده ها و تنظیم پارامتر.
۱۳. ویدئو ۱۳: رفع تاری، شرایط مرزی و رفع تاری کور.
۱۴. ویدئو ۱۴: درون پرکردن و ابرتفکیک به عنوان مسائل چندجوابی.
۱۵. ویدئو ۱۵: یادگیری باقیمانده، DnCNN و اثر تابع هزینه.
۱۶. ویدئو ۱۶: ترنسفورمرهای بازسازی و مدل های همه کاره.
۱۷. ویدئو ۱۷: شبکه های باز شده و جداسازی سازگاری داده از پیشین.
۱۸. ویدئو ۱۸: RED، Plug-and-Play و مسئله همگرایی.
۱۹. ویدئو ۱۹: هویت توپیدی، تابع امتیاز و بازسازی با انتشار.
۲۰. ویدئو ۲۰: نمونه گیری پسین، عدم قطعیت و خطر توهم.
۲۱. ویدئو ۲۱: ادراک-اعوجاج، PSNR/SSIM/LPIPS و معیار پایین دست.
۲۲. ویدئو ۲۲: کارگاه مقایسه کلاسیک و تحلیل حساسیت پارامتر.
۲۳. ویدئو ۲۳: طراحی آزمایش داده واقعی و آزمون خارج از توزیع.

۰۲۴. ویدئو ۲۴: جمع‌بندی، نقد مقاله و تعریف پروژه پایان فصل.

۲۲.۵ پروژه پایان فصل: از مدل تا گزارش قابل داوری

دانشجویی از سه مسیر را انتخاب می‌کند:

۰۱. مسیر کلاسیک عمیق: مقایسه وینر، موجک، NLM، BM3D و TV با تحلیل فرض و پیچیدگی؛
 ۰۲. مسیر ترکیبی: بازسازی یک عملگر جدید با PnP یا شبکه باز شده؛
 ۰۳. مسیر مولد: نمونه‌گیری پسین برای درون‌پرکردن یا ابرتفکیک همراه با سنجش عدم قطعیت.
- گزارش باید شامل مدل پیشرو، مدل نویز، داده، معیار، خط مبنا، تنظیم پارامتر، تحلیل شکست، هزینه محاسباتی، کد و بذرتصادفی باشد. حداقل یک ادعای کیفی باید با آزمون کمی یا تحلیل باقیمانده پشتیبانی شود.

۲۳.۵ جمع‌بندی و پل به فصل ششم

جمع‌بندی فصل

۰۱. حذف نویز حالت ویژه‌ای از مسئله معکوس است؛ عملگر H ، درست‌نمایی و پیشین باید از ابتدا روشن باشند.
۰۲. برآوردگر بهینه به تابع خطر وابسته است: هزینه مربعی میانگین شرطی و هزینه قدرمطلق میانه شرطی را می‌دهد.
۰۳. وینر راه‌حل خطی MMSE است و تیکانوف همان منطق پایداری را از دیدگاه تغییراتی و بیزی بیان می‌کند.
۰۴. روش‌های موجک، فرهنگ لغت، غیرمحلی و رتبه کم همگی درجه آزادی مؤثر تصویر را کاهش می‌دهند، اما با ساختارهای متفاوت.
۰۵. TV لبه را بهتر از همواری درجه دوم حفظ می‌کند، ولی فرض قطعه‌ای ثابت و پدیده پلکانی دارد.
۰۶. روش‌های پروگرام‌زبان محاسباتی منظم‌سازهای ناهموارند و باید با شرط گام، باقیمانده و معیار توقف تدریس شوند.
۰۷. شبکه‌های عمیق تابع شرطی را از داده می‌آموزند؛ نوع هزینه، داده آموزشی و تخریب شبیه‌سازی شده ماهیت برآوردگر را تعیین می‌کند.

۸. شبکه باز شده و PnP سازگاری فیزیکی را با پیشین آموخته شده ترکیب می کنند، اما تفسیر انرژی و همگرایی نیازمند شرط است.
۹. مدل انتشار امکان نمونه گیری از پاسخ های متعدد را فراهم می کند، ولی بدون قید داده و کالیبراسیون ممکن است جزئیات کاذب بسازد.
۱۰. ارزیابی معتبر باید هم زمان اعوجاج، ادراک، سازگاری داده، عدم قطعیت، هزینه و عملکرد پایین دست را بسنجد.
۱۱. فصل ششم می تواند بر استخراج ویژگی، لبه، ساختار چند مقیاسی و نمایش های هندسی بنا شود؛ زیرا اکنون می دانیم پیش پردازش چگونه اطلاعات را حفظ یا نابود می کند.

منابع منتخب فصل

Bibliography

- [1] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4th ed., Pearson, 2018.
- [2] M. Bertero and P. Boccacci, *Introduction to Inverse Problems in Imaging*, CRC Press, 1998.
- [3] H. W. Engl, M. Hanke, and A. Neubauer, *Regularization of Inverse Problems*, Springer, 1996.
- [4] S. M. Kay, *Fundamentals of Statistical Signal Processing: Estimation Theory*, Prentice Hall, 1993.
- [5] N. Wiener, *Extrapolation, Interpolation, and Smoothing of Stationary Time Series*, MIT Press, 1949.
- [6] A. N. Tikhonov and V. Y. Arsenin, *Solutions of Ill-Posed Problems*, Winston, 1977.
- [7] L. I. Rudin, S. Osher, and E. Fatemi, "Nonlinear total variation based noise removal algorithms," *Physica D*, vol. 60, pp. 259–268, 1992.
- [8] A. Chambolle, "An algorithm for total variation minimization and applications," *Journal of Mathematical Imaging and Vision*, vol. 20, pp. 89–97, 2004.
- [9] A. Chambolle and T. Pock, "A first-order primal-dual algorithm for convex problems with applications to imaging," *Journal of Mathematical Imaging and Vision*, vol. 40, pp. 120–145, 2011.
- [10] A. Beck and M. Teboulle, "A fast iterative shrinkage-thresholding algorithm for linear inverse problems," *SIAM Journal on Imaging Sciences*, vol. 2, no. 1, pp. 183–202, 2009.
- [11] S. Boyd, N. Parikh, E. Chu, B. Peleato, and J. Eckstein, "Distributed optimization and statistical learning via the alternating direction method

- of multipliers," *Foundations and Trends in Machine Learning*, vol. 3, no. 1, pp. 1-122, 2011.
- [12] D. L. Donoho, "De-noising by soft-thresholding," *IEEE Transactions on Information Theory*, vol. 41, no. 3, pp. 613-627, 1995.
- [13] C. M. Stein, "Estimation of the mean of a multivariate normal distribution," *The Annals of Statistics*, vol. 9, no. 6, pp. 1135-1151, 1981.
- [14] A. Buades, B. Coll, and J.-M. Morel, "A non-local algorithm for image denoising," in *Proceedings of CVPR*, pp. 60-65, 2005.
- [15] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian, "Image denoising by sparse 3-D transform-domain collaborative filtering," *IEEE Transactions on Image Processing*, vol. 16, no. 8, pp. 2080-2095, 2007.
- [16] M. Aharon, M. Elad, and A. Bruckstein, "K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation," *IEEE Transactions on Signal Processing*, vol. 54, no. 11, pp. 4311-4322, 2006.
- [17] E. J. Candès, X. Li, Y. Ma, and J. Wright, "Robust principal component analysis?," *Journal of the ACM*, vol. 58, no. 3, 2011.
- [18] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang, "Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising," *IEEE Transactions on Image Processing*, vol. 26, no. 7, pp. 3142-3155, 2017.
- [19] D. Ulyanov, A. Vedaldi, and V. Lempitsky, "Deep image prior," in *Proceedings of CVPR*, pp. 9446-9454, 2018.
- [20] J. Lehtinen et al., "Noise2Noise: Learning image restoration without clean data," in *Proceedings of ICML*, pp. 2965-2974, 2018.
- [21] J. Batson and L. Royer, "Noise2Self: Blind denoising by self-supervision," in *Proceedings of ICML*, pp. 524-533, 2019.
- [22] S. V. Venkatakrisnan, C. A. Bouman, and B. Wohlberg, "Plug-and-play priors for model based reconstruction," in *IEEE GlobalSIP*, pp. 945-948, 2013.
- [23] Y. Romano, M. Elad, and P. Milanfar, "The little engine that could: Regularization by denoising (RED)," *SIAM Journal on Imaging Sciences*, vol. 10, no. 4, pp. 1804-1844, 2017.

- [24] J. Liu, Y. Sun, X. Xu, and U. S. Kamilov, "Recovery analysis for plug-and-play priors using the restricted eigenvalue condition," in *Advances in Neural Information Processing Systems*, 2021.
- [25] J. Liang et al., "SwinIR: Image restoration using Swin Transformer," in *Proceedings of ICCV Workshops*, pp. 1833–1844, 2021.
- [26] S. W. Zamir et al., "Restormer: Efficient Transformer for high-resolution image restoration," in *Proceedings of CVPR*, pp. 5728–5739, 2022.
- [27] L. Chen, X. Chu, X. Zhang, and J. Sun, "Simple baselines for image restoration," in *Proceedings of ECCV*, pp. 17–33, 2022.
- [28] V. Potlapalli, S. W. Zamir, S. Khan, and F. S. Khan, "PromptIR: Prompting for all-in-one blind image restoration," in *Advances in Neural Information Processing Systems*, 2023.
- [29] H. Li, X. Chen, J. Dong, J. Tang, and J. Pan, "FoundIR: Unleashing million-scale training data to advance foundation models for image restoration," in *Proceedings of ICCV*, pp. 12626–12636, 2025.
- [30] Y. Song et al., "Score-based generative modeling through stochastic differential equations," in *Proceedings of ICLR*, 2021.
- [31] H. Chung, J. Kim, M. T. Mccann, M. L. Klasky, and J. C. Ye, "Diffusion posterior sampling for general noisy inverse problems," in *Proceedings of ICLR*, 2023.
- [32] Y. Blau and T. Michaeli, "The perception-distortion tradeoff," in *Proceedings of CVPR*, pp. 6228–6237, 2018.
- [33] A. Abdelhamed, S. Lin, and M. S. Brown, "A high-quality denoising dataset for smartphone cameras," in *Proceedings of CVPR*, pp. 1692–1700, 2018.
- [34] T. Plötz and S. Roth, "Benchmarking denoising algorithms with real photographs," in *Proceedings of CVPR*, pp. 1586–1595, 2017.
- [35] T. Brooks, B. Mildenhall, T. Xue, J. Chen, D. Sharlet, and J. T. Barron, "Unprocessing images for learned raw denoising," in *Proceedings of CVPR*, pp. 11036–11045, 2019.

راهنمای کامپایل، فونت و اجرای آزمایش‌ها

فایل با XeLaTeX کامپایل می‌شود. در TeXstudio، کامپایلر پیش‌فرض را روی XeLaTeX قرار دهید و برای تکمیل فهرست مطالب دوبار اجرا کنید. فونت اصلی Amiri، فونت لاتین DejaVu Serif و فونت کد DejaVu Sans Mono است؛ برای هر سه جایگزین خودکار تعریف شده است. هیچ فایل فونتی در بسته قرار نگرفته است.

برای تولید شکل‌ها:

```
1 python -m venv .venv
2 # Windows: .venv\Scripts\activate
3 # Linux/macOS: source .venv/bin/activate
4 pip install -r requirements.txt
5 python scripts/generate_figures.py
6 xelatex image_processing_next_decade_ch05_fa.tex
7 xelatex image_processing_next_decade_ch05_fa.tex
```