
پردازش تصویر در دهه آینده

از عمق ریاضیات تا مهندس حرفه‌ای

کتاب - جزوه درس کارشناسی ارشد و آزمایشگاه پژوهش محور

هشتم فصل

ناحیه استخراج و تصویر قطعه‌بندی

گرافی، انرژی‌های تا آماری مدل‌های و ناحیه رشد آستانه‌گذاری، از
قطعه‌بندی بنیادین مدل‌های و عمیق شبکه‌های فعال، منحنی‌های

«تصمیم به پیکسل» مقدار «تغییر از تصویر پردازش که است نقطه‌ای قطعه‌بندی
مدرن و کلاسیک روش‌های فصل این می‌رسد. معنا» و شیء ساختار، درباره
می‌دهد. پیوند بهینه‌سازی و احتمال انرژی، تصمیم، مشترک زبان یک با را

نسخه تفصیلی درس - تابستان ۱۴۰۵ / ۲۰۲۶

قابل کامپایل با XeLaTeX + TeXstudio + TeX Live

یادداشت روش شناختی فصل هشتم

قطعه‌بندی یکی از کاربردی‌ترین و در عین حال بدتعریف‌ترین مسائل پردازش تصویر است. «قطعه درست» تنها از مقادیر خاکستری به دست نمی‌آید؛ تعریف آن به هدف، مقیاس، دانش دامنه، نوع برچسب و هزینه خطا بستگی دارد. مرز تومور برای برنامه‌ریزی جراحی، ناحیه جاده برای ربات، حروف یک سند، قطعات یک محصول صنعتی و اشیای یک صحنه طبیعی همگی قطعه‌بندی‌اند، اما خروجی، زیان و معیار ارزیابی یکسان ندارند.

هدف فصل

هدف این فصل حفظ یک ستون فقرات واحد است:

$$\hat{z} = \arg \min_z \left\{ \underbrace{D(z; \mathbf{y})}_{\text{سازگاری با داده}} + \lambda \underbrace{R(z)}_{\text{ساختار، همواری و دانش پیشین}} \right\}.$$

آستانه‌گذاری هنگامی پدید می‌آید که تصمیم مستقل و یک‌بعدی باشد؛ رشد ناحیه اتصال را وارد می‌کند؛ مدل‌های آماری عدم قطعیت را می‌افزایند؛ روش‌های گرافی و واریاسیونی وابستگی مکانی را مدل می‌کنند؛ و شبکه‌های عمیق و مدل‌های بنیادین نمایش و پیشین را از داده‌های بزرگ می‌آموزند.

نقشه فشرده فصل

محرور	پرسش اصلی و خروجی آموزشی
تعریف مسئله	تفاوت قطعه‌بندی دودویی، چندکلاسه، معنایی، نمونه‌ای، پان‌پتیک، تعاملی و مفهوم محور چیست؟
تصمیم‌آماري	چگونه از چگالی‌های شرطی و هزینه خطا، قاعده بیز و آستانه بهینه استخراج می‌شود؟
آستانه‌گذاری	Otsu، چندآستانه‌ای، Niblack، error، minimum entropy، Sauvola و تصویر انتگرالی چگونه کار می‌کنند؟
روش ناحیه‌ای	رشد ناحیه، watershed split-merge، نشان‌محور و قیود اتصال چگونه طراحی می‌شوند؟
خوشه‌بندی	k-means، c-means fuzzy GMM-EM و shift mean چه فرض‌هایی دارند و چگونه مکان را وارد کنیم؟
مدل واریاسیونی	Chan-Vese، Mumford-Shah، set level و انرژی‌های محلی چگونه استخراج می‌شوند؟
گراف و طیف	walker random cut، normalized cut، graph MRF/CRF چگونه به دستگاه خطی یا max-flow می‌رسند؟
ابریکسل	SLIC چگونه فضای رنگ و مکان را خوشه‌بندی می‌کند و کیفیت ابریکسل چگونه سنجیده می‌شود؟
یادگیری عمیق	Former، Mask، R-CNN Mask، DeepLab، U-Net، FCN، چگونه مسئله ابریکسل و ماسک را حل می‌کنند؟
زیان‌ها	boundary Lovasz، Tversky، Dice، focal، cross-entropy، loss topology چه هندسه‌ای دارند؟
مدل بنیادی	SAM، SAM ۲ و SAM ۳ چگونه prompt، حافظه و مفهوم را وارد قطعه‌بندی می‌کنند؟
ارزیابی	PQ، AP، Hausdorff، IoU، Boundary Dice، IoU، و آزمون آماری چه چیزی را می‌سنجند؟
مهندسی	چگونه داده، برش تصویر، عدم توازن، بازتولیدپذیری، زمان اجرا و ممیزی شکست مدیریت می‌شوند؟

اهداف یادگیری

پس از پایان فصل، دانشجو باید بتواند:

۱. یک مسئله کاربردی را به نوع صحیح قطعه‌بندی و فضای برچسب نگاشت کند؛
۲. آستانه بیزی و Otsu را از ابتدا استخراج و پیاده‌سازی کند؛
۳. تفاوت آستانه جهانی و محلی را با تحلیل روشنایی و نویز توضیح دهد؛
۴. الگوریتم‌های رشد ناحیه، graph GMM-EM، random cut، Chan-Vese walker و SLIC را پیاده‌سازی و ممیزی کند؛
۵. انرژی‌های MRF/CRF و شرط زیرمدولار بودن برش گراف را تشخیص دهد؛
۶. معماری و زیان شبکه قطعه‌بندی را بر اساس اندازه شیء، عدم توازن، مرز و توپولوژی انتخاب کند؛
۷. تفاوت semantic، panoptic instance و segmentation promptable را در خروجی و معیار ارزیابی بیان کند؛
۸. عدم قطعیت، کالیبراسیون و تعمیم خارج از توزیع را در گزارش نهایی وارد کند؛
۹. یک خط لوله پژوهشی قابل بازتولید از داده خام تا گزارش آماری بسازد.

پیش نیازها و قرارداد نمادگذاری

فرض می کنیم تصویر مشاهده شده $y \in \mathbb{R}^{H \times W \times C}$ و مجموعه پیکسل ها $\Omega = \{1, \dots, H\} \times \{1, \dots, W\}$ است. برچسب پیکسل p را با $z_p \in \{0, \dots, K-1\}$ نشان می دهیم. در مسئله دودویی، ماسک $M \subseteq \Omega$ یا تابع مشخصه $m_p \in \{0, 1\}$ معادل اند. همسایگی گراف تصویر را $\mathcal{N}$ و یال ها را $\mathcal{E}$ می نامیم.

قرارداد میان ریاضیات و کد

هر روش باید پنج خروجی تولید کند: ماسک یا نقشه برچسب، نقشه اطمینان، پارامترهای استفاده شده، زمان و حافظه، و گزارش شکست. هر مقایسه باید قرارداد مرز، اتصال، فضای رنگ، نرمال سازی، seed تصادفی و نسخه گنجینه را ثبت کند. نمایش یک تصویر زیبا بدون ذخیره این اطلاعات آزمایش علمی محسوب نمی شود.

فهرست مطالب

آ	یادداشت روش شناختی فصل هشتم
ب	نقشه فشرده فصل
ت	پیش نیازها و قرارداد نمادگذاری
۱	۸ قطعه بندی تصویر: از آستانه تا مفهوم
۱	۱۰.۸ چرا قطعه بندی یک مسئله واحد نیست؟
۲	۱۰.۱۰.۸ قطعه بندی به عنوان تصمیم ساخت یافته
۲	۲۰.۸ قاعده بیز و پیدایش آستانه
۳	۱۰.۲۰.۸ دو کلاس گاوسی با واریانس برابر
۳	۳۰.۸ آستانه گذاری سراسری
۳	۱۰.۳۰.۸ فرمول بندی عمومی
۳	۲۰.۳۰.۸ روش Otsu: استخراج دقیق
۵	۳۰.۳۰.۸ تفسیر Otsu به عنوان خوشه بندی یک بعدی
۵	۴۰.۳۰.۸ چند آستانه ای و برنامه ریزی پویا
۶	۵۰.۳۰.۸ آستانه entropy و error minimum
۶	۶۰.۳۰.۸ روش های ساده اما مفید
۶	۴۰.۸ آستانه گذاری محلی و روش نای ناهمگن
۷	۱۰.۴۰.۸ میانگین محلی و تصویر انتگرالی
۷	۲۰.۴۰.۸ Sauvola و Niblack
۸	۳۰.۴۰.۸ آستانه دوبعدی و ویژگی های چند کاناله
۸	۵۰.۸ رشد ناحیه و اتصال
۹	۱۰.۵۰.۸ انتخاب seed
۱۰	۲۰.۵۰.۸ merge and Split

۳۰۵۰۸	رابطه با watershed	۱۰
۶۰۸	خوشه‌بندی و مدل‌های مخلوط	۱۰
۱۰۶۰۸	k-means در فضای ویژگی	۱۰
۲۰۶۰۸	GMM و الگوریتم EM	۱۱
۳۰۶۰۸	c-means Fuzzy	۱۲
۴۰۶۰۸	shfit Mean	۱۲
۵۰۶۰۸	افزودن ساختار مکانی	۱۲
۷۰۸	قطعه‌بندی واریاسیونی: از Mumford-Shah تا Chan-Vese	۱۲
۱۰۷۰۸	تابع Mumford-Shah	۱۳
۲۰۷۰۸	مدل قطعه‌ای ثابت و انرژی Chan-Vese	۱۳
۳۰۷۰۸	contour active Geodesic	۱۴
۴۰۷۰۸	مدل‌های محلی و چندفازی	۱۴
۸۰۸	مدل‌های گرافی و انرژی گسسته	۱۵
۱۰۸۰۸	MRF/CRF و انرژی Potts	۱۵
۲۰۸۰۸	برش s-t برای مسئله دودویی	۱۵
۳۰۸۰۸	چندکلاسه و alpha-expansion	۱۶
۴۰۸۰۸	cut Normalized و مسئله مقدار ویژه	۱۶
۵۰۸۰۸	walker Random و توابع هارمونیک	۱۷
۶۰۸۰۸	مقایسه cut graph و walker random	۱۸
۷۰۸۰۸	الگوریتم گرافی Felzenszwalb-Huttenlocher	۱۸
۹۰۸	ابریکسل: کاهش هوشمند تعداد متغیرها	۱۸
۱۰۹۰۸	SLIC به عنوان k-means محلی	۱۸
۲۰۹۰۸	معیارهای ابریکسل	۱۹
۱۰۰۸	از طبقه‌بندی پیکسل تا شبکه‌های تمام کانولوشنی	۱۹
۱۰۱۰۰۸	فرمول‌بندی شبکه	۱۹
۲۰۱۰۰۸	U-Net و مسیر مکان‌یابی	۲۰
۳۰۱۰۰۸	convolution atrous و میدان دید	۲۰
۴۰۱۰۰۸	R-CNN Mask و segmentation Instance	۲۰
۵۰۱۰۰۸	segmentation Panoptic	۲۱
۶۰۱۰۰۸	Transformer و پیش‌بینی مجموعه ماسک	۲۱
۱۱۰۸	توابع زیان: آنچه آموزش می‌دهیم الزاماً آنچه ارزیابی می‌کنیم نیست	۲۱
۱۰۱۱۰۸	Cross-entropy و وزن‌دهی کلاس	۲۱

۲۲		loss Focal ۲۰۱۱۰۸
۲۲		Dice و رابطه آن با IoU ۳۰۱۱۰۸
۲۲		Tversky و کنترل FP/FN ۴۰۱۱۰۸
۲۲		Lovasz-Softmax ۵۰۱۱۰۸
۲۳		۶۰۱۱۰۸ زیان مرز، فاصله و توپولوژی
۲۳		۱۲۰۸ داده، برچسب و طراحی آموزش
۲۴		۱۰۱۲۰۸ پروتکل برچسب گذاری
۲۴		۲۰۱۲۰۸ تقسیم داده بدون leakage
۲۴		۳۰۱۲۰۸ Patch sampling و عدم توازن
۲۴		۴۰۱۲۰۸ augmentation Data هندسی و فوتومتریک
۲۴		۵۰۱۲۰۸ برش تصویر و stitching
۲۴		۶۰۱۲۰۸ نظارت ضعیف، نیمه نظارتی و خودنظارتی
۲۵		۷۰۱۲۰۸ learning Active
۲۵		۱۳۰۸ عدم قطعیت و کالیبراسیون
۲۵		۱۰۱۳۰۸ عدم قطعیت aleatoric و epistemic
۲۵		۲۰۱۳۰۸ کالیبراسیون پیکسلی
۲۶		۳۰۱۳۰۸ scaling Temperature و محدودیت آن
۲۶		۴۰۱۳۰۸ prediction Conformal برای مجموعه برچسب
۲۶		۱۴۰۸ مدل های بنیادین قطعه بندی
۲۶		۱۰۱۴۰۸ SAM: قطعه بندی promptable
۲۷		۲۰۱۴۰۸ SAM ۲: حافظه جریان برای تصویر و ویدئو
۲۷		۳۰۱۴۰۸ SAM ۳: prompt مفهومی
۲۸		۴۰۱۴۰۸ Adaptation کم هزینه
۲۸		۵۰۱۴۰۸ محدودیت ها و ممیزی
۲۸		۱۵۰۸ معیارهای ارزیابی
۲۸		۱۰۱۵۰۸ ماتریس اغتشاش پیکسلی
۲۹		۲۰۱۵۰۸ micro Macro و وزن دهی
۲۹		۳۰۱۵۰۸ مرز و فاصله
۲۹		۴۰۱۵۰۸ instance و panoptic معیار
۳۰		۵۰۱۵۰۸ توپولوژی و ساختار نازک
۳۰		۶۰۱۵۰۸ آزمون آماری
۳۰		۱۶۰۸ طبقه بندی خطا و آزمون فشار

۱۷۰۸	کارگاه پایتون: پیاده‌سازی مرجع و قابل آزمون	۳۱
۱۰۱۷۰۸	Otsu از صفر	۳۱
۲۰۱۷۰۸	آستانه Sauvola با کنترل نوع داده	۳۲
۳۰۱۷۰۸	رشد ناحیه با صف و آمار آنالین	۳۲
۴۰۱۷۰۸	GMM و نگاشت مسئولیت	۳۳
۵۰۱۷۰۸	walker Random و Chan-Vese با scikit-image	۳۴
۶۰۱۷۰۸	معیارهای مقاوم به ماسک خالی	۳۴
۷۰۱۷۰۸	اسکلت فشرده U-Net در PyTorch	۳۵
۱۸۰۸	الگوریتم آموزش و ارزیابی شبکه	۳۶
۱۹۰۸	آزمایش‌های پیشنهادی فصل	۳۷
۱۰۱۹۰۸	آزمایش ۱: مرز اعتبار Otsu	۳۷
۲۰۱۹۰۸	آزمایش ۲: روشنایی ناهمگن	۳۷
۳۰۱۹۰۸	آزمایش ۳: رشد ناحیه و ترتیب	۳۷
۴۰۱۹۰۸	آزمایش ۴: GMM و ویژگی مکانی	۳۷
۵۰۱۹۰۸	آزمایش ۵: cut graph در برابر walker random	۳۸
۶۰۱۹۰۸	آزمایش ۶: Chan-Vese زیر مدل‌های مختلف	۳۸
۷۰۱۹۰۸	آزمایش ۷: ابرپیکسل	۳۸
۸۰۱۹۰۸	آزمایش ۸: loss و عدم توازن	۳۸
۹۰۱۹۰۸	آزمایش ۹: کیفیت مرز	۳۸
۱۰۰۱۹۰۸	آزمایش ۱۰: segmentation promptable	۳۸
۱۰۱۹۰۸	آزمایش ۱۱: تعمیم خارج از توزیع	۳۸
۱۲۰۱۹۰۸	آزمایش ۱۲: اثر قطعه‌بندی بر وظیفه پایین‌دست	۳۹
۲۰۰۸	پروتکل گزارش حرفه‌ای	۳۹
۲۱۰۸	تمرین‌های نظری و اثباتی	۳۹
۲۲۰۸	پروژه‌های پایان فصل	۴۰
۱۰۲۲۰۸	پروژه A: آزمایشگاه جامع آستانه‌گذاری	۴۰
۲۰۲۲۰۸	پروژه B: قطعه‌بندی تعاملی کلاسیک و بنیادی	۴۰
۳۰۲۲۰۸	پروژه C: قطعه‌بندی پزشکی با عدم قطعیت	۴۱
۴۰۲۲۰۸	پروژه D: قطعه‌بندی ناحیه‌ای هیبرید	۴۱
۵۰۲۲۰۸	پروژه E: مدل بنیادی برای تولید داده	۴۱
۶۰۲۲۰۸	پروژه F: قطعه‌بندی توپولوژی آگاه	۴۱

۴۱		۲۳۰۸	پرامپت پیشنهادی برای Codex
۴۲		۲۴۰۸	تقسیم پیشنهادی ویدئوهای ۱۵ دقیقه‌ای
۴۴		۲۵۰۸	جمع‌بندی و پل به فصل نهم


۴۶			منابع منتخب فصل
----	--	--	-----------------

۵۰			راهنمای کامپایل، فونت و اجرای آزمایش‌ها
----	--	--	---

فصل ۸

قطعه‌بندی تصویر: از آستانه تا مفهوم

۱۰۸ چرا قطعه‌بندی یک مسئله واحد نیست؟



The output semantics, supervision and interaction protocol define different mathematical tasks.

شکل ۱۰۸: رده‌بندی وظایف قطعه‌بندی بر اساس معنای خروجی، تعامل و بعد زمانی. یک معماری ممکن است چند وظیفه را پوشش دهد، اما قرارداد برچسب و معیار ارزیابی باید صریح باشد.

در ساده‌ترین حالت، هدف تقسیم Ω به دو مجموعه پیش‌زمینه و پس‌زمینه است. در قطعه‌بندی چندکلاسه، هر پیکسل یک رده می‌گیرد. در قطعه‌بندی معنایی، دو شیء هم‌رده یک برچسب مشترک دارند؛ در قطعه‌بندی نمونه‌ای، هویت هر نمونه نیز جدا می‌شود؛ و در قطعه‌بندی پان‌پتیک، همه پیکسل‌ها باید هم‌زمان یک رده معنایی و در صورت شمارش‌پذیر بودن یک شناسه نمونه دریافت کنند. قطعه‌بندی تعاملی خروجی را مشروط به `mask`، `scribble`، `box`، `click` یا متن می‌سازد. در ویدئو، ثبات هویت و زمان نیز وارد مسئله می‌شود.

تعریف ۱۰.۸ (افراز). خانواده $\mathcal{P} = \{R_1, \dots, R_K\}$ یک افراز از دامنه Ω است اگر

$$R_i \cap R_j = \emptyset \quad (i \neq j), \quad \bigcup_{k=1}^K R_k = \Omega.$$

در *segmentation instance* معمولاً ماسک‌های پیش‌بینی شده می‌توانند پیش از حل تعارض هم‌پوشانی داشته باشند؛ در *segmentation panoptic* خروجی نهایی باید افراز بدون هم‌پوشانی باشد.

۱۰.۱۰.۸ قطعه‌بندی به عنوان تصمیم ساخت‌یافته

برای زیان $L(\hat{z}, z)$ ، تصمیم ییزی به صورت

$$\hat{z}_{\text{Bayes}} = \arg \min_{\hat{z}} \mathbb{E}[L(\hat{z}, z) | \mathbf{y}]$$

تعریف می‌شود. اگر زیان جمع پیکسلی و posterior مستقل باشد، تصمیم به HW طبقه‌بندی مستقل تجزیه می‌شود. اما مرز، اتصال، اندازه، شکل و هویت نمونه‌ها مستقل نیستند؛ از این رو تقریب مستقل اغلب ماسک‌های دنداندار، سوراخ‌دار یا ناسازگار تولید می‌کند.

اصل راهنما

هر قطعه‌بندی سه لایه دارد: «چه چیزی را بخش‌بندی می‌کنیم؟»، «چه شواهدی از تصویر می‌گیریم؟» و «چه ساختاری را مجاز می‌دانیم؟». خطای رایج این است که معماری را پیش از تعریف این سه لایه انتخاب کنیم.

۲۰.۸ قاعده ییز و پیدایش آستانه

فرض کنید شدت Y از یکی از دو کلاس $Z \in \{0, 1\}$ آمده است. برای هزینه‌های C_{ij} یعنی هزینه تصمیم i در حالی که کلاس واقعی j است، کلاس یک انتخاب می‌شود اگر

$$(C_{10} - C_{..})P(Z = 0 | y) < (C_{01} - C_{11})P(Z = 1 | y).$$

با استفاده از ییز:

$$\frac{p(y | Z = 1)}{p(y | Z = 0)} > \eta, \quad \eta = \frac{(C_{10} - C_{..})P(Z = 0)}{(C_{01} - C_{11})P(Z = 1)}.$$

این رابطه یک آزمون نسبت درست‌نمایی است. بنابراین آستانه صرفاً یک ترفند هیستوگرام نیست؛ حالت خاص تصمیم ییزی است.

۱۰۲۰۸ دو کلاس گاوسی با واریانس برابر

اگر

$$Y | Z = k \sim \mathcal{N}(\mu_k, \sigma^2),$$

آنگاه لگاریتم نسبت درست‌نمایی خطی است و آستانه به صورت

$$t^* = \frac{\mu_0 + \mu_1}{2} + \frac{\sigma^2}{\mu_1 - \mu_0} \log \eta$$

به دست می‌آید. برای prior و هزینه برابر، $t^* = (\mu_0 + \mu_1)/2$. اگر واریانس‌ها متفاوت باشند، معادله تصمیم درجه دوم است و حتی ممکن است ناحیه تصمیم یک بازه محدود باشد، نه یک نیم‌خط.

خطای رایج

وجود دو قله در هیستوگرام شرط لازم یا کافی برای قطعه‌بندی خوب نیست. دو ناحیه می‌توانند شدت مشابه و بافت متفاوت داشته باشند، یا یک شیء به علت سایه و روشنایی چند قله تولید کند. هیستوگرام مکان پیکسل را حذف می‌کند.

۳۰۸ آستانه‌گذاری سراسری

۱۰۳۰۸ فرمول‌بندی عمومی

برای تصویر خاکستری نرمال‌شده $y_p \in [0, 1]$ ، قطعه‌بندی دودویی با آستانه t برابر است با

$$m_p(t) = \mathbb{1}[y_p > t].$$

هزینه انتخاب t می‌تواند بر جدایی آماری، entropy خطای مدل مخلوط یا معیار پایین‌دست بنا شود. اگر آستانه پس از دیدن truth ground انتخاب شود، نتیجه خوش‌بینانه و غیرقابل تعمیم است؛ بنابراین پارامتر باید روی validation یا با معیار بدون نظارت انتخاب شود.

۲۰۳۰۸ روش Otsu: استخراج دقیق

فرض کنید هیستوگرام نرمال‌شده $p_i = n_i/N$ برای سطوح $i = 0, \dots, L-1$ باشد. برای آستانه t :

$$\omega_0(t) = \sum_{i=0}^t p_i, \quad \omega_1(t) = 1 - \omega_0(t),$$

$$\mu_0(t) = \frac{1}{\omega_0(t)} \sum_{i=0}^t i p_i, \quad \mu_1(t) = \frac{1}{\omega_1(t)} \sum_{i=t+1}^{L-1} i p_i.$$

واریانس درون کلاسی و بین کلاسی عبارت‌اند از

$$\sigma_w^2(t) = \omega \cdot \sigma^2 + \omega_1 \sigma_1^2, \quad \sigma_b^2(t) = \omega \cdot \omega_1 (\mu_+ - \mu_1)^2.$$

از تجزیه واریانس کل داریم

$$\sigma_T^2 = \sigma_w^2(t) + \sigma_b^2(t),$$

که مستقل از t است؛ پس کمینه‌کردن واریانس درون کلاسی معادل بیشینه‌کردن واریانس بین کلاسی است:

$$t_{\text{Otsu}} = \arg \max_t \sigma_b^2(t).$$


با تعریف میانگین تجمعی $\mu(t) = \sum_{i=0}^t ip_i$ و میانگین کل μ_T ، فرم پایدارتر محاسباتی

$$\sigma_b^2(t) = \frac{(\mu_T \omega_+(t) - \mu(t))^2}{\omega_+(t)(1 - \omega_+(t))}$$

به دست می‌آید. آستانه‌هایی که یکی از کلاس‌ها وزن صفر دارد حذف می‌شوند.

پیچیدگی Otsu

ساخت هیستوگرام $O(N)$ و پیمایش آستانه‌ها $O(L)$ است. با مجموع‌های تجمعی، برای هر t محاسبه ثابت انجام می‌شود؛ بنابراین کل پیچیدگی $O(N + L)$ و حافظه $O(L)$ است.



شکل ۲.۰۸: آستانه Otsu و چندآستانه‌ای روی یک تصویر مصنوعی. انتخاب صرفاً از هیستوگرام انجام می‌شود و مکان پیکسل‌ها در معیار حضور ندارد.

الگوریتم ۱: Otsu پایدار با مجموع تجمی

۱. هیستوگرام h_i را بسازید و $p_i = h_i/N$ را محاسبه کنید.
 ۲. آرایه‌های تجمی $\omega(t) = \sum_{i \leq t} p_i$ و $\mu(t) = \sum_{i \leq t} i p_i$ را بسازید.
 ۳. برای هر t با $0 < \omega(t) < 1$ ، مقدار $\sigma_b^2(t)$ را محاسبه کنید.
 ۴. اگر چند آستانه پیشنهادی برابر دارند، قرارداد tie-breaking را ثبت کنید؛ انتخاب میانگین بازه پیشنهادی معمولاً پایدارتر است.
 ۵. آستانه را به مقیاس شدت اصلی بازگردانید و ماسک را با قرارداد $>$ یا $\geq$ بسازید.
- آزمون صحت: روی تصویر ثابت، هیستوگرام تک جرمی و تصویر دو سطحی رفتار مورد انتظار را بررسی کنید.

۳.۳.۰۸ تفسیر Otsu به عنوان خوشه‌بندی یک بعدی

Otsu برای دو کلاس معادل انتخاب برشی است که مجموع خطای مربعی درون دو خوشه شدت را کمینه می‌کند. در نتیجه، با k -means یک بعدی ارتباط مستقیم دارد، اما قید می‌کند خوشه‌ها در محور شدت پیوسته و با یک آستانه جدا شوند. این قید سرعت و تفسیرپذیری می‌دهد، ولی برای چگالی‌های درهم‌رفته یا چندوجهی محدودکننده است.

۴.۳.۰۸ چندآستانه‌ای و برنامه‌ریزی پویا

برای K کلاس و آستانه‌های $t_1 < \dots < t_{K-1}$ ، هدف کمینه‌سازی

$$J(t_1, \dots, t_{K-1}) = \sum_{k=1}^K \sum_{i \in I_k} p_i (i - \mu_k)^2$$

است. جست‌وجوی مستقیم $O(L^{K-1})$ است. اگر هزینه یک بازه $[a, b]$ را

$$C(a, b) = \sum_{i=a}^b p_i (i - \mu_{a:b})^2$$

بنامیم، برنامه‌ریزی پویا می‌نویسد

$$D(k, b) = \min_{a < b} \{D(k-1, a) + C(a+1, b)\}.$$

با پیش‌محاسبه جمع‌های p_i ، $i p_i$ و $i^2 p_i$ ، هزینه هر بازه در زمان ثابت محاسبه می‌شود و پیچیدگی معمول $O(KL^2)$ است. backtracking آستانه‌ها را بازیابی می‌کند.

الگوریتم ۲: Multi-Otsu با برنامه‌ریزی پویا

۱. سه مجموع تجمعی S_0, S_1, S_2 را برای $p_i, ip_i, i^2 p_i$ بسازید.
۲. با آنها $C(a, b) = S_2 - S_1^2 / S_0$ را برای بازه‌های معتبر محاسبه کنید.
۳. جدول $D(k, b)$ و جدول والد $P(k, b)$ را پر کنید.
۴. از $D(K, L - 1)$ به عقب حرکت کنید تا $K - 1$ آستانه به دست آید.
۵. کلاس‌های بسیار کوچک را با حداقل جرم یا جریمه تعداد کلاس کنترل کنید.

۵.۳.۰۸ آستانه entropy و error minimum

در روش entropy، maximum برای هر سوی آستانه entropy شرطی محاسبه می‌شود:

$$H_0(t) = - \sum_{i \leq t} \frac{p_i}{\omega_0} \log \frac{p_i}{\omega_0}, \quad H_1(t) = - \sum_{i > t} \frac{p_i}{\omega_1} \log \frac{p_i}{\omega_1},$$

و $H_0 + H_1$ پیشنهاد می‌شود. روش Kittler-Illingworth هیستوگرام را مخلوط دو گاوسی فرض و خطای طبقه‌بندی برآورد شده را کمینه می‌کند. این روش هنگامی مناسب‌تر است که مدل شدت واقعاً نزدیک مخلوط پارامتری باشد، ولی در برابر برآورد ناپایدار واریانس کلاس کوچک حساس است.

۶.۳.۰۸ روش‌های ساده اما مفید

- **Percentile:** وقتی نسبت تقریبی پیش‌زمینه معلوم است؛ برای کنترل کیفیت خط تولید مفید است.
- **Triangle:** برای هیستوگرام یک‌قله‌ای با دنباله بلند؛ فاصله نقاط هیستوگرام از خط قله تا انتهای دنباله را پیشنهاد می‌کند.
- **Hysteresis:** دو آستانه $t_l < t_h$ ؛ پیکسل قوی seed است و پیکسل ضعیف فقط در صورت اتصال پذیرفته می‌شود.
- **Threshold:** روی نسبت یا شاخص: در تصاویر چندطیفی، متغیری مانند $(a - b) / (a + b)$ گاه جدایی فیزیکی بهتری از شدت خام می‌دهد.

۴.۰۸ آستانه‌گذاری محلی و روشی ناهمگن

مدل ساده سند یا صحنه سایه‌دار را می‌توان چنین نوشت:

$$y(p) = \ell(p)r(p) + n(p),$$

که ℓ روشنایی آهسته‌تغییر و r بازتاب است. آستانه جهانی تغییرات ℓ را با تغییر کلاس اشتباه می‌گیرد. راه‌حل‌ها یا ℓ را برآورد و حذف می‌کنند، یا آستانه را تابع مکان می‌سازند: $t = t(p)$.

۱۰۴۰۸ میانگین محلی و تصویر انتگرالی

برای پنجره W_p :

$$\mu_p = \frac{1}{|W_p|} \sum_{q \in W_p} y_q, \quad m_p = 1[y_p > \mu_p - c].$$

تصویر انتگرالی

$$I(r, c) = \sum_{i \leq r} \sum_{j \leq c} y(i, j)$$

جمع هر مستطیل را با چهار دسترسی محاسبه می‌کنند؛ بنابراین میانگین محلی برای همه پیکسل‌ها در $O(N)$ مستقل از اندازه پنجره قابل محاسبه است.

۲۰۴۰۸ Sauvola و Niblack


از Niblack

$$t_p = \mu_p + k\sigma_p$$

استفاده می‌کند. در سند، علامت و مقدار k به قرارداد foreground بستگی دارد. Sauvola برای جلوگیری از تولید نویز در نواحی کم‌واریانس پیشنهاد می‌کند

$$t_p = \mu_p \left[1 + k \left(\frac{\sigma_p}{R} - 1 \right) \right],$$

که R دامنه مرجع انحراف معیار است. وقتی $\sigma_p \ll R$ ، آستانه از میانگین فاصله می‌گیرد و حساسیت به پس‌زمینه هموار کاهش می‌یابد.



شکل ۳۰۸: نمونه شکست آستانه جهانی زیر روشنایی ناهمگن و نقش آستانه محلی. کیفیت به اندازه پنجره و نسبت مقیاس روشنایی به شیء وابسته است؛ یک روش محلی الزاماً در هر تصویر بهتر نیست.

الگوریتم ۳: آستانه محلی با تصویر انتگرالی

۱. تصویر و مربع آن را به float تبدیل کنید و دو تصویر انتگرالی I و I_2 بسازید.
 ۲. برای هر پیکسل، مرز پنجره را با قرارداد مشخص clip یا reflect کنید.
 ۳. جمع و جمع مربع را با چهار گوشه بازیابی و μ_p, σ_p را محاسبه کنید.
 ۴. آستانه، Sauvola Niblack یا فرمول سفارشی را اعمال کنید.
 ۵. اجزای کوچک و حفره‌ها را تنها در صورت وجود دلیل هندسی اصلاح کنید؛ post-processing بخشی از مدل است و باید گزارش شود.
- پیمیدگی: زمان $O(N)$ ، حافظه $O(N)$. برای تصاویر عظیم می‌توان پردازش tiled با halo انجام داد.

خطای رایج

پنجره بسیار کوچک نویز را دنبال می‌کند؛ پنجره بسیار بزرگ دوباره به آستانه جهانی نزدیک می‌شود. اندازه پنجره باید از مقیاس stroke یا شیء و مقیاس تغییر روشنایی استخراج شود، نه با آزمون روی set. test

۳۰۴۰۸ آستانه دوبعدی و ویژگی‌های چندکاناله

هیستوگرام مشترک شدت و میانگین محلی، شدت و گرادیان، یا دو کانال رنگ می‌تواند ابهام یک‌بعدی را کاهش دهد. اما تعداد bin‌ها با بعد به صورت نمایی رشد می‌کند. در ابعاد بالاتر، تخمین چگالی، GMM یا classifier معمولاً مناسب‌تر از هیستوگرام چندبعدی خام است.

کارگاه کد و آزمایش: آستانه‌گذاری قابل تمیزی

برای یک مجموعه شامل سند، سلول، قطعه صنعتی و تصویر سایه‌دار، Otsu، Sauvola Triangle و یک آستانه بیزی را مقایسه کنید. علاوه بر Dice، حساسیت به blur، gamma، نویز و resize را گزارش کنید. نمودار آستانه منتخب در هر perturbation بهتر از یک جدول تک‌عددی رفتار روش را آشکار می‌کند.

۵۰۸ رشد ناحیه و اتصال


آستانه‌گذاری می‌پرسد «مقدار این پیکسل چیست؟»؛ رشد ناحیه می‌پرسد «آیا این پیکسل به یک ناحیه موجود و سازگار متصل است؟». از های seed S_k شروع می‌کنیم و پیکسل مرزی q را به ناحیه R_k می‌افزاییم اگر

$$q \in \mathcal{N}(R_k), \quad P(q, R_k) = \text{true}.$$

یک predicate ساده

$$P(q, R_k) = \mathbb{1} [|y_q - \mu(R_k)| \leq \tau]$$

است. چون $\mu(R_k)$ با رشد تغییر می‌کند، ترتیب پردازش ممکن است نتیجه را تغییر دهد. استفاده از صف اولویت بر اساس هزینه الحاق این وابستگی را کنترل می‌کند.



شکل ۴۰۸: حساسیت رشد ناحیه به آستانه سازگاری. مقدار کوچک کم‌قطعه‌بندی و مقدار بزرگ leakage ایجاد می‌کند؛ seed و مدل ناحیه بخشی از مسئله‌اند.

الگوریتم ۴: رشد ناحیه صف‌محور

۱. ها seed را اعتبارسنجی و برچسب اولیه را ایجاد کنید.
 ۲. همسایه‌های seed را در صف یا queue priority وارد کنید.
 ۳. کم‌هزینه‌ترین پیکسل q را خارج و هزینه آن نسبت به ناحیه‌های مجاور را محاسبه کنید.
 ۴. اگر بهترین هزینه کمتر از τ است، برچسب را تثبیت و آمار ناحیه را آنلاین به‌روزرسانی کنید.
 ۵. همسایه‌های برچسب‌نخورده را وارد صف کنید؛ در تعارض، قاعده tie-breaking را ثبت کنید.
 ۶. در پایان، شرط اندازه، compactness یا اتصال را بررسی کنید.
- پیچیدگی: با صف ساده $O(N)$ و با heap معمولاً $O(N \log N)$. هر پیکسل باید تعداد محدودی وارد صف شود.

۱۰.۵.۸ انتخاب seed

seed می‌تواند دستی، از آستانه قوی، extrema تبدیل فاصله، marker مورفولوژیک، detection نقطه کاربر یا خروجی شبکه باشد. کیفیت seed در روش‌های تعاملی باید با «تعداد تعامل تا رسیدن به کیفیت هدف» سنجیده شود، نه فقط کیفیت پس از تعداد نامحدود click.

۲۰۵.۸ merge and Split

دامنه ابتدا به بلوک‌هایی تقسیم می‌شود. اگر predicate همگنی برقرار نباشد، بلوک به چهار فرزند شکسته می‌شود؛ سپس بلوک‌های مجاور سازگار ادغام می‌شوند. ساختار quadtree محاسبه را منظم می‌کند، ولی مرزهای بلوکی مصنوعی و وابستگی به alignment ایجاد می‌کند. ادغام پس از split برای حذف این اثر ضروری است.

۳۰۵.۸ رابطه با watershed

watershed نشان‌محور را می‌توان رشد همزمان چند ناحیه روی توپوگرافی گرادیان دیده. تفاوت اصلی آن است که اولویت رشد از ارتفاع یا هزینه مسیر می‌آید و خط جدایی در برخورد جبهه‌ها ساخته می‌شود. ابزارهای فصل هفتم برای marker، بازسازی مورفولوژیک و کنترل minima مستقیماً در اینجا استفاده می‌شوند.

۶.۸ خوشه‌بندی و مدل‌های مخلوط

۱۰۶.۸ k-means در فضای ویژگی

برای ویژگی $x_p \in \mathbb{R}^d$ شامل رنگ، شدت، بافت و مختصات، k-means حل می‌کند

$$\min_{\{z_p\}, \{\mu_k\}} \sum_{p \in \Omega} \|x_p - \mu_{z_p}\|_2^2.$$

الگوریتم Lloyd دو گام دارد:

$$z_p \leftarrow \arg \min_k \|x_p - \mu_k\|_2^2, \quad \mu_k \leftarrow \frac{1}{|R_k|} \sum_{p: z_p=k} x_p.$$

هر گام تابع هدف را کاهش می‌دهد، اما تضمین تنها همگرایی به مینیمم محلی است. k-means++ چند restart و ثبت بهترین تابع هدف ضروری‌اند.

مقیاس ویژگی

اگر $x_p = [L, a, b, \alpha x, \alpha y]$ باشد، پارامتر α نسبت شباهت ظاهری به فشردگی مکانی را تعیین می‌کند. بدون استانداردسازی، کانالی با دامنه بزرگ هندسه فاصله را تسخیر می‌کند. انتخاب فضای Lab یا ویژگی آموخته‌شده نیز بخشی از فرض مدل است.

۲۰۶۰۸ GMM و الگوریتم EM

در مدل مخلوط گاوسی

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k), \quad \sum_k \pi_k = 1.$$

متغیر پنهان z_p عضویت کلاس است. در گام E مسئولیت‌ها


$$\gamma_{pk} = P(z_p = k | \mathbf{x}_p) = \frac{\pi_k \mathcal{N}(\mathbf{x}_p; \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_p; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$

و در گام M

$$N_k = \sum_p \gamma_{pk}, \quad \pi_k = \frac{N_k}{N}, \quad \boldsymbol{\mu}_k = \frac{1}{N_k} \sum_p \gamma_{pk} \mathbf{x}_p,$$

$$\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_p \gamma_{pk} (\mathbf{x}_p - \boldsymbol{\mu}_k)(\mathbf{x}_p - \boldsymbol{\mu}_k)^T$$

به‌روزرسانی می‌شوند. EM درست‌نمایی را کاهش نمی‌دهد، اما به مقداردهی اولیه و فروپاشی کوواریانس حساس است؛ افزودن ϵI و حداقل جرم مؤلفه لازم است.



شکل ۵.۸: خوشه‌بندی GMM در فضایی که شدت و مختصات را ترکیب می‌کند. افزودن مکان اتصال را تضمین نمی‌کند، اما از پخش شدن یک کلاس ظاهری در سراسر تصویر می‌کاهد.

الگوریتم ۵: EM پایدار برای قطعه‌بندی GMM

۱. ویژگی‌ها را با آمار train یا همان تصویر، طبق پروتکل ثابت، نرمال کنید.
۲. پارامترها را با k -means++ یا چند مقداردهی اولیه بسازید.
۳. در E-step، احتمال‌ها را در فضای log و با log-sum-exp محاسبه کنید.
۴. در M-step، وزن، میانگین و کوواریانس را به‌روزرسانی و regularization قطری اضافه کنید.

۵. معیار توقف را بر تغییر log-likelihood نسبی و حداکثر iteration تعریف کنید.
۶. برچسب نهایی را با $\arg \max \gamma_{pk}$ و عدم قطعیت را با entropy مسئولیت‌ها گزارش کنید.
- پچیدگی: برای کوواریانس کامل تقریباً $O(TNKd^2)$ ؛ کوواریانس قطری هزینه را به $O(TNKd)$ کاهش می‌دهد.

۳۰۶۰۸ c-means Fuzzy

برای عضویت نرم $u_{pk} \in [0, 1]$ و $\sum_k u_{pk} = 1$:

$$J_m = \sum_p \sum_k u_{pk}^m \|x_p - \mu_k\|^2, \quad m > 1.$$

پارامتر m میزان fuzziness را کنترل می‌کند. عضویت نرم برای volume partial MRI یا مرزهای مخلوط مفید است، اما membership لزوماً احتمال کالیبره نیست.

۴۰۶۰۸ shfit Mean

shfit Mean مد چگالی KDE را دنبال می‌کند. برای kernel K_h ، بردار mean-shfit اختلاف میانگین وزن‌دار همسایگی و نقطه جاری است. مزیت آن نیازنداشتن به تعداد خوشه از پیش است؛ عیب آن حساسیت شدید به bandwidth و هزینه بالا در ابعاد و داده بزرگ است.

۵۰۶۰۸ افزودن ساختار مکانی

یک راه ساده افزودن مختصات به ویژگی است؛ راه اصولی‌تر افزودن prior روی برچسب‌هاست:

$$p(z) \propto \exp \left(-\beta \sum_{(p,q) \in \mathcal{E}} \mathbf{1}[z_p \neq z_q] \right).$$

این مدل Potts مرز را جریمه می‌کند. posterior دیگر به پیکسل‌ها تجزیه نمی‌شود و به روش‌های گرافی، mean-field propagation، belief یا روش واریاسیونی نیاز دارد.

۷۰۸ قطعه‌بندی واریاسیونی: از Mumford-Shah تا Chan-Vese

۱۰۷۰۸ تابع Mumford-Shah

برای تصویر $y: \Omega \rightarrow \mathbb{R}$ ، تابع u piecewise-smooth و مجموعه ناپوستگی C :

$$E(u, C) = \int_{\Omega \setminus C} (u - y)^2 d\mathbf{x} + \alpha \int_{\Omega \setminus C} \|\nabla u\|^2 d\mathbf{x} + \beta \mathcal{H}^1(C).$$

ترم نخست، fidelity، ترم دوم همواری درون ناحیه و ترم سوم طول مرز است. بهینه‌سازی مستقیم روی تابع و مجموعه منحنی دشوار است. تقریب Ambrosio-Tortorelli یا مدل‌های constant piecewise این مانع را کاهش می‌دهند.

۲۰۷۰۸ مدل قطعه‌ای ثابت و انرژی Chan-Vese

برای ناحیه داخل منحنی C و خارج آن، شدت با ثابت‌های c_1, c_2 تقریب زده می‌شود:

$$E(C, c_1, c_2) = \mu \text{Length}(C) + \nu \text{Area}(\text{inside}(C)) \quad (10.8)$$

$$+ \lambda_1 \int_{\text{inside}(C)} (y - c_1)^2 d\mathbf{x} + \lambda_2 \int_{\text{outside}(C)} (y - c_2)^2 d\mathbf{x}. \quad (20.8)$$

برای منحنی ثابت، کمینه نسبت به c_1, c_2 میانگین نواحی است. منحنی را با level-set $C = \{\mathbf{x} : \phi(\mathbf{x}) = 0\}$ نمایش می‌دهیم. با تابع Heaviside $H(\phi)$ و دلتا $\delta(\phi)$:


$$E(\phi) = \mu \int \delta(\phi) \|\nabla \phi\| d\mathbf{x} + \nu \int H(\phi) d\mathbf{x} \quad (30.8)$$

$$+ \lambda_1 \int (y - c_1)^2 H(\phi) d\mathbf{x} + \lambda_2 \int (y - c_2)^2 (1 - H(\phi)) d\mathbf{x}. \quad (40.8)$$

نزول گرادیان شکل تقریبی

$$\frac{\partial \phi}{\partial t} = \delta_\epsilon(\phi) \left[\mu \operatorname{div} \left(\frac{\nabla \phi}{\|\nabla \phi\|} \right) - \nu - \lambda_1 (y - c_1)^2 + \lambda_2 (y - c_2)^2 \right]$$

دارد. curvature مرز را هموار و اختلاف خطاهای ناحیه‌ای جبهه را هدایت می‌کند.



شکل ۶.۰۸: تکامل یک contour ناحیه‌محور. مدل Chan-Vese برای مرزهایی که گرادیان ضعیف دارند مفید است، ولی فرض ثابت بودن شدت هر ناحیه در روشی ناهمگن می‌شکند.

مسیر اثبات: چرا میانگین ناحیه به دست می‌آید؟

برای ناحیه ثابت R ، تابع $F(c) = \int_R (y - c)^2 dx$ را مشتق می‌گیریم:

$$F'(c) = 2 \int_R (c - y) dx = 0 \quad \Rightarrow \quad c = \frac{1}{|R|} \int_R y dx.$$

پس Chan-Vese در هر iteration یک مدل دو-میانگینی می‌سازد و مرز را با regularization هندسی به آن سازگار می‌کند.

۳.۷.۰۸ contour active Geodesic

مدل edge-based از تابع توقف

$$g(|\nabla G_\sigma * y|) = \frac{1}{1 + |\nabla G_\sigma * y|^2}$$

استفاده می‌کند و انرژی طول وزن‌دار $\int_C g ds$ را کمینه می‌سازد. گرادیان قوی g را کوچک و contour را متوقف می‌کند. در مرز ضعیف، gap یا بافت، leakage رخ می‌دهد؛ در مقابل Chan-Vese از آمار ناحیه استفاده می‌کند.

۴.۷.۰۸ مدل‌های محلی و چندفازی

برای روشی ناهمگن، c_1, c_2 را تابع مکان یا میانگین kernel-weighted می‌سازند. مدل‌های multiphase با چند level-set تا 2^m ناحیه تولید می‌کنند. افزایش انعطاف، هزینه بهینه‌سازی و خطر مینیمم محلی را نیز افزایش می‌دهد.

الگوریتم ۶: Chan-Vese با set level

۱. ϕ^* را از دایره، checkerboard یا seed بسازید؛ فاصله علامت‌دار شروع مناسبی است.
۲. $H_\epsilon, \delta_\epsilon$ را با تقریب نرم تعریف کنید.
۳. c_1, c_2 را از میانگین‌های وزن‌دار $H_\epsilon(\phi)$ محاسبه کنید.
۴. curvature و نیروی داده را محاسبه و ϕ را با گام پایدار به‌روزرسانی کنید.
۵. در صورت روش کلاسیک، هر چند reinitialization iteration انجام دهید؛ یا از level-set فاصله‌منظم استفاده کنید.
۶. توقف را بر تغییر انرژی، تغییر ماسک و سقف iteration مشترک تعریف کنید.

۸.۸ مدل‌های گرافی و انرژی گسسته

۱۰.۸.۰۸ MRF/CRF و انرژی Potts

یک انرژی رایج چندکلاسه:

$$E(z) = \sum_p D_p(z_p) + \lambda \sum_{(p,q) \in \mathcal{E}} w_{pq} \mathbf{1}[z_p \neq z_q].$$

ترم unary از مدل شدت، شبکه یا prompt می‌آید. وزن

$$w_{pq} = \exp(-\beta \|y_p - y_q\|^2) \frac{1}{\text{dist}(p, q)}$$

جریمه قطع را در مرز ظاهری کاهش می‌دهد. این انرژی posterior منفی-log یک MRF یا CRF زوجی است.


۲۰.۸.۰۸ برش s-t برای مسئله دودویی

برای $z_p \in \{0, 1\}$ ، گرافی با source، sink، پیکسل‌ها، های unary t-link و های pairwise n-link ساخته می‌شود. هر برش source-sink یک برچسب‌گذاری دودویی و ظرفیت برش برابر انرژی آن است. قضیه max-flow/min-cut تضمین می‌کند کهینه سراسری با max-flow به دست آید، اگر ترم زوجی زیرمدولار باشد.

قضیه ۱۰.۸ (شرط زیرمدولار زوج دودویی). برای هزینه $V(z_p, z_q)$ ، نمایش دقیق با برش گراف زمانی ممکن است که

$$V(0, 0) + V(1, 1) \leq V(0, 1) + V(1, 0).$$

این شرط یعنی ترجیح برچسب یکسان از نظر انرژی ناسازگار نیست.



شکل ۷۰۸: قطعه‌بندی تعاملی دودویی با seed و min-cut. unary ها مدل پیش‌زمینه/پس‌زمینه و pairwise ها از اختلاف همسایه‌ها ساخته می‌شوند.

الگوریتم ۷: cut graph تعاملی

۱. از scribble یا seed، مدل رنگ پیش‌زمینه و پس‌زمینه را برآورد کنید.
۲. unary را به صورت $-\log p(y_p | z_p = k)$ بسازید و ها seed را با ظرفیت بزرگ hard-constrain کنید.
۳. وزن یال همسایگی را از contrast و فاصله مکانی تعریف کنید.
۴. گراف را بسازید و max-flow/min-cut را اجرا کنید.
۵. در روش تکراری مانند GrabCut، های GMM رنگ و برچسب را تناوبی به‌روزرسانی کنید.
۶. زمان تعامل، تعداد اصلاح و کیفیت پس از هر prompt را ذخیره کنید.

۳۰۸۰۸ چندکلاسه و alpha-expansion

کمینه‌سازی دقیق Potts چندکلاسه عموماً دشوار است. alpha-expansion در هر حرکت به پیکسل‌ها اجازه می‌دهد برچسب فعلی را حفظ یا به α تغییر دهند؛ هر حرکت یک cut graph دودویی است. برای pairwise، تقریب دارای کران است.

۴۰۸۰۸ cut Normalized و مسئله مقدار ویژه

برای گراف وزن‌دار، cut ساده به جدا کردن مجموعه کوچک تمایل دارد. معیار

$$Ncut(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)}$$

قطع را با حجم هر بخش نرمال می‌کند. relaxation پیوسته به مسئله مقدار ویژه تعمیم یافته

$$(D - W)v = \lambda Dv$$


می‌رسد. بردار ویژه دوم اطلاعات دویبخشی را می‌دهد. ساخت گراف کامل گران است؛ گراف تنک، Nyström یا superpixel برای مقیاس‌پذیری استفاده می‌شود.

۵.۸.۸ walker Random و توابع هارمونیک

برای های seed برچسب‌دار، احتمال اینکه walk random از پیکسل p نخست به seed کلاس k برسد، تابع هارمونیک است. با لاپلاسی گراف $L = D - W$ و تفکیک گره‌های برچسب‌دار M و آزاد U :

$$\begin{bmatrix} L_{UU} & L_{UM} \\ L_{MU} & L_{MM} \end{bmatrix} \begin{bmatrix} x_U \\ x_M \end{bmatrix} = 0 \Rightarrow L_{UU}x_U = -L_{UM}x_M.$$

برای هر کلاس یک دستگاه sparse حل می‌شود و برچسب $\arg \max_k x_{pk}$ است. خروجی -probability-like برای تعامل و uncertainty مفید است.



شکل ۸.۸: Random walker: seed شرط مرزی و لاپلاسی وزن‌دار انتشار احتمال را تعیین می‌کنند. مرز در ناحیه مقاومت بالا قرار می‌گیرد.

مسیر اثبات: اصل کینه انرژی دیریکله

راه‌حل هارمونیک walker random کینه‌کننده

$$\mathcal{E}(x) = \frac{1}{2} \sum_{(p,q)} w_{pq} (x_p - x_q)^2 = \frac{1}{2} x^T L x$$

تحت مقادیر ثابت seed است. مشتق نسبت به x_U همان دستگاه $L_{UU}x_U = -L_{UM}x_M$ را می‌دهد.

۶.۸.۰۸ مقایسه walker random و cut graph

cut Graph مرز گسسته و مینیمم انرژی Potts می‌دهد؛ walker random پاسخ نرم هارمونیک می‌سازد. cut graph می‌تواند artifact metrication داشته باشد و به جریمه طول حساس است؛ walker random در ناحیه‌های ضعیف احتمال پخش شده و مرز نرم می‌دهد. انتخاب باید با نوع خطا و تعامل کاربر انجام شود.

۷.۸.۰۸ الگوریتم گرافی Felzenszwalb-Huttenlocher

این روش یال‌ها را بر اساس تفاوت مرتب و مؤلفه‌ها را union می‌کند اگر تفاوت بین مؤلفه‌ای از variation داخلی به علاوه آستانه وابسته به اندازه کمتر باشد. پیچیدگی تقریباً $O(E \log E)$ از مرتب‌سازی می‌آید و برای over-segmentation سریع مفید است، ولی پارامتر scale معنای مستقیم تعداد قطعه ندارد.

۹.۰۸ ابرپیکسل: کاهش هوشمند تعداد متغیرها

ابرپیکسل گروه کوچکی از پیکسل‌های مجاور و مشابه است. هدف نهایی لزوماً شیء کامل نیست؛ بلکه جایگزینی میلیون‌ها پیکسل با چندصد یا چندهزار primitive است که مرزهای مهم را حفظ کنند.


۱۰.۹.۰۸ SLIC به عنوان k-means محلی

در فضای $f_p = [L_p, a_p, b_p, x_p, y_p]$ ، فاصله SLIC معمولاً

$$d_c = \sqrt{(L_p - L_k)^2 + (a_p - a_k)^2 + (b_p - b_k)^2}, \quad d_s = \sqrt{(x_p - x_k)^2 + (y_p - y_k)^2},$$

$$D = \sqrt{d_c^2 + \left(\frac{m}{S}\right)^2 d_s^2}$$

است؛ $S \approx \sqrt{N/K}$ فاصله شبکه مراکز و compactness m است. برخلاف k-means عمومی، هر مرکز فقط در پنجره $2S \times 2S$ جست‌وجو می‌کند؛ از این رو هزینه تقریباً خطی در تعداد پیکسل‌هاست.



شکل ۹.۰۸: SLIC، مرز ابرپیکسل و تقریب قطعه‌ای ثابت. افزایش compactness شکل منظم‌تر و adhere-ence مرزی کمتر ایجاد می‌کند.

الگوریتم ۸: SLIC

۱. تصویر را به فضای رنگ ادراکی تبدیل و K مرکز روی شبکه با فاصله S قرار دهید.
۲. هر مرکز را در همسایگی کوچک به کمترین گرادیان منتقل کنید تا روی لبه قرار نگیرد.
۳. برای هر مرکز فقط پیکسل‌های پنجره $2S \times 2S$ را با فاصله D ارزیابی کنید.
۴. پیکسل را به کمترین فاصله تخصیص و مراکز را میانگین‌گیری کنید.
۵. تا تغییر کوچک مراکز یا تعداد iteration ثابت ادامه دهید.
۶. در پایان اتصال را صریح enforce و اجزای کوچک را به نزدیک‌ترین همسایه ادغام کنید.

۲۰۹۰۸ معیارهای ابرپیکسل

- **Recall: Boundary** چه سهمی از مرز truth ground در فاصله مجاز از مرز ابرپیکسل است؟
 - **Error: Undersegmentation** یک ابرپیکسل تا چه حد چند ناحیه واقعی را قطع کرده است؟
 - **Accuracy: Segmentation Achievable** بهترین ماسکی که با نسبت‌دادن یک برچسب به هر ابرپیکسل قابل دستیابی است.
 - **Compactness و regularity** شکل و پایداری هندسی، که نباید به قیمت از دست‌دادن مرز مهم بهینه شود.
- مقایسه باید در تعداد ابرپیکسل برابر یا منحنی کیفیت بر حسب تعداد انجام شود؛ یک نقطه منفرد می‌تواند گمراه‌کننده باشد.

۱۰۰۸ از طبقه‌بندی پیکسل تا شبکه‌های تمام کانولوشنی

۱۰۱۰۰۸ فرمول‌بندی شبکه

شبکه f_θ logits

$$\mathbf{a}_p = f_\theta(\mathbf{y})_p \in \mathbb{R}^K$$


و احتمال

$$p_\theta(z_p = k | \mathbf{y}) = \frac{e^{a_{pk}}}{\sum_j e^{a_{pj}}}$$

تولید می‌کند. تفاوت با patch-based classifier آن است که extraction feature مشترک و خروجی dense است. FCN لایه‌های fully connected را به convolution تبدیل کرد تا تصویر با اندازه متغیر را به نقشه برچسب نگاشت کند.

۲۰۱۰۰۸ U-Net و مسیر مکان‌یابی

U-Net یک encoder برای زمینه و decoder برای بازیابی وضوح دارد. connection skip ویژگی کم عمق و پر جزئیات را با ویژگی عمیق و معنایی ترکیب می‌کند. اگر downsampling زیاد باشد، شیء کوچک پیش از decoder حذف می‌شود؛ skip تنها اطلاعاتی را بازمی‌گرداند که واقعاً در map feature وجود داشته باشد.



شکل ۱۰۰۸: طرح مفهومی encoder-decoder با های skip چند مقیاسی. اندازه receptive field، stride و حافظه activation سه تصمیم اصلی طراحی‌اند.

۳۰۱۰۰۸ میدان دید و convolution atrous

کانولوشن dilated با نرخ r

$$y[i] = \sum_k x[i + rk]w[k]$$

بدون کاهش resolution میدان دید را افزایش می‌دهد. DeepLab از pooling pyramid spatial atrous برای زمینه چند مقیاسی و decoder برای مرز استفاده می‌کند. نرخ‌های نامناسب می‌توانند artifact gridding ایجاد کنند؛ ترکیب نرخ‌ها و feature سطوح مختلف راه کاهش آن است.

۴۰۱۰۰۸ R-CNN Mask و segmentation Instance

R-CNN Mask یک شاخه ماسک به detector دو مرحله‌ای می‌افزاید. برای هر RoI، ماسک کلاس ویژه یا class-agnostic پیش‌بینی می‌شود. RoIAlign به جای quantization از نمونه‌برداری bilinear استفاده می‌کند تا misalignment فضایی کاهش یابد. معیار اصلی segmentation instance معمولاً AP ماسک در آستانه‌های مختلف IoU است، نه فقط Dice کلی.

segmentation Panoptic ۵.۱۰.۸

در panoptic، هر پیکسل یا به یک instance از کلاس thing یا یک ناحیه stuff تعلق دارد. معیار

$$PQ = \underbrace{\frac{\sum_{(p,g) \in TP} \text{IoU}(p,g)}{|TP|}}_{SQ} \times \underbrace{\frac{|TP|}{|TP| + \frac{1}{\alpha}|FP| + \frac{1}{\beta}|FN|}}_{RQ}$$

کیفیت قطعه و کیفیت تشخیص را جدا می‌کند. ادغام head معنایی و نمونه‌ای باید تعارض هم‌پوشانی را حل کند.

Transformer ۶.۱۰.۸ و پیش‌بینی مجموعه ماسک

در MaskFormer/Mask، Former مدل مجموعه‌ای از queryها تولید می‌کند؛ هر query یک embedding کلاس و یک ماسک دارد. matching دوطرفه Hungarian بین پیش‌بینی و truth ground مسئله permutation را حل می‌کند. attention masked توجه را به ناحیه ماسک پیش‌بینی شده محدود می‌سازد و یک معماری را برای instance semantic و panoptic مشترک می‌کند.

پل به دهه آینده

در معماری‌های جدید، مرز میان detection و segmentation کمرنگ شده است: مدل به جای برچسب مستقل پیکسل، مجموعه‌ای از mask، object tokenها یا queryها یا prompt-conditioned masks تولید می‌کند. بنابراین «واحد پیش‌بینی» از پیکسل به ناحیه و مفهوم انتقال یافته است.

۱۱.۸ توابع زیان: آنچه آموزش می‌دهیم الزاماً آنچه ارزیابی می‌کنیم نیست

Cross-entropy ۱۰.۱۱.۸ و وزن‌دهی کلاس

برای one-hot: label

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_p \sum_k y_{pk} \log p_{pk}.$$

این زیان rule scoring proper است و در حالت ایده‌آل احتمال شرطی را می‌آموزد، اما تعداد زیاد background می‌تواند گرادیان را غالب کند. CE weighted

$$\mathcal{L}_{WCE} = -\frac{1}{N} \sum_p w_{z_p} \log p_{p,z_p}$$

trade-off خطا را تغییر می‌دهد و احتمال خروجی دیگر بدون اصلاح الزاماً کالیبره نیست.

۲.۱۱.۰۸ loss Focal

برای مسئله دودویی با p_t احتمال کلاس درست:

$$\mathcal{L}_{focal} = -\alpha_t(1 - p_t)^\gamma \log p_t.$$

نمونه آسان با $p_t \approx 1$ وزن اندک می‌گیرد. γ بزرگ تمرکز بر سخت‌ها را زیاد می‌کند، اما noise label و مرز مبهم نیز «سخت» هستند و ممکن است بیش‌وزن شوند.

۳.۱۱.۰۸ Dice و رابطه آن با IoU

برای مجموعه‌های دودویی A, B :

$$\text{Dice}(A, B) = \frac{2|A \cap B|}{|A| + |B|}, \quad \text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

رابطه دقیق

$$\text{Dice} = \frac{2 \text{IoU}}{1 + \text{IoU}}, \quad \text{IoU} = \frac{\text{Dice}}{2 - \text{Dice}}$$

است؛ بنابراین برای ranking یک مجموعه ثابت یکنوا هستند، ولی per-case averaging باعث برابری کامل گزارش نمی‌شود. نسخه نرم

$$\mathcal{L}_{Dice} = 1 - \frac{2 \sum_p p_p y_p + \epsilon}{\sum_p p_p + \sum_p y_p + \epsilon}$$

نسبت به اندازه foreground سازگارتر است، اما calibration probability را مستقیماً آموزش نمی‌دهد.

۴.۱۱.۰۸ Tversky و کنترل FP/FN

$$T_{\alpha, \beta} = \frac{TP}{TP + \alpha FP + \beta FN}, \quad \mathcal{L}_T = 1 - T_{\alpha, \beta}.$$

برای کاربردی که negative false پرهزینه‌تر است، $\beta > \alpha$ انتخاب می‌شود. این انتخاب باید از هزینه بالینی یا مهندسی بیاید، نه صرفاً بهترین Dice validation.

۵.۱۱.۰۸ Lovasz-Softmax

IoU یک تابع مجموعه‌ای غیرتفاضل‌پذیر است. Lovasz extension برای زیان زیرمدولار Jaccard یک surrogate قطعه‌ای خطی می‌سازد که خطاها را مرتب و گرادین را بر اساس تغییر IoU marginal وزن می‌دهد. مزیت هم‌راستایی با mIoU است؛ عیب پیاده‌سازی حساس به کلاس خالی و تفاوت per-image در برابر per-batch است.

۶.۱۱.۰۸ زیان مرز، فاصله و توپولوژی

برای ساختار نازک یا دقت هندسی، CE/Dice کافی نیستند. گزینه‌ها:

- loss boundary بر اساس transform distance زمین حقیقت؛

- surrogate Hausdorff برای بدترین فاصله؛

- signed-distance یا regression؛


- clDice برای هم‌پوشانی centerline ساختارهای لوله‌ای؛

- زیان persistence یا Betti برای اتصال و حفره.

زیان مرکب

$$\mathcal{L} = \lambda_1 \mathcal{L}_{CE} + \lambda_2 \mathcal{L}_{Dice} + \lambda_3 \mathcal{L}_{boundary}$$

تنها زمانی معنادار است که scale و gradient هر ترم پایش شود؛ ضریب عددی برابر به معنای اثر برابر نیست.



شکل ۱۱.۰۸: هندسه چند زیان برای یک پیکسل مثبت. زیان‌های overlap به کل ماسک وابسته‌اند و این نمودار تنها شهود موضعی می‌دهد؛ رفتار واقعی به نسبت کلاس و batch بستگی دارد.

خطای رایج

وقتی ground-truth و prediction هر دو خالی‌اند، Dice می‌تواند ۱، ۰ یا undefined تعریف شود. این قرارداد در مسائل ضایعه نادر نتایج را به شدت تغییر می‌دهد. گزارش باید Dice روی موارد مثبت، نرخ positive false در موارد منفی و میانگین کل را جدا کند.

۱۲.۰۸ داده، برچسب و طراحی آموزش

۱۰۱۲۰۸ پروتکل برچسب گذاری

پیش از آموزش باید سند annotation تعریف کند: چه چیزی foreground است؟ مرز نامطمئن چگونه ثبت می‌شود؟ سوراخ، occlusion اشیای ناقص در لبه تصویر و پیکسل ignore چه قراردادی دارند؟ توافق بین annotator با Dice یا kappa Cohen's و تحلیل اختلاف مرزی سنجیده می‌شود. اختلاف انسانی سقف عملی معیار و منبع uncertainty است.

۲۰۱۲۰۸ تقسیم داده بدون leakage

در پزشکی، اسلاید، بیمار یا دستگاه باید واحد split باشد؛ در ویدئو، های frame یک sequence نباید میان train و test پخش شوند؛ در سنجش ازدور، های tile هم‌پوشان یا مجاور leakage مکانی ایجاد می‌کنند. افزایش مصنوعی تعداد patch جای افزایش تنوع مستقل را نمی‌گیرد.

۳۰۱۲۰۸ Patch sampling و عدم توازن

اگر patch تصادفی باشند، شیء نادر کم دیده می‌شود. sampling می‌تواند بر حضور، foreground، مرز، example hard یا دشواری وزن بگیرد. اما نسبت sampling با prior واقعی deployment متفاوت است و calibration را تغییر می‌دهد. برای استنباط probability باید این تغییر distribution در نظر گرفته شود.

۴۰۱۲۰۸ augmentation Data هندسی و فوتومتریک

تبدیل T باید همزمان روی تصویر و ماسک اعمال شود. interpolation تصویر می‌تواند bilinear باشد، اما categorical label به nearest-neighbor نیاز دارد؛ در غیر این صورت های label کسری جعلی ساخته می‌شود. های transform غیرصلب باید با فیزیک دامنه سازگار باشند. augmentation باید روی train باشد و augmentation test-time جدا گزارش شود.

۵۰۱۲۰۸ برش تصویر و stitching

برای تصویر بزرگ، شبکه روی tile اجرا می‌شود. artifact مرز tile با weighting window overlap و padding context کاهش می‌یابد. اگر logits پیش از softmax میانگین شوند، با میانگین probability یکسان نیست. قرارداد stitching باید ثابت و برای همه روش‌ها یکسان باشد.

۶۰۱۲۰۸ نظارت ضعیف، نیمه نظارتی و خودنظارتی

برچسب ضعیف می‌تواند، image-level، scribble point یا box باشد. pseudo-labeling و consistency regularization از داده بدون برچسب استفاده می‌کنند:

$$\mathcal{L} = \mathcal{L}_{sup} + au(t) \|f_{\theta}(T_1(y)) - T_1 T_{\tau}^{-1} f_{\theta}(T_{\tau}(y))\|^2.$$

teacher میانگین ثمائی و threshold اطمینان خطای bias confirmation را کاهش می‌دهند، اما حذف نمی‌کنند. کیفیت باید بر حسب مقدار annotation واقعی و هزینه انسانی گزارش شود.

۷.۰۱۲.۰۸ learning Active

معیار انتخاب می‌تواند، entropy، disagreement margin، diversity ensemble یا ترکیب uncertainty و نمایندگی باشد. در قطعه‌بندی، انتخاب «تصویر» تنها واحد ممکن نیست؛ patch ناحیه، contour یا prompt نیز می‌تواند query باشد. معیار علمی مناسب، عملکرد بر حسب دقیقه annotation یا تعداد click است.

۱۳.۰۸ عدم قطعیت و کالیبراسیون

۱۰.۱۳.۰۸ عدم قطعیت epistemic و aleatoric


Aleatoric از ابهام تصویر و برچسب می‌آید؛ epistemic از کمبود داده و عدم قطعیت مدل، ensemble، dropout MC و posterior تقریبی عمدتاً epistemic را برآورد می‌کنند. softmax entropy هر دو را مخلوط می‌کند و به تنهایی تفکیک کننده نیست.

۲۰.۱۳.۰۸ کالیبراسیون پیکسلی

مدل کالیبره برای confidence c باید تقریباً در c درصد موارد درست باشد. Calibration Expected Error

$$ECE = \sum_{b=1}^B \frac{|S_b|}{N} |\text{acc}(S_b) - \text{conf}(S_b)|$$

به binning حساس است و dominance پس زمینه می‌تواند آن را مصنوعی خوب کند. ECE باید per-boundary-aware و foreground-only class، نیز گزارش شود.



شکل ۱۲۰۸: نمودار reliability برای خروجی پیکسلی. مدل over-confident می‌تواند Dice بالا ولی probability غیرقابل اعتماد داشته باشد.

۳.۱۳.۰۸ scaling Temperature و محدودیت آن

برای logits a ,

$$p_k(T) = \text{softmax}(a_k/T).$$

پارامتر T روی validation با NLL انتخاب می‌شود. ranking scaling و argmax را عوض نمی‌کند، اما calibration را بهبود می‌دهد. یک دمای سراسری ممکن است برای کلاس، اندازه شیء و مرزهای متفاوت کافی نباشد.

۴.۱۳.۰۸ prediction Conformal برای مجموعه برچسب

با score کالیبراسیون می‌توان برای هر پیکسل مجموعه‌ای از کلاس‌ها ساخت که تحت فرض exchangeability پوشش حاشیه‌ای تضمین شده دارد. اما وابستگی شدید پیکسل‌ها و نیاز به تضمین در سطح شیء یا تصویر، طراحی segmentation conformal را پیچیده می‌کند؛ تضمین پیکسلی الزاماً تضمین کل ماسک نیست.

۱۴.۰۸ مدل‌های بنیادین قطعه‌بندی

۱۰.۱۴.۰۸ SAM: قطعه‌بندی promptable

SAM مسئله را از «مدل مخصوص کلاس» به «مدل تولید ماسک مشروط به «prompt تغییر داد. اجزای مفهومی آن:

۰۱. encoder image سنگین که embedding تصویر را یک بار محاسبه می‌کند؛
 ۰۲. encoder prompt برای، box point، و mask؛
 ۰۳. decoder mask سبک که چند ماسک و برآورد کیفیت تولید می‌کند.
- خروجی چند ماسکی ابهام prompt را بازتاب می‌دهد: یک click ممکن است به جزء، شیء یا گروه اشاره کند.

۲۰۱۴.۸ SAM ۲: حافظه جریان برای تصویر و ویدئو

SAM ۲ معماری promptable را به ویدئو گسترش می‌دهد. encoder memory و attention memory اطلاعات فریم‌های گذشته و های prompt اصلاحی را نگه می‌دارند. ارزیابی ویدئو باید علاوه بر دقت ماسک، drfit، بازیابی پس از، occlusion حفظ هویت، latency و تعداد تعامل را بسنجد.

۳۰۱۴.۸ SAM ۳: prompt مفهومی


SAM ۳ در ۲۰۲۵ مفهوم segmentation concept promptable را مطرح کرد: متن کوتاه یا exemplar یک مفهوم را تعیین و مدل همه نمونه‌های مطابق را در تصویر و ویدئو، segment detect و track می‌کند. این گذار مهم است:

• SAM/SAM ۲ عمدتاً می‌پرسند «این ناحیه اشاره شده چیست؟»؛

• SAM ۳ می‌پرسد «همه نمونه‌های این مفهوم کجا هستند؟».

جدا سازی recognition از head presence localization و tracker حافظه دار امکان open-vocabulary generation mask را فراهم می‌کند. با این حال، مفهوم‌های تخصصی، روابط پیچیده و shfit domain هنوز به adaptation و ارزیابی مستقل نیاز دارند.

Evolution of promptable segmentation



شکل ۱۳.۸: تکامل segmentation promptable از prompt هندسی در تصویر، به حافظه ویدئویی، و سپس prompt مفهومی متنی یا exemplar. شکل، بازطراحی آموزشی است.

۴.۱۴.۸ Adaptation کم‌هزینه

راهبردها شامل LoRA، adapter، tuning، decoder probe، linear distillation و tuning prompt هستند. انتخاب لایه‌های قابل آموزش باید با اندازه داده، فاصله دامنه و حافظه انجام شود. فریز کامل encoder در دامنه‌ای مانند MRI ممکن است ویژگی نامناسب را تثبیت کند؛ fine-tune کامل با داده کم overfit می‌کند.

۵.۱۴.۸ محدودیت‌ها و ممیزی

- مرزهای نازک، اشیای بسیار کوچک و بافت‌های تکراری؛
- ambiguity معنایی و وابستگی به wording، prompt؛
- shfit domain در پزشکی، سنجش ازدور و تصویر صنعتی؛
- confidence غیرکالیبره و نبود تضمین ایمنی؛
- هزینه حافظه، latency و دسترسی/ license مدل؛
- bias داده و نادیده گرفتن اشیای کم‌نماینده؛
- در ویدئو، drfit و باقی ماندن ماسک پس از ناپدید شدن شیء.

خواندن مقاله و استاندارد: مدل بنیادی ابزار است، نه truth ground

برای ساخت dataset، خروجی SAM می‌تواند annotation را سرعت دهد، اما پذیرش خودکار آن noise label ساختاری و bias مدل را وارد داده می‌کند. یک حلقه مناسب شامل پیشنهاد مدل، اصلاح انسان، ثبت prompt و زمان، کنترل کیفیت دوگانه و نگهداری نمونه‌های شکست است.

۱۵.۸ معیارهای ارزیابی

۱۰.۱۵.۸ ماتریس اغتشاش پیکسلی

برای کلاس دودویی، TP, FP, FN, TN تعریف می‌شوند. معیارها:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN},$$

$$\text{Dice} = \frac{2TP}{2TP + FP + FN}, \quad \text{IoU} = \frac{TP}{TP + FP + FN}.$$

Pixel accuracy در foreground کوچک می‌تواند با پیش‌بینی تمام-background بالا باشد؛ balanced accuracy یا per-class metric لازم است.

۲۰۱۵۰۸ micro Macro، و وزن‌دهی


- macro: میانگین کلاس‌ها با وزن برابر؛ حساس به کلاس نادر؛
 - micro: ابتدا شمارش‌ها جمع و سپس معیار؛ غالب شدن کلاس بزرگ؛
 - frequency-weighted: مطابق توزیع پیکسل؛ مناسب برخی کاربردها، ولی نادرها را پنهان می‌کند؛
 - per-image: هر تصویر وزن برابر؛ با IoU dataset-level متفاوت است.
- همه گزارش‌ها باید نوع averaging را ذکر کنند.

۳۰۱۵۰۸ مرز و فاصله

IoU Region برای شیء بزرگ به جابه‌جایی کوچک مرز کم‌حساس است. IoU Boundary نوار مرزی truth ground و prediction را مقایسه می‌کند. فاصله Hausdorff

$$H(A, B) = \max \left\{ \sup_{a \in A} \inf_{b \in B} d(a, b), \sup_{b \in B} \inf_{a \in A} d(a, b) \right\}$$

به یک outlier حساس است؛ HD ۹۵ صدک ۹۵ فاصله را گزارش می‌کند. ASSD میانگین فاصله دوطرفه سطح است.



شکل ۱۴۰۸: دو خطای هندسی می‌توانند IoU نزدیک ولی پیامد مهندسی متفاوت داشته باشند. ارزیابی باید ناحیه، مرز و در صورت نیاز توپولوژی را همزمان بسنجد.

۴۰۱۵۰۸ معیار instance و panoptic

AP Instance بر matching ماسک‌ها در های IoU threshold و منحنی precision-recall است. AII و PQ برای صحنه‌های چند نمونه‌ای مفیدند. در شمارش سلول، خطای split/merge باید جدا گزارش شود، زیرا Dice کلی ممکن است ادغام دو سلول را کم‌جریمه کند.


۵.۱۵.۰۸ توپولوژی و ساختار نازک

تعداد، component، حفره، Betti، number، clDice، طول centerline و خطای branch برای رگ، جاده و شبکه عصبی اهمیت دارند. پس‌پردازش مورفولوژیک ممکن است Dice را بهتر و topology را بدتر کند؛ هر دو باید پیش و پس از post-processing گزارش شوند.

۶.۱۵.۰۸ آزمون آماری

برای مقایسه دو مدل روی همان موارد، paired bootstrap روی واحد مستقل (بیمار، صحنه، ویدئو) - inter-val اختلاف را می‌دهد. میانگین $\pm$ انحراف معیار روی های seed تصادفی برای uncertainty آموزش و bootstrap برای uncertainty نمونه‌گیری دو مفهوم متفاوت‌اند. انتخاب بهترین seed و گزارش آن ممنوع است.

۱۶.۰۸ طبقه‌بندی خطا و آزمون فشار



شکل ۱۵.۰۸: چهار خانواده خطای رایج: bias مرز، leakage fragmentation، و حذف شیء کوچک. یک معیار واحد همه را به خوبی جدا نمی‌کند.

پروتکل آزمون باید حداقل شامل، blur، noise، gamma، compression، تغییر، resolution، occlusion، shfit دستگاه و کلاس‌های ناشناخته باشد. robustness را با عملکرد مطلق و افت نسبت به clean گزارش کنید. برای کاربرد واقعی، set failure به صورت دارایی دائمی پروژه نگهداری و در هر نسخه اجرا می‌شود.

کاربرد مهندسی: بازرسی صنعتی

برای نقص کوچک، معیار pixel accuracy بی‌معناست. ترکیب recall شیء، per alarms false، tolerance، localization image، زمان inference و calibration تصمیم توقف خط تولید لازم است. threshold عملیاتی باید از هزینه reject false و accept false استخراج شود.

کاربرد مهندسی: تصویر پزشکی

گزارش باید patient-level، split، HD ۹۵، ASD / موارد خالی، توافق، annotator، uncertainty، validation external و اثر خطای segment بر اندازه‌گیری پایین دست را پوشش دهد. نتیجه تصویری

زیبا جای تحلیل بالینی را نمی‌گیرد.

کاربرد مهندسی: سنجش ازدور

اندازه پیکسل زمینی، tile، shfit domain overlap، اشیا بسیار کوچک و مرزهای مبهم اهمیت دارند. split تصادفی‌های patch مجاور معمولاً برآورد خوش‌بینانه می‌دهد؛ split منطقه‌ای یا زمانی معتبرتر است.

۱۷۰۸ کارگاه پایتون: پیاده‌سازی مرجع و قابل آزمون

۱۰۱۷۰۸ Otsu از صفر

```

1 from __future__ import annotations
2 import numpy as np
3
4
5 def otsu_threshold(image: np.ndarray, levels: int = 256) -> float:
6     """Return an Otsu threshold in the original image scale."""
7     x = np.asarray(image, dtype=np.float64)
8     if x.ndim != 2 or not np.isfinite(x).all():
9         raise ValueError("image must be a finite 2-D array")
10    lo, hi = float(x.min()), float(x.max())
11    if hi <= lo:
12        return lo
13
14    hist, edges = np.histogram(x, bins=levels, range=(lo, hi))
15    p = hist.astype(np.float64) / hist.sum()
16    centers = 0.5 * (edges[:-1] + edges[1:])
17    omega = np.cumsum(p)
18    mu = np.cumsum(p * centers)
19    mu_total = mu[-1]
20
21    valid = (omega > 0.0) & (omega < 1.0)
22    score = np.full(levels, -np.inf)
23    numerator = (mu_total * omega[valid] - mu[valid]) ** 2
24    score[valid] = numerator / (omega[valid] * (1.0 - omega[valid]))
25
26    maxima = np.flatnonzero(np.isclose(score, np.nanmax(score)))
27    idx = int(np.round(maxima.mean()))
28    return float(centers[idx])

```

۲۰۱۷۰۸ آستانه Sauvola با کنترل نوع داده

```

1 import numpy as np
2 from scipy.ndimage import uniform_filter
3
4
5 def sauvola_mask(image, window=41, k=0.2, r=None, foreground="bright"
6 ):
7     x = np.asarray(image, dtype=np.float64)
8     if x.ndim != 2 or window < 3 or window % 2 == 0:
9         raise ValueError("window must be an odd integer >= 3")
10    mean = uniform_filter(x, size=window, mode="reflect")
11    mean_sq = uniform_filter(x * x, size=window, mode="reflect")
12    std = np.sqrt(np.maximum(mean_sq - mean * mean, 0.0))
13    if r is None:
14        r = 0.5 * (np.percentile(x, 99.5) - np.percentile(x, 0.5))
15        r = max(float(r), np.finfo(float).eps)
16    threshold = mean * (1.0 + k * (std / r - 1.0))
17    return (x > threshold) if foreground == "bright" else (x <
18 threshold)

```

۳۰۱۷۰۸ رشد ناحیه با صف و آمار آنالین

```

1 from collections import deque
2 import numpy as np
3
4
5 def region_grow(image, seed, tolerance, connectivity=4):
6     x = np.asarray(image, dtype=np.float64)
7     h, w = x.shape
8     r0, c0 = seed
9     if not (0 <= r0 < h and 0 <= c0 < w):
10        raise ValueError("seed is outside image")
11    offsets = [(-1, 0), (1, 0), (0, -1), (0, 1)]
12    if connectivity == 8:
13        offsets += [(-1, -1), (-1, 1), (1, -1), (1, 1)]
14
15    accepted = np.zeros((h, w), dtype=bool)
16    visited = np.zeros((h, w), dtype=bool)
17    q = deque([(r0, c0)])
18    visited[r0, c0] = True
19    mean, count = float(x[r0, c0]), 0

```

```

20
21 while q:
22     r, c = q.popleft()
23     if abs(float(x[r, c]) - mean) > tolerance:
24         continue
25     accepted[r, c] = True
26     count += 1
27     mean += (float(x[r, c]) - mean) / count
28     for dr, dc in offsets:
29         rr, cc = r + dr, c + dc
30         if 0 <= rr < h and 0 <= cc < w and not visited[rr, cc]:
31             visited[rr, cc] = True
32             q.append((rr, cc))
33 return accepted

```

۴۰۱۷۰۸ GMM و نگاشت مسئولیت

```

1 import numpy as np
2 from sklearn.mixture import GaussianMixture
3
4
5 def gmm_segment(image, n_components=3, spatial_weight=0.0, seed=0):
6     x = np.asarray(image, dtype=np.float64)
7     h, w = x.shape[:2]
8     color = x[..., None] if x.ndim == 2 else x
9     yy, xx = np.mgrid[:h, :w]
10    features = color.reshape(-1, color.shape[-1])
11    if spatial_weight > 0:
12        space = np.column_stack((xx.ravel() / w, yy.ravel() / h))
13        features = np.column_stack((features, spatial_weight * space))
14    features = (features - features.mean(0)) / (features.std(0) + 1e-8)
15    model = GaussianMixture(
16        n_components=n_components,
17        covariance_type="full",
18        reg_covar=1e-5,
19        n_init=5,
20        random_state=seed,
21    ).fit(features)
22    responsibilities = model.predict_proba(features).reshape(h, w, n_components)

```

```

23 labels = responsibilities.argmax(axis=-1)
24 uncertainty = -(responsibilities * np.log(responsibilities + 1e
-12)).sum(-1)
25 return labels, uncertainty, model

```

۵.۱۷.۰۸ walker Random و Chan-Vese با scikit-image

```

1 import numpy as np
2 from skimage.segmentation import random_walker,
  morphological_chan_vese
3
4
5 def random_walker_from_seeds(image, foreground, background, beta=130)
  :
6     markers = np.zeros(image.shape, dtype=np.int32)
7     markers[np.asarray(background, bool)] = 1
8     markers[np.asarray(foreground, bool)] = 2
9     if not np.any(markers == 1) or not np.any(markers == 2):
10         raise ValueError("both foreground and background seeds are
required")
11     return random_walker(image, markers, beta=beta, mode="cg_j") == 2
12
13
14 def chan_vese_segment(image, iterations=150, smoothing=2):
15     return morphological_chan_vese(
16         np.asarray(image, dtype=float),
17         num_iter=iterations,
18         init_level_set="checkerboard",
19         smoothing=smoothing,
20     )

```

۶.۱۷.۰۸ معیارهای مقاوم به ماسک خالی

```

1 import numpy as np
2
3
4 def binary_metrics(pred, target, empty_value=1.0):
5     p = np.asarray(pred, bool)
6     y = np.asarray(target, bool)
7     if p.shape != y.shape:
8         raise ValueError("shape mismatch")

```

```

9     tp = np.logical_and(p, y).sum()
10    fp = np.logical_and(p, ~y).sum()
11    fn = np.logical_and(~p, y).sum()
12    union = tp + fp + fn
13    denom = 2 * tp + fp + fn
14    return {
15        "iou": float(empty_value if union == 0 else tp / union),
16        "dice": float(empty_value if denom == 0 else 2 * tp / denom),
17        "precision": float(1.0 if tp + fp == 0 else tp / (tp + fp)),
18        "recall": float(1.0 if tp + fn == 0 else tp / (tp + fn)),
19    }

```

۷.۱۷.۰۸ اسکلت فشرده U-Net در PyTorch

```

1  import torch
2  from torch import nn
3
4
5  class ConvBlock(nn.Module):
6      def __init__(self, c_in, c_out):
7          super().__init__()
8          self.net = nn.Sequential(
9              nn.Conv2d(c_in, c_out, 3, padding=1, bias=False),
10             nn.BatchNorm2d(c_out), nn.ReLU(inplace=True),
11             nn.Conv2d(c_out, c_out, 3, padding=1, bias=False),
12             nn.BatchNorm2d(c_out), nn.ReLU(inplace=True),
13         )
14     def forward(self, x):
15         return self.net(x)
16
17
18  class SmallUNet(nn.Module):
19     def __init__(self, in_channels=1, classes=2, base=32):
20         super().__init__()
21         self.e1 = ConvBlock(in_channels, base)
22         self.e2 = ConvBlock(base, 2 * base)
23         self.b = ConvBlock(2 * base, 4 * base)
24         self.pool = nn.MaxPool2d(2)
25         self.up2 = nn.ConvTranspose2d(4 * base, 2 * base, 2, stride
26         =2)
27         self.d2 = ConvBlock(4 * base, 2 * base)
28         self.up1 = nn.ConvTranspose2d(2 * base, base, 2, stride=2)

```

```

28     self.d1 = ConvBlock(2 * base, base)
29     self.head = nn.Conv2d(base, classes, 1)
30
31     def forward(self, x):
32         e1 = self.e1(x)
33         e2 = self.e2(self.pool(e1))
34         b = self.b(self.pool(e2))
35         d2 = self.d2(torch.cat([self.up2(b), e2], dim=1))
36         d1 = self.d1(torch.cat([self.up1(d2), e1], dim=1))
37         return self.head(d1)

```

خطای رایج

کد آموزشی کوتاه جای pipeline تولیدی را نمی‌گیرد. training، distributed precision، mixed validation logging، normalization، checkpoint، mode، deterministic و leakage بدون مدیریت ماسک ignore باید در پروژه واقعی اضافه شوند.

۱۸.۸ الگوریتم آموزش و ارزیابی شبکه

الگوریتم ۹: آموزش قابل بازتولید شبکه قطعه‌بندی

۱. واحد مستقل split را تعریف و train/validation/test را پیش از هر tuning تثبیت کنید.
۲. transform مشترک تصویر-ماسک را با interpolation صحیح بسازید.
۳. seed همه کتابخانه‌ها، نسخه محیط و hash داده را ذخیره کنید.
۴. loss اصلی و auxiliary را تعریف و magnitude و gradient آنها را log کنید.
۵. در هر epoch، های metric، per-class موارد خالی، مرز و calibration را روی validation محاسبه کنید.
۶. checkpoint را بر معیار از پیش تعیین‌شده، نه انتخاب پسینی بهترین چند معیار، ذخیره کنید.
۷. پس از پایان، test tuning را فقط یک بار اجرا و paired bootstrap را روی واحد مستقل محاسبه کنید.
۸. نمونه‌های شکست، latency حافظه و threshold عملیاتی را همراه وزن مدل منتشر کنید.

الگوریتم ۱۰: پالایش تعاملی promptable

۱. prompt اولیه point یا box را از کاربر یا detector بگیرید.
۲. چند ماسک و کیفیت پیش‌بینی‌شده را تولید و بهترین را نمایش دهید.
۳. کاربر بزرگ‌ترین ناحیه خطا را با click مثبت/منفی یا scribble اصلاح کند.
۴. prompt جدید و ماسک قبلی را به decoder بدهید و زمان تعامل را ثبت کنید.
۵. تا رسیدن به IoU هدف یا سقف تعامل ادامه دهید.
۶. منحنی کیفیت بر حسب click و زمان annotation را گزارش کنید.

۱۹.۰۸ آزمایش‌های پیشنهادی فصل

۱۰۱۹.۰۸ آزمایش ۱: مرز اعتبار Otsu

دو گاوسی با فاصله میانگین، نسبت کلاس و واریانس متفاوت بسازید. threshold ییزی، Otsu و minimum-error را از نظر خطای طبقه‌بندی و bias آستانه مقایسه کنید. سپس arrangement spatial را تغییر دهید و نشان دهید Otsu به آن حساس نیست.

۲۰۱۹.۰۸ آزمایش ۲: روشی ناهمگن

تصویر سند مصنوعی با میدان روشنی polynomial و نویز بسازید. subtraction، background Otsu، Niblack و Sauvola را روی شبکه‌ای از اندازه پنجره و k ارزیابی کنید. heatmap پارامتر و پایداری را گزارش کنید.

۳۰۱۹.۰۸ آزمایش ۳: رشد ناحیه و ترتیب

seed، tolerance، اتصال و ساختار صف را تغییر دهید. leakage، تعداد مؤلفه و زمان را بسنجید. نسخه mean-updating را با مدل ثابت seed و مدل مقاوم median مقایسه کنید.

۴۰۱۹.۰۸ آزمایش ۴: GMM و ویژگی مکانی

GMM شدت‌محور، رنگ‌محور و رنگ+مکان را روی تصاویر با اشیای هم‌رنگ در مکان‌های جدا مقایسه کنید. entropy مسئولیت و اثر full/diag covariance را گزارش کنید.

۵.۱۹.۰۸ آزمایش ۵: walker random cut graph در برابر

برای seed یکسان، β و λ را تغییر دهید. کیفیت مرز، ناحیه اطمینان، زمان حل و حساسیت به seed اشتباه را تحلیل کنید.

۶.۱۹.۰۸ آزمایش ۶: Chan-Vese زیر مدل‌های مختلف

تصاویر، piecewise-constant، روشنایی گرادیانی و بافت‌دار بسازید. اثر، μ initialization، smoothing و تعداد iteration را بر انرژی و IoU گزارش کنید.

۷.۱۹.۰۸ آزمایش ۷: ابرپیکسل

SLIC را روی تعداد ابرپیکسل و compactness مختلف اجرا کنید. Boundary، Recall، Undersegmen- Error، tation ASA، زمان و حافظه را به صورت منحنی گزارش کنید.

۸.۱۹.۰۸ آزمایش ۸: loss و عدم‌توازن

U-Net کوچک را با، weighted CE، Dice، CE، focal CE+Dice و Tversky روی نسبت foreground-های مختلف آموزش دهید. علاوه بر، Dice، precision/recall، norm gradient calibration، عملکرد روی ماسک خالی را گزارش کنید.

۹.۱۹.۰۸ آزمایش ۹: کیفیت مرز

دو مدل با IoU region مشابه ولی decoder متفاوت بسازید. Boundary، HD IoU، ASSD و خطای اندازه‌گیری مساحت/محیط را مقایسه کنید.

۱۰.۱۹.۰۸ آزمایش ۱۰: segmentation promptable

SAM-family یا مدل promptable در دسترس را با، box point و prompt mask روی چند دامنه اجرا کنید. کیفیت بر حسب تعداد، click، object latency، domain size، type failure و گزارش شود. هیچ نتیجه‌ای بدون ذکر checkpoint و license معتبر نیست.

۱۱.۱۹.۰۸ آزمایش ۱۱: تعمیم خارج از توزیع

مدل را روی یک مرکز، حسگر یا فصل آموزش و روی مرکز/حسگر/فصل دیگر ارزیابی کنید. افت clean-to-OOD، correlation uncertainty-error و گزارش کنید.

۱۲۰۱۹۰۸ آزمایش ۱۲: اثر قطعه‌بندی بر وظیفه پایین دست

ماسک را برای اندازه‌گیری، شمارش، classification یا کنترل ربات استفاده کنید. نشان دهید بهبود Dice همیشه بهبود وظیفه پایین دست نیست؛ sensitivity وظیفه به انواع خطا را استخراج کنید.

۲۰۰۸ پروتکل گزارش حرفه‌ای

جزء گزارش	حداقل اطلاعات لازم
داده	منبع، license، واحد، split، تعداد مستقل، توزیع کلاس، -resolu- tion، modality، حذف‌ها
برچسب	دستورالعمل، annotator، توافق، ignore، ماسک خالی، کنترل کیفیت
پیش‌پردازش	normalization، resize، crop، رنگ، interpolation، padding
مدل	معماری، backbone، checkpoint، تعداد پارامتر، receptive field، ورودی
آموزش	optimizer، schedule، batch، epoch، seed، augmentation، loss و ضرایب
انتخاب مدل	معیار validation و قانون stopping early از پیش تعیین شده
ارزیابی	averaging، threshold، post-processing، test CI، مستقل، موارد خالی
مهندسی	batch= latency، peak throughput، memory، سخت‌افزار، انرژی در صورت اهمیت
شکست	نمونه‌های کیفی انتخاب نشده، taxonomy خطا، corrup- OOD، sensitivity prompt tion،
بازتولید	کد، environment، hash lock، داده، command، log line و checkpoint

۲۱۰۸ تمرین‌های نظری و اثباتی

۱. آستانه بیزی دو گاوسی با واریانس نابرابر و هزینه نامتقارن را استخراج و تعداد نقاط تصمیم را تحلیل کنید.

۲. برابری کمینه σ_w^2 و بیشینه σ_b^2 در Otsu را اثبات کنید.

۳. فرمول هزینه بازه $C(a, b)$ را با سه مجموع تجمعی برای Multi-Otsu استخراج کنید.

۴. نشان دهید هر Lloyd iteration تابع هدف k-means را افزایش نمی‌دهد.

۰۵. با نابرابری Jensen، گام E در EM و bound lower درست‌نمایی را توضیح دهید.
۰۶. معادله اوایلر-لاگرانژ Chan-Vese را با تقریب نرم Heaviside استخراج کنید.
۰۷. شرط زیرمدولار cut graph را برای Potts بررسی و یک pairwise غیرقابل نمایش بسازید.
۰۸. دستگاه walker random را از کمینه انرژی دیریکله به دست آورید.
۰۹. مسئله cut normalized relaxed را از quotient Rayleigh استخراج کنید.
۰۱۰. پیچیدگی SLIC را با محدود شدن جست‌وجوی هر مرکز به $2S \times 2S$ تحلیل کنید.
۰۱۱. رابطه Dice و IoU را اثبات و اثر per-image averaging را با مثال نقض نشان دهید.
۰۱۲. گرادیان Dice soft نسبت به probability یک پیکسل را استخراج و coupling بین پیکسل‌ها را نشان دهید.
۰۱۳. یک مثال بسازید که accuracy pixel بالا و foreground IoU صفر باشد.
۰۱۴. PQ را برای سه prediction شامل merge split و positive false محاسبه کنید.
۰۱۵. توضیح دهید چرا argmax scaling temperature را عوض نمی‌کند.
۰۱۶. یک زیان مرکب برای رگ پیشنهاد و اثر هر ترم را از نظر گرادیان تحلیل کنید.
۰۱۷. برای segmentation، interactive، معیار Curve NoC Under Area را تعریف و مزیت آن را نسبت به IoU یک prompt بیان کنید.
۰۱۸. یک پروتکل conformal برای پوشش سطح شیء پیشنهاد و تفاوت آن با پوشش پیکسلی را تحلیل کنید.

۲۲۰۸ پروژه‌های پایان فصل

۱۰۲۲۰۸ پروژه A: آزمایشگاه جامع آستانه‌گذاری

یک بسته Python با Otsu، Multi-Otsu، Kittler، Triangle، Sauvola Niblack و hysteresis بسازید. همه روش‌ها باید API یکسان، تست واحد، benchmark پشتیبانی `uint8/uint16/float` و گزارش stability داشته باشند.

۲۰۲۲۰۸ پروژه B: قطعه‌بندی تعاملی کلاسیک و بنیادی

Graph، walker random cut، و یک model SAM-family را با prompt یکسان مقایسه کنید. معیار اصلی کیفیت بر حسب click و زمان کاربر باشد؛ prompt failure و shfit domain را دسته‌بندی کنید.

۳۰۲۲۰۸ پروژه C: قطعه‌بندی پزشکی با عدم قطعیت

یک U-Net سه‌بعدی یا دوبعدی را با ensemble آموزش دهید. HD Dice، ۹۵، uncertainty-calibration، test external error، و اثر بر اندازه‌گیری بالینی را گزارش کنید.

۴۰۲۲۰۸ پروژه D: قطعه‌بندی ناحیه‌ای هیبرید

ابتدا SLIC یا watershed سپس GNN/CRF روی graph adjacency region اجرا کنید. کیفیت، حافظه و سرعت را با شبکه dense مقایسه کنید.

۵۰۲۲۰۸ پروژه E: مدل بنیادی برای تولید داده

یک حلقه annotation با پیشنهاد SAM، اصلاح انسان، کنترل کیفیت و learning active بسازید. زمان annotation، نرخ اصلاح، bias کلاس و سود واقعی نسبت به برچسب گذاری دستی را اندازه بگیرید.

۶۰۲۲۰۸ پروژه F: قطعه‌بندی توپولوژی آگاه

برای رگ، جاده یا CE+Dice crack، boundary و loss cDice/topology مقایسه کنید. Betti distance centerline error، و کارایی پایین دست را وارد ارزیابی کنید.

۲۳۰۸ پرامپت پیشنهادی برای Codex

```

1 Build a fully reproducible Python research package for Chapter 8, "
  Image
2 Segmentation: From Thresholding to Foundation Models".
3
4 Implement from scratch where educationally useful:
5 - Bayesian two-class thresholding with asymmetric costs;
6 - stable Otsu and dynamic-programming multi-Otsu;
7 - integral-image local mean/variance, Niblack and Sauvola;
8 - queue-based region growing with 4/8 connectivity;
9 - k-means, GMM-EM with log-sum-exp and fuzzy c-means;
10 - binary s-t graph cut and random walker;
11 - Chan-Vese level set with energy logging;
12 - SLIC superpixels and boundary-recall/undersegmentation metrics;
13 - binary and multiclass segmentation metrics, Boundary IoU, HD95,
  ASSD,
14 calibration and paired bootstrap confidence intervals;
15 - a compact PyTorch U-Net training pipeline with CE, focal, Dice,
  Tversky,

```

Lovasz and boundary-aware losses.

Add wrappers, not fake reimplementations, for current promptable segmentation models when weights and licenses are available. Record model name, checkpoint, commit, license, prompt type, inference device and latency. Never download weights silently and never fabricate benchmark results.

Research requirements:

1. Use synthetic data with analytic ground truth plus at least three public datasets from different domains (documents, natural images, medical, remote sensing or industrial inspection).
2. Prevent patient/scene/video/tile leakage using group-aware splits.
3. Save every configuration, random seed, environment, command line and input hash. Produce CSV, JSON and publication-quality PDF figures.
4. Evaluate region, boundary, instance/topology and calibration metrics.
5. Include robustness tests for blur, noise, JPEG, gamma, scale, occlusion and domain shift.
6. Report mean and standard deviation across training seeds and paired bootstrap confidence intervals across independent test units.
7. Benchmark runtime and peak memory on CPU and GPU when available.
8. Add unit and property tests for empty masks, ignored labels, label remapping, connectivity, deterministic transforms and metric edge cases.
9. Generate a failure gallery automatically, without cherry-picking, by sorting cases using predeclared error criteria.
10. Provide one command that regenerates all chapter figures and tables.

بخش	موضوع
۱	تعریف قطعه‌بندی و taxonomy وظایف
۲	تصمیم‌بیزی و نسبت درست‌نمایی
۳	آستانه گاوسی با هزینه نامتقارن
۴	استخراج Otsu
۵	پیاده‌سازی پایدار Otsu
۶	Multi-Otsu و برنامه‌ریزی پویا
۷	error minimum entropy و Triangle
۸	مدل روشنایی ناهمگن
۹	تصویر انتگرالی و آستانه محلی
۱۰	Sauvola Niblack و انتخاب پنجره
۱۱	hysteresis و threshold چندکاناله
۱۲	رشد ناحیه و seed
۱۳	الگوریتم صف‌محور و پیچیدگی
۱۴	split-merge و watershed نشان‌محور
۱۵	k-means در فضای رنگ-مکان
۱۶	استخراج EM برای GMM
۱۷	c-means fuzzy و shift mean
۱۸	Potts MRF و ساختار مکانی
۱۹	Mumford-Shah تابع
۲۰	استخراج Chan-Vese
۲۱	curvature و set level
۲۲	contour geodesic و مدل‌های محلی
۲۳	cut graph و گراف s-t
۲۴	شرط زیرمدولار و max-flow/min-cut
۲۵	alpha-expansion و چندکلاسه
۲۶	cut normalized و مسئله مقدار ویژه
۲۷	walker random و لاپلاسی گراف
۲۸	مقایسه cut graph و walker random
۲۹	SLIC و فاصله رنگ-مکان
۳۰	معیارهای ابرپیکسل
۳۱	FCN و طبقه‌بندی dense
۳۲	U-Net و connection skip
۳۳	convolution atrous و DeepLab
۳۴	R-CNN Mask و segmentation instance
۳۵	segmentation panoptic و PQ
۳۶	Former Mask و MaskFormer Transformer
۳۷	cross-entropy و عدم‌توازن

Tversky و Dice focal،	۳۸
Lovasz و زیان مرزی	۳۹
loss topology و ساختار نازک	۴۰
برچسب‌گذاری، split و leakage	۴۱
patch، augmentation sampling و stitching	۴۲
نیمه‌نظارتی و active learning	۴۳
عدم قطعیت و calibration	۴۴
SAM و masks promptable	۴۵
SAM ۲ و حافظه ویدئویی	۴۶
SAM ۳ و prompt مفهومی	۴۷
adaptation مدل بنیادی و محدودیت‌ها	۴۸
Dice IoU، averaging و	۴۹
Boundary، HD IoU ۹۵ و ASSD	۵۰
AP instance و PQ panoptic	۵۱
ارزیابی توپولوژی و calibration	۵۲
آزمون آماری و bootstrap paired	۵۳
کارگاه کدنویسی کلاسیک	۵۴
کارگاه U-Net و loss	۵۵
طراحی gallery failure و robustness	۵۶
پروژه‌های حوزه پزشکی، صنعتی و سنجش ازدور	۵۷
مرور مقاله‌های مرزی و جمع‌بندی	۵۸

۲۵۰۸ جمع‌بندی و پل به فصل نهم

جمع‌بندی فصل

۱. قطعه‌بندی یک تصمیم وابسته به هدف است؛ «ناحیه درست» بدون تعریف کاربرد معنا ندارد.
۲. آستانه‌گذاری حالت خاص تصمیم‌بیزی است و Otsu جدایی واریانسی شدت را بدون استفاده از مکان بهینه می‌کند.
۳. روشنایی ناهمگن نیازمند تصحیح photometric یا آستانه تابع مکان است؛ تصویر انتگرالی محاسبه محلی را خطی می‌کند.
۴. رشد ناحیه اتصال و seed را وارد تصمیم می‌کند، ولی به predicate ترتیب و leakage حساس است.
۵. k-means و GMM مدل ظاهر می‌سازند؛ ساختار مکانی باید با ویژگی مکان یا prior گرافی اضافه شود.

۶. Mumford-Shah و Chan-Vese قطعه‌بندی را به کمینه‌سازی، fidelity، همواری و طول مرز تبدیل می‌کنند.
۷. cut graph برای انرژی دودویی زیرمدولار مینیمم سراسری و walker random راه‌حل هارمونیک نرم تولید می‌کند.
۸. superpixel تعداد متغیرها را کاهش می‌دهد، اما سقف کیفیت آن با adherence مرزی و undersegmentation تعیین می‌شود.
۹. شبکه‌های encoder-decoder نمایش را می‌آموزند؛ models query-based واحد پیش‌بینی را از پیکسل به ماسک منتقل می‌کنند.
۱۰. هیچ loss واحدی، region، مرز، imbalance class topology و calibration را همزمان حل نمی‌کند.
۱۱. SAM، SAM ۲ و SAM ۳ به ترتیب prompt هندسی، حافظه ویدئویی و prompt مفهومی را وارد قطعه‌بندی کردند.
۱۲. ارزیابی حرفه‌ای باید، region، boundary، object، topology، robustness uncertainty و هزینه مهندسی را پوشش دهد.
۱۳. فصل بعد می‌تواند بر استخراج و نمایش ویژگی، بافت و توصیف ناحیه بنا شود؛ زیرا اکنون ناحیه‌ها از تصویر جدا و قابل اندازه‌گیری‌اند.

منابع منتخب فصل

- [1] N. Otsu, "A threshold selection method from gray-level histograms," IEEE Transactions on Systems, Man, and Cybernetics, 1979.
- [2] J. Kittler and J. Illingworth, "Minimum error thresholding," Pattern Recognition, 1986.
- [3] J. N. Kapur, P. K. Sahoo, and A. K. C. Wong, "A new method for gray-level picture thresholding using the entropy of the histogram," Computer Vision, Graphics, and Image Processing, 1985.
- [4] W. Niblack, *An Introduction to Digital Image Processing*, Prentice-Hall, 1986.
- [5] J. Sauvola and M. Pietikäinen, "Adaptive document image binarization," Pattern Recognition, 2000.
- [6] D. Bradley and G. Roth, "Adaptive thresholding using the integral image," Journal of Graphics Tools, 2007.
- [7] R. Adams and L. Bischof, "Seeded region growing," IEEE Transactions on Pattern Analysis and Machine Intelligence, 1994.
- [8] F. Meyer, "Topographic distance and watershed lines," Signal Processing, 1994.
- [9] A. P. Dempster, N. M. Laird, and D. B. Rubin, "Maximum likelihood from incomplete data via the EM algorithm," Journal of the Royal Statistical Society B, 1977.
- [10] J. C. Bezdek, R. Ehrlich, and W. Full, "FCM: The fuzzy c-means clustering algorithm," Computers and Geosciences, 1984.
- [11] D. Comaniciu and P. Meer, "Mean shift: A robust approach toward feature space analysis," IEEE TPAMI, 2002.

- [12] D. Mumford and J. Shah, "Optimal approximations by piecewise smooth functions and associated variational problems," *Communications on Pure and Applied Mathematics*, 1989.
- [13] V. Caselles, R. Kimmel, and G. Sapiro, "Geodesic active contours," *International Journal of Computer Vision*, 1997.
- [14] T. F. Chan and L. A. Vese, "Active contours without edges," *IEEE Transactions on Image Processing*, 2001.
- [15] S. Osher and J. A. Sethian, "Fronts propagating with curvature-dependent speed: Algorithms based on Hamilton-Jacobi formulations," *Journal of Computational Physics*, 1988.
- [16] Y. Boykov and M.-P. Jolly, "Interactive graph cuts for optimal boundary and region segmentation of objects in N-D images," *ICCV*, 2001.
- [17] Y. Boykov and V. Kolmogorov, "An experimental comparison of min-cut/max-flow algorithms for energy minimization in vision," *IEEE TPAMI*, 2004.
- [18] V. Kolmogorov and R. Zabih, "What energy functions can be minimized via graph cuts?" *IEEE TPAMI*, 2004.
- [19] C. Rother, V. Kolmogorov, and A. Blake, "GrabCut: Interactive foreground extraction using iterated graph cuts," *ACM Transactions on Graphics*, 2004.
- [20] J. Shi and J. Malik, "Normalized cuts and image segmentation," *IEEE TPAMI*, 2000.
- [21] L. Grady, "Random walks for image segmentation," *IEEE TPAMI*, 2006.
- [22] P. F. Felzenszwalb and D. P. Huttenlocher, "Efficient graph-based image segmentation," *International Journal of Computer Vision*, 2004.
- [23] R. Achanta et al., "SLIC superpixels compared to state-of-the-art superpixel methods," *IEEE TPAMI*, 2012.
- [24] D. Stutz, A. Hermans, and B. Leibe, "Superpixels: An evaluation of the state-of-the-art," *Computer Vision and Image Understanding*, 2018.
- [25] J. Long, E. Shelhamer, and T. Darrell, "Fully convolutional networks for semantic segmentation," *CVPR*, 2015.
- [26] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," *MICCAI*, 2015.

- [27] L.-C. Chen et al., "Encoder-decoder with atrous separable convolution for semantic image segmentation," ECCV, 2018.
- [28] K. He, G. Gkioxari, P. Dollár, and R. Girshick, "Mask R-CNN," ICCV, 2017.
- [29] A. Kirillov et al., "Panoptic segmentation," CVPR, 2019.
- [30] R. Strudel et al., "Segmenter: Transformer for semantic segmentation," ICCV, 2021.
- [31] B. Cheng, A. Schwing, and A. Kirillov, "Per-pixel classification is not all you need for semantic segmentation," NeurIPS, 2021.
- [32] B. Cheng et al., "Masked-attention mask transformer for universal image segmentation," CVPR, 2022.
- [33] T.-Y. Lin et al., "Focal loss for dense object detection," ICCV, 2017.
- [34] S. S. M. Salehi, D. Erdogmus, and A. Gholipour, "Tversky loss function for image segmentation using 3D fully convolutional deep networks," MLMI, 2017.
- [35] M. Berman, A. Rannen Triki, and M. B. Blaschko, "The Lovasz-Softmax loss: A tractable surrogate for the optimization of the intersection-over-union measure," CVPR, 2018.
- [36] H. Kervadec et al., "Boundary loss for highly unbalanced segmentation," MIDL, 2019.
- [37] D. Karimi and S. E. Salcudean, "Reducing the Hausdorff distance in medical image segmentation with convolutional neural networks," IEEE TMI, 2020.
- [38] S. Shit et al., "clDice: A novel topology-preserving loss function for tubular structure segmentation," CVPR, 2021.
- [39] B. Cheng et al., "Boundary IoU: Improving object-centric image segmentation evaluation," CVPR, 2021.
- [40] A. Kirillov et al., "Segment Anything," ICCV, 2023.
- [41] N. Ravi et al., "SAM 2: Segment Anything in Images and Videos," 2024.
- [42] N. Carion et al., "SAM 3: Segment Anything with Concepts," 2025.
- [43] Y. He et al., "VISTA3D: A unified segmentation foundation model for 3D medical imaging," CVPR, 2025.

- [44] T. Zhou et al., "Image segmentation in foundation model era: A survey," 2024.
- [45] C. Kamann and C. Rother, "Benchmarking the robustness of semantic segmentation models," CVPR, 2020.
- [46] C. Guo et al., "On calibration of modern neural networks," ICML, 2017.
- [47] Y. Gal and Z. Ghahramani, "Dropout as a Bayesian approximation: Representing model uncertainty in deep learning," ICML, 2016.
- [48] B. Lakshminarayanan, A. Pritzel, and C. Blundell, "Simple and scalable predictive uncertainty estimation using deep ensembles," NeurIPS, 2017.
- [49] scikit-image Developers, "Segmentation and thresholding API documentation," accessed 2026.
- [50] OpenCV Development Team, "Image thresholding, watershed and GrabCut documentation," accessed 2026.

راهنمای کامپایل، فونت و اجرای آزمایش‌ها

فایل با XeLaTeX کامپایل می‌شود. فونت اصلی Amiri، فونت لاتین DejaVu Serif و فونت کد DejaVu Sans Mono است و برای هر سه جایگزین خودکار تعریف شده است. فایل فونت در بسته توزیع نمی‌شود.

```
1 python -m venv .venv
2 # Windows: .venv\Scripts\activate
3 # Linux/macOS: source .venv/bin/activate
4 pip install -r requirements.txt
5 python generate_figures.py
6 python chapter08_experiments.py --output outputs
7 xelatex image_processing_next_decade_ch08_fa.tex
8 xelatex image_processing_next_decade_ch08_fa.tex
```