
پردازش تصویر در دهه آینده

از عمق ریاضیات تا مهندس حرفه‌ای

کتاب - جزوه درس کارشناسی ارشد و آزمایشگاه پژوهش محور

نهم فصل

کلاسیک بازشناسی و تطبیق ویژگی،

راستی آزمایی، ORB و SIFT تا مقیاس فضای و گوشه قالب، تطبیق از
آموختنی تطبیق به گذار و HOG-SVM بصری، کلمات مقاوم،

آن از که می شود متصل کلاس یا شیء نقشه، حافظه، به هنگامی تصویر
فصل این کنیم. استخراج تصمیم قابل و تطبیق قابل تکرار، قابل نمایش
می آورد. گرد مشترک لوله خط یک در را الگوریتم و آمار هندسه،

نسخه تفصیلی درس - تابستان ۱۴۰۵ / ۲۰۲۶

قابل کامپایل با XeLaTeX + TeXstudio + TeX Live

یادداشت روش شناختی فصل نهم

در فصل‌های پیشین آموختیم تصویر چگونه تشکیل، نویزی، بازسازی و قطعه‌بندی می‌شود. اکنون پرسش عوض می‌شود: کدام بخش تصویر ارزش به‌یادسپاری دارد، چگونه همان ساختار را زیر تغییر نور، چرخش، مقیاس و دیدگاه دوباره پیدا کنیم، و چگونه از مجموعه این تطابق‌ها برای بازشناسی شیء یا صحنه استفاده کنیم؟ پاسخ تاریخی بینایی ماشین، خط لوله‌ای چندمرحله‌ای است:


بازشناسی → راستی‌آزمایی هندسی → تطبیق → توصیف → آشکارسازی

هر مرحله فرضی را به مرحله بعد تحویل می‌دهد. اگر آشکارساز تکرارپذیر نباشد، بهترین توصیفگر نیز شکست می‌خورد؛ اگر توصیفگر متمایز نباشد، نزدیک‌ترین همسایه پر از تطابق کاذب است؛ اگر هندسه آزموده نشود، شباهت بافتی به اشتباه به وجود یک شیء تعبیر می‌شود؛ و اگر تجمع ویژگی‌ها هندسه و فراوانی را نابود کند، بازشناسی ضعیف خواهد شد.

هدف فصل

هدف فصل حفظ چهار کمیت در تمام بحث‌هاست:

۱. هم‌وردایی و ناوردایی: ویژگی زیر تبدیل تصویر چگونه جابه‌جا یا ثابت می‌ماند؟
۲. تکرارپذیری و دقت مکانی: آیا همان ساختار دوباره یافت می‌شود و مکان آن چقدر خطا دارد؟
۳. تمایزبخشی و احتمال ابهام: یک توصیفگر چند وصله نامرتبط را مشابه می‌بیند؟
۴. هزینه و مقیاس‌پذیری: استخراج، جست‌وجو و راستی‌آزمایی برای هزار تصویر یا یک میلیارد ویژگی چقدر هزینه دارد؟



دنگ هی‌چوت ار دوخ‌یت‌اب‌س‌اج‌م‌هن‌یزه و یش‌خ‌ب‌زی‌امت، ین‌اک‌م‌ت‌ق‌د، یی‌اد‌روان‌دی‌اب‌ه‌ل‌ج‌رم‌ره.

شکل ۱: خط‌لوله کلاسیک ویژگی‌تا‌بازشناسی. روش‌های جدید بخشی از این بلوک‌ها را می‌آموزند یا ادغام می‌کنند، اما پرسش‌های بنیادی آن‌ها پابرجاست.

نقشه فشرده فصل

محور	پرسش و خروجی آموزشی
مدل تبدیل	روشنایی، نویز، چرخش، مقیاس، آفین و پرسپکتیو چگونه بر وصله اثر می گذارند؟
تطبیق قالب	ZNCC، NCC، SAD، SSD، correlation phase و چه فرض هایی دارند و چگونه سریع می شوند؟
نقطه کلیدی	FAST، Shi-Tomasi، Harris، Moravec، AGAST و چه ساختاری را آشکار می کنند؟
فضای مقیاس	Gaussian، scale-space، LoG، Hessian DoG و adapta-affine tion چگونه ناوردایی می سازند؟
توصیفگر	SIFT، RootSIFT، HOG، context shape و توصیفگرهای دودویی چه اطلاعاتی را نگه می دارند؟
تطبیق	فاصله اقلیدسی، کسینوسی، ماهالانویس و همینگ؛ cross-test، ratio، assignment و check چگونه انتخاب می شوند؟
راستی آزمایی	RANSAC، PROSAC، LO-RANSAC و MAGSAC++ چگونه مدل هندسی را از برون ریزها جدا می کنند؟
بازشناسی مستقیم	kNN، PCA/LDA، chamfer، Hough، generalized template، SVM و boosting چه زمانی مناسب اند؟
واژگان بصری	VLAD pyramid، spatial TF-IDF، BoVW، Vector Fisher و چگونه ویژگی های محلی را به بردار تصویر تبدیل می کنند؟
ارزیابی	confusion mAP، AUC، pose score، matching repeatability، و آزمون تاب آوری چگونه گزارش می شوند؟
مرز دانش	RDD OmniGlue، RoMa، LoFTR، LightGlue، SuperPoint، و تطبیق گرهای ۲۰۲۶ چه چیزی را تغییر داده اند؟
مهندسی	چگونه خط لوله، reproducible، سریع، بدون leakage و دارای fail-tolerance taxonomy ساخته شود؟

فهرست مطالب

آ	یادداشت روش شناختی فصل نهم
پ	نقشه فشرده فصل
۱	۹ ویژگی، تطبیق و بازشناسی کلاسیک
۱	۱۰۹ ویژگی چیست؟ از مقدار پیکسل تا ساختار قابل تطبیق
۲	۱۰۱۰۹ گروه تبدیل و هزینه ناوردایی
۲	۲۰۱۰۹ معیارهای کیفیت نقطه و ناحیه
۳	۲۰۹ تطبیق قالب: ساده، بنیادی و هنوز کاربردی
۳	۱۰۲۰۹ چرا همبستگی نرمال شده؟
۴	۲۰۲۰۹ محاسبه سریع با انتگرال و FFT
۵	۳۰۹ آشکارسازی گوشه: از انرژی تغییر وصله تا مقادیر ویژه
۵	۱۰۳۰۹ تفسیر طیفی
۶	۲۰۳۰۹ FAST و AGAST: تصمیم روی دایره
۷	۴۰۹ فضای مقیاس: چرا یک نقطه باید اندازه داشته باشد؟
۷	۱۰۴۰۹ نرمال سازی مشتق
۸	۲۰۴۰۹ DoG به عنوان تقریب LoG
۸	۳۰۴۰۹ مکان یابی زیرپیکسلی و حذف پاسخ لبه
۹	۴۰۴۰۹ Hessian و detector blob
۹	۵۰۴۰۹ هموردایی آفین و نواحی پایدار
۱۰	۵۰۹ تخصیص جهت و نرمال سازی ناحیه
۱۰	۶۰۹ توصیفگرهای محلی: چه چیزی از وصله باقی بماند؟
۱۱	۱۰۶۰۹ وصله خام، whitening و NCC
۱۱	۲۰۶۰۹ histogram SIFT: جهت با pooling مکانی
۱۲	۳۰۶۰۹ RootSIFT و هندسه Hellinger

۴۰۶۰۹	HOG: توصیف dense برای بازشناسی	۱۳
۵۰۶۰۹	Context Shape و descriptor شکل	۱۳
۶۰۶۰۹	توصیفگرهای دودویی	۱۳
۷۰۹	تطبیق توصیفگر: از فاصله تا correspondence	۱۵
۱۰۷۰۹	انتخاب معیار فاصله	۱۵
۲۰۷۰۹	آزمون نسبت Lowe	۱۵
۳۰۷۰۹	uniqueness و neighbor nearest mutual cross-check	۱۶
۴۰۷۰۹	جست و جوی دقیق و تقریبی	۱۶
۸۰۹	راستی آزمایی هندسی: شباهت توصیفگر کافی نیست	۱۸
۱۰۸۰۹	RANSAC و احتمال موفقیت	۱۸
۲۰۸۰۹	threshold و مدل نویز	۱۹
۳۰۸۰۹	پیشرفت های RANSAC	۲۰
۴۰۸۰۹	تباهی و انتخاب مدل	۲۰
۹۰۹	از match به بازشناسی: سه خانواده کلاسیک	۲۰
۱۰۹۰۹	تطبیق مستقیم قالب، chamfer و Hough generalized	۲۱
۲۰۹۰۹	ویژگی های کلی شکل و ممان	۲۱
۳۰۹۰۹	Eigenfaces و PCA	۲۱
۴۰۹۰۹	Fisherfaces و LDA	۲۲
۱۰۰۹	طبقه بندی های کلاسیک روی ویژگی	۲۲
۱۰۱۰۰۹	kNN و هندسه فضای ویژگی	۲۳
۲۰۱۰۰۹	مدل مولد گاوسی: LDA و QDA به عنوان classifier	۲۳
۳۰۱۰۰۹	ماشین بردار پشتیبان	۲۳
۴۰۱۰۰۹	چندکلاسه و calibration	۲۴
۵۰۱۰۰۹	cascade و AdaBoost	۲۴
۱۱۰۹	بازنمایی کلمات بصری: از ویژگی محلی به بردار تصویر	۲۵
۱۰۱۱۰۹	ساخت واژگان	۲۵
۲۰۱۱۰۹	assignment multiple و soft hard	۲۶
۳۰۱۱۰۹	TF-IDF و فهرست معکوس	۲۶
۴۰۱۱۰۹	words stop و burstiness	۲۷
۵۰۱۱۰۹	Matching Pyramid Spatial	۲۷
۶۰۱۱۰۹	residual VLAD: تجزیه	۲۸

۲۹	log-likelihood	گرادیان	Vector: Fisher	۷۰۱۱۰۹
۲۹	بازشناسی کلاسیک شیء و چهره:	خط لوله کامل		۱۲۰۹
۲۹	SVM + HOG	برای آشکارسازی شیء		۱۰۱۲۰۹
۳۰	Model Part Deformable			۲۰۱۲۰۹
۳۰	Fisherfaces Eigenfaces،	زیرفضاهای چهره		۳۰۱۲۰۹
۳۱	Histogram Pattern Binary Local			۴۰۱۲۰۹
۳۱	یادگیری متریک و بازشناسی مبتنی بر فاصله			۱۳۰۹
۳۱	تطبیق چندتصویری، مسیر و مکان			۱۴۰۹
۳۲	retrieval سپس localization			۱۰۱۴۰۹
۳۲	روش‌های آموختنی: ادامه یا جایگزین خط لوله کلاسیک؟			۱۵۰۹
۳۲	SuperPoint: آشکارسازی و توصیف self-supervised			۱۰۱۵۰۹
۳۲	SuperGlue و LightGlue			۲۰۱۵۰۹
۳۳	LoFTR و matching detector-free			۳۰۱۵۰۹
۳۳	Dense matching و ویژگی‌های بنیادی			۴۰۱۵۰۹
۳۴	ارزیابی آشکارساز و تطبیق گر			۱۶۰۹
۳۴	repeatability			۱۰۱۶۰۹
۳۴	score و recall precision، matching			۲۰۱۶۰۹
۳۵	AUC pose و خطای هندسی			۳۰۱۶۰۹
۳۵	ارزیابی بازشناسی			۴۰۱۶۰۹
۳۵	robustness	پروتکل		۵۰۱۶۰۹
۳۶	آزمایشگاه کدنویسی فصل			۱۷۰۹
۳۶	Harris	از صفر با قرارداد نوع داده		۱۰۱۷۰۹
۳۷	RANSAC	خط و تعمیم به homography		۲۰۱۷۰۹
۳۸	SVM + BoVW	در pipeline امن		۳۰۱۷۰۹
۳۹	طراحی آزمایش‌های عمیق و بازتولیدپذیر			۱۸۰۹
۴۰	آزمایش ۱: ناوردایی کنترل‌شده			۱۰۱۸۰۹
۴۰	trade-off و threshold	آزمایش ۲:		۲۰۱۸۰۹
۴۰	budget descriptor	آزمایش ۳:		۳۰۱۸۰۹
۴۰	FV و VLAD BoVW،	آزمایش ۴:		۴۰۱۸۰۹
۴۰	کلاسیک در برابر آموختنی	آزمایش ۵:		۵۰۱۸۰۹
۴۰	shfit domain	آزمایش ۶:		۶۰۱۸۰۹
۴۱	خطاهای رایج در مقاله و پروژه			۱۹۰۹

۴۱		۲۰۰۹ پرسش‌های تصمیم مهندسی
۴۲		۲۱۰۹ تمرین‌های نظری و اثباتی
۴۳		۲۲۰۹ پروژه‌های پایان فصل
۴۳		۱۰۲۲۰۹ پروژه A: آزمایشگاه ویژگی کلاسیک
۴۳		۲۰۲۲۰۹ پروژه B: موتور تطبیق و panorama
۴۳		۳۰۲۲۰۹ پروژه C: بازشناسی کلاسیک کامل
۴۳		۴۰۲۲۰۹ پروژه D: بازیابی تصویر مقیاس‌پذیر
۴۳		۵۰۲۲۰۹ پروژه E: کلاسیک در برابر LightGlue/LoFTR
۴۳		۶۰۲۲۰۹ پروژه F: open-set چهره یا شیء
۴۳		۲۳۰۹ پرامپت پیشنهادی برای Codex
۴۵		۲۴۰۹ تقسیم پیشنهادی ویدئوهای ۱۵ دقیقه‌ای
۴۷		۲۵۰۹ جمع‌بندی و پل به فصل دهم

۴۹ منابع منتخب فصل

۵۳ راهنمای کامپایل، فونت و اجرای آزمایش‌ها

فصل ۹

ویژگی، تطبیق و بازشناسی کلاسیک

اهداف یادگیری

- در پایان فصل، دانشجو باید بتواند:
- پاسخ آشکارساز، LoG/DoG Harris و Hessian را از مدل تغییر وصله استخراج کند؛
 - مفهوم هم‌وردایی آشکارساز و ناوردایی توصیفگر را با زبان گروه تبدیل توضیح دهد؛
 - SIFT و HOG را نه به صورت نام، بلکه به صورت histogram جهت‌دار، نرمال‌سازی و pooling پیاده‌سازی کند؛
 - برای توصیفگرهای حقیقی و دودویی معیار فاصله و جست‌وجوی مناسب انتخاب کند؛
 - تعداد iteration لازم RANSAC را محاسبه و degeneracy و threshold را تحلیل کند؛
 - VLAD pyramid، spatial BoVW و Vector Fisher را از های‌descriptor محلی بسازد؛
 - Eigenfaces/Fisherfaces HOG+SVM و cascade AdaBoost را آموزش و ارزیابی کند؛
 - روش کلاسیک را با SuperPoint/LightGlue/LoFTR در پروتکل هندسی عادلانه مقایسه کند؛
 - بین دقت تطبیق، پوشش، سرعت، حافظه، قابلیت توضیح و robustness تصمیم مهندسی بگیرد.

۱۰۹ ویژگی چیست؟ از مقدار پیکسل تا ساختار قابل تطبیق

فرض کنید تصویر مشاهده‌شده از یک صحنه مرجع با تبدیل هندسی g ، تبدیل فوتومتريک ϕ و نویز n ساخته شود:

$$I_{\tau}(u) = \phi(I_1(g^{-1}u)) + n(u). \quad (10.9)$$

هدف ویژگی، ساخت نگاشتی Φ است که اطلاعات مورد نیاز وظیفه را حفظ و تغییرات مزاحم را حذف کند. دو مفهوم باید جدا شوند.

تعریف ۱۰۹ (هموردایی آشکارساز). اگر آشکارساز D مجموعه نواحی یا نقاط را برگرداند، نسبت به تبدیل g همورداست هرگاه

$$D(I \circ g^{-1}) = gD(I).$$

یعنی مکان ویژگی همراه تصویر تبدیل می‌شود، نه اینکه ثابت بماند.

تعریف ۲۰۹ (ناوردایی توصیفگر). توصیفگر Ψ نسبت به g ناورداست اگر پس از نرمال‌سازی ناحیه

$$\Psi(I, p) \approx \Psi(I \circ g^{-1}, gp).$$

برای دقیق معمولاً ناممکن و حتی نامطلوب است؛ تقریب باید تغییرات مجاز را تحمل و تفاوت ساختارهای واقعاً متفاوت را حفظ کند.

اصل راهنما

آشکارساز باید کجا را پایدار پیدا کند؛ توصیفگر باید بگوید چه چیزی در آنجاست؛ matcher باید شباهت را به فرضیه correspondence تبدیل کند؛ و هندسه باید بررسی کند آیا مجموعه فرضیه‌ها می‌تواند از یک دوربین یا تبدیل مشترک آمده باشد.

۱۰.۱۰۹ گروه تبدیل و هزینه ناوردایی

تبدیل‌های رایج به صورت زیر مرتب می‌شوند:

$$u' = u + t, \quad (209)$$

$$u' = sRu + t, \quad (309)$$

$$u' = Au + t, \quad (409)$$

$$\tilde{u}' \sim H\tilde{u}. \quad (509)$$

هر ناوردایی هزینه دارد. توصیفگری که نسبت به همه چرخش‌ها و بازتاب‌ها ناوردا باشد ممکن است حروف «ب» و «پ» یا دو قطعه صنعتی جهت‌دار را بیش از حد مشابه کند. بنابراین ناوردایی باید با کاربرد تعریف شود، نه با شعار «هرچه بیشتر بهتر».

۲۰.۱۰۹ معیارهای کیفیت نقطه و ناحیه

برای یک آشکارساز، چهار معیار اصلی‌اند:

- **repeatability** سهم ساختارهای قابل مشاهده در دو تصویر که هر دو بار آشکار شده‌اند؛
- **error: localization** فاصله نقطه یا اختلاف هم‌پوشانی ناحیه پس از انتقال با هندسه حقیقی؛

- **coverage:** آیا نقاط فقط روی یک بافت پرتکرار جمع شده‌اند یا کل تصویر را می‌پوشانند؟
 - **stability:** حساسیت مکان، مقیاس و جهت به نویز و تغییر نمونه‌برداری.
- برای نواحی بیضوی A و B ، خطای هم‌پوشانی متداول از نسبت اشتراک به اجتماع ساخته می‌شود:

$$\epsilon_{\text{overlap}} = 1 - \frac{|A \cap B|}{|A \cup B|}. \quad (۶.۹)$$

این معیار وابسته به آستانه هم‌پوشانی است و باید همراه تعداد نواحی و محدوده دید مشترک گزارش شود [۴، ۵].

خطای رایج

تعداد زیاد keypoint نشانه کیفیت نیست. یک آشکارساز می‌تواند هزار نقطه روی بافت تکراری تولید کند و برای تخمین وضعیت دوربین از آشکارسازی با دویست نقطه متنوع بدتر باشد. همیشه repeatability، توزیع مکانی، تعداد inlier هندسی و هزینه را همزمان گزارش کنید.

۲.۰۹ تطبیق قالب: ساده، بنیادی و هنوز کاربردی

پیش از نقاط کلیدی، مسئله کلاسیک یافتن یک قالب T در تصویر I است. برای جابه‌جایی d ، مجموع مربعات اختلاف

$$E_{\text{SSD}}(d) = \sum_{x \in \Omega} [I(x+d) - T(x)]^2 \quad (۷.۹)$$

است. اگر نویز جمعی گاوسی مستقل باشد، کمینه‌کردن SSD همان پیشنهادی درست‌نمایی است. برای نویز لاپلاس، SAD طبیعی‌تر است:

$$E_{\text{SAD}}(d) = \sum_{x \in \Omega} |I(x+d) - T(x)|. \quad (۸.۹)$$

۱۰.۲۰۹ چرا همبستگی نرمال شده؟

اگر $I' = aI + b$ باشد، SSD به روشنایی و contrast حساس است. ضریب همبستگی صفرمیانگین نرمال شده

$$\text{ZNCC}(d) = \frac{\sum_{\Omega} (T - \bar{T})(I_d - \bar{I}_d)}{\sqrt{\sum_{\Omega} (T - \bar{T})^2} \sqrt{\sum_{\Omega} (I_d - \bar{I}_d)^2} + \varepsilon} \quad (۹.۹)$$

نسبت به تبدیل مثبت آفین شدت ناورداست. این نتیجه از حذف میانگین و تقسیم بر انحراف معیار می‌آید. با این حال، ZNCC در وصله‌های تقریباً ثابت بدشرط است و در occlusion شدید همچنان شکست می‌خورد.

۲۰.۲۰۹ محاسبه سریع با انتگرال و FFT

بسط می‌دهد:

$$E_{\text{SSD}}(d) = \sum I_d^2 + \sum T^2 - 2 \sum I_d T. \quad (10.9)$$

دو جمله نخست با تصویر انتگرالی و جمله همبستگی با convolution یا FFT محاسبه می‌شود. برای انتقال خالص، قضیه شیفت فوریه پایه correlation phase است:

$$I_T(x) = I_1(x - d) \implies \hat{I}_T(\omega) = e^{-j\omega^T d} \hat{I}_1(\omega). \quad (11.9)$$

با نرمال‌سازی cross-power spectrum، تبدیل معکوس قله‌ای در d تولید می‌کند:

$$R(\omega) = \frac{\hat{I}_1(\omega) \hat{I}_T^*(\omega)}{|\hat{I}_1(\omega) \hat{I}_T^*(\omega)| + \varepsilon}. \quad (12.9)$$

کاربرد مهندسی: ثبت تصویر و کنترل کیفیت

matching Template برای قطعات با وضعیت تقریباً ثابت، fiducial کنترل چاپ، ردیابی کوتاه‌مدت و ثبت translation-only هنوز گزینه‌ای شفاف و سریع است. شکست اصلی آن تغییر مقیاس، دوران، تغییر شکل، پس‌زمینه پرتکرار و تغییر نور موضعی است.

کارگاه کد و آزمایش: پیاده‌سازی ZNCC

```

1 import numpy as np
2
3 def zncc(template: np.ndarray, patch: np.ndarray, eps: float = 1
4         e-8) -> float:
5     """Zero-mean normalized cross correlation for equal-size
6     arrays."""
7     if template.shape != patch.shape:
8         raise ValueError("template and patch must have the same
9     shape")
10    t = template.astype(np.float64) - np.mean(template)
11    p = patch.astype(np.float64) - np.mean(patch)
12    denom = np.linalg.norm(t) * np.linalg.norm(p)
13    if denom < eps:
14        return float("nan") # constant patches are not
15    informative
16    return float(np.sum(t * p) / denom)

```

در آزمایش، روشنایی $I' = aI + b$ ، نویز، occlusion blur و دوران را جداگانه تغییر دهید. نمودار score باید نشان دهد کدام تغییر در مدل ناوردایی ZNCC است و کدام نیست.

۳.۹ آشکارسازی گوشه: از انرژی تغییر وصله تا مقادیر ویژه

برای وصله w و انتقال کوچک $\delta = (u, v)^T$ ، تغییر شدت را تعریف می‌کنیم:

$$E(u, v) = \sum_x w(x) [I(x + \delta) - I(x)]^2. \quad (13.9)$$

با تقریب تیلور مرتبه اول

$$I(x + \delta) - I(x) \approx I_x u + I_y v$$

و بنابراین

$$E(u, v) \approx \begin{bmatrix} u & v \end{bmatrix} \underbrace{\sum_x w(x) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}}_M \begin{bmatrix} u \\ v \end{bmatrix}. \quad (14.9)$$

ماتریس M همان تانسور ساختار فصل هفتم است، اما اینجا نقش آن تصمیم درباره نقطه قابل تطبیق است.


۱۰.۳.۹ تفسیر طیفی

اگر مقادیر ویژه λ_1, λ_2 باشند:

- هر دو کوچک: وصله تخت؛
 - یکی بزرگ و دیگری کوچک: لبه؛ تغییر فقط عمود بر لبه قابل تشخیص است؛
 - هر دو بزرگ: گوشه یا بافت دوبعدی؛ انتقال در هر جهت انرژی را تغییر می‌دهد.
- Harris از محاسبه صریح eigenvalue اجتناب می‌کند:

$$R_H = \det(M) - k \operatorname{tr}(M)^2 = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2. \quad (15.9)$$

Shi-Tomasi معیار $\min(\lambda_1, \lambda_2)$ را پیشنهاد می‌کند و مستقیماً ضعیف‌ترین جهت را می‌سنجد [۲، ۱].



شکل ۱۰.۹: چپ: نقاط با پاسخ Harris زیاد. راست: پاسخ در صفحه مقادیر ویژه؛ گوشه هنگامی پدید می‌آید که هر دو eigenvalue بزرگ باشند.

الگوریتم ۱۰.۹ - Harris با suppression non-maximum

۱. تصویر را در مقیاس مشتق σ_d هموار و I_x, I_y را محاسبه کنید.
 ۲. $I_x^2, I_y^2, I_x I_y$ را در مقیاس integration σ_i هموار کنید.
 ۳. برای هر پیکسل $R_H = \det M - k(\text{tr } M)^2$ را بسازید.
 ۴. نقاط با $R_H > \tau$ را نگه دارید.
 ۵. در همسایگی شعاع r فقط بیشینه محلی را حفظ کنید.
 ۶. برای دقت زیرپیکسلی، یک تابع درجه دوم روی پاسخ اطراف قله برازش کنید.
- پچیدگی با فیلتر separable و NMS محلی $O(N)$ است. آستانه مطلق بین تصاویر قابل انتقال نیست؛ quantile یا budget ثابت نقاط برای آزمایش منصفانه مناسب‌تر است.

۲.۳.۹ FAST و AGAST: تصمیم روی دایره

FAST به جای تانسور، شانزده پیکسل روی دایره Bresenham شعاع ۳ را آزمون می‌کند. نقطه گوشه است اگر حداقل n پیکسل متوالی از مرکز به اندازه t روشن‌تر یا تاریک‌تر باشند. تصمیم درختی ترتیب آزمون‌ها را برای رد سریع نامزدها می‌آموزد. FAST بسیار سریع است، اما مقیاس و جهت را ذاتاً فراهم نمی‌کند. ORB با هرم، orientation و NMS آن را به آشکارساز کامل‌تری تبدیل می‌کند [۳، ۱۲]. AGAST درخت تصمیم را برای معماری‌ها و الگوهای مختلف تعمیم می‌دهد.

خطای رایج

آستانه FAST یا Harris را روی تصویر ۸uint و float با یک عدد ثابت استفاده نکنید. مقیاس gamma intensity و preprocessing مستقیماً پاسخ را عوض می‌کند. قرارداد داده باید در API آشکارساز صریح باشد.

۴.۰۹ فضای مقیاس: چرا یک نقطه باید اندازه داشته باشد؟

یک گوشه در تصویر نزدیک ممکن است در تصویر دور به لکه‌ای کوچک تبدیل شود. آشکارسازی در یک مقیاس ثابت نمی‌تواند زیر zoom تکرارپذیر باشد. فضای مقیاس خطی با convolution گاوسی تعریف می‌شود:

$$L(\mathbf{x}, \sigma) = G(\mathbf{x}; \sigma) * I(\mathbf{x}), \quad G(\mathbf{x}; \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\|\mathbf{x}\|^2}{2\sigma^2}\right). \quad (16.9)$$

گاوسی تحت اصول خطی بودن، ناوردایی انتقال، نیم گروه و عدم ایجاد ساختار جدید، هسته طبیعی فضای مقیاس است. خاصیت نیم گروه

$$G(\cdot; \sigma_1) * G(\cdot; \sigma_2) = G\left(\cdot; \sqrt{\sigma_1^2 + \sigma_2^2}\right) \quad (17.9)$$

اجازه می‌دهد octaveها به صورت بازگشتی ساخته شوند.

۱.۴.۰۹ نرمال سازی مشتق

مقدار مشتق با بزرگ شدن σ کاهش می‌یابد. برای مقایسه میان مقیاس‌ها از مشتق نرمال شده

$$\partial_{\xi_i} = \sigma^\gamma \partial_{x_i} \quad (18.9)$$

استفاده می‌شود. برای blob دوبعدی، لاپلاسی نرمال شده

$$\mathcal{L}(\mathbf{x}, \sigma) = \sigma^2 \nabla^2 L(\mathbf{x}, \sigma) \quad (19.9)$$

در مقیاس متناسب با اندازه blob اکستریم دارد. این اصل «انتخاب مقیاس خودکار» است.

۲۰.۴.۰۹ DoG به عنوان تقریب LoG

از معادله گرما داریم

$$\frac{\partial G}{\partial \sigma} = \sigma \nabla^2 G. \quad (20.09)$$

پس برای k نزدیک یک:


$$G(k\sigma) - G(\sigma) \approx (k - 1)\sigma \frac{\partial G}{\partial \sigma} \quad (21.09)$$

$$= (k - 1)\sigma^2 \nabla^2 G. \quad (22.09)$$

بنابراین Gaussians of Difference

$$D(x, \sigma) = L(x, k\sigma) - L(x, \sigma) \quad (23.09)$$

تقریبی مقیاس نرمال از LoG است و با تفریق دو تصویر هموارشده ارزان محاسبه می شود. SIFT اکستریمم D را در ۲۶ همسایه فضای x, y, σ می یابد [۶].



شکل ۲۰.۹: ردیف بالا: تصویر در مقیاس های افزایشده. ردیف پایین: DoG میان مقیاس های مجاور. نقطه مقیاس ناورد را باید در فضای سه بعدی مکان-مقیاس اکستریمم باشد.

۳۰.۴.۰۹ مکان یابی زیرپیکسلی و حذف پاسخ لبه

بردار offset اکستریمم با بسط درجه دوم DoG حول نمونه $z = (x, y, \sigma)$ به دست می آید:

$$D(z + \Delta z) \approx D(z) + \nabla D^T \Delta z + \frac{1}{2} \Delta z^T H_D \Delta z. \quad (24.09)$$

شرط ایستایی می دهد

$$\widehat{\Delta z} = -\mathbf{H}_D^{-1} \nabla D. \quad (25.9)$$

اگر offset بزرگ باشد، نامزد به نمونه مجاور منتقل و دوباره برازش می شود. کنتراست پایین با مقدار interpolated حذف می شود. برای رد پاسخ های کشیده روی لبه، اگر $\alpha \geq \beta$ های Hessian eigenvalue مکانی باشند و $r = \alpha/\beta$ ، آنگاه

$$\frac{\text{tr}(H)^2}{\det(H)} = \frac{(\alpha + \beta)^2}{\alpha\beta} = \frac{(r + 1)^2}{r}. \quad (26.9)$$

نامزدهایی که این نسبت از حد متناظر $r_{\max}$ بزرگ تر است رد می شوند.

۴.۴.۰۹ Hessian و detector blob

Hessian تصویر

$$\mathbf{H}_L = \begin{bmatrix} L_{xx} & L_{xy} \\ L_{xy} & L_{yy} \end{bmatrix} \quad (27.9)$$

و پاسخ مقیاس نرمال آن

$$R_{\text{Hess}}(\mathbf{x}, \sigma) = \sigma^4 \det(\mathbf{H}_L) \quad (28.9)$$

به ساختارهای blob حساس است. SURF پاسخ Hessian را با filter box و تصویر انتگرالی تقریب می کند. KAZE و AKAZE به جای فضای مقیاس گاوسی خطی، diffusion غیرخطی را به کار می گیرند تا مرزها بهتر حفظ شوند؛ AKAZE با Dffusion Explicit Fast هزینه را کاهش می دهد [۹، ۱۰].

۵.۴.۰۹ هموردایی آفین و نواحی پایدار

تغییر دیدگاه محلی تقریباً آفین است. Harris-Affine و Hessian-Affine شکل بیضی ناحیه را با iteration ماتریس moment second نرمال می کنند. MSER مجموعه های تراز شدت را دنبال می کند و نواحی ای را برمی گزیند که مساحتشان در بازه threshold کم تغییر کند:

$$q(i) = \frac{|Q_{i+\Delta} \setminus Q_{i-\Delta}|}{|Q_i|}. \quad (29.9)$$

کمینه های $q(i)$ نواحی stable maximally هستند. این روش برای نوشته، نماهای شهری و ساختارهای دارای contrast پایدار مفید است [۸]. ارزیابی جامع نواحی affine-covariant نشان داد که انتخاب detector و descriptor باید جداگانه سنجیده شود [۴، ۵].

الگوریتم ۲۰۹ - آشکارسازی اکستریم فضای مقیاس

۰۱. برای هر octave، $s + 3$ تصویر گاوسی با نسبت $k = 2^{1/s}$ بسازید.
 ۰۲. تصاویر مجاور را تفریق و $s + 2$ لایه DoG تولید کنید.
 ۰۳. هر نمونه داخلی را با ۸ همسایه همان مقیاس و ۹+۹ همسایه مقیاس مجاور مقایسه کنید.
 ۰۴. نامزد را با معادله (۲۵۰۹) زیرپیکسلی کنید.
 ۰۵. نامزدهای کنتراست پایین و edge-like را حذف کنید.
 ۰۶. مختصات را به دستگاه تصویر اصلی و مقیاس فیزیکی تبدیل کنید.
- اگر ها separable kernell باشند، ساخت pyramid نسبت به تعداد پیکسل های کل ها octave خطی است. هزینه اصلی descriptor و matching است، نه صرفاً DoG.

۵.۹ تخصیص جهت و نرمال سازی ناحیه

برای ناوردایی دوران، های gradient اطراف keypoint در مقیاس انتخاب شده محاسبه می شوند:

$$m(x) = \sqrt{L_x^2 + L_y^2}, \quad \theta(x) = \text{atan}(L_y, L_x). \quad (30.9)$$

هر نمونه با وزن گاوسی به histogram جهت رأی می دهد. قله اصلی جهت canonical را تعیین می کند؛ قله های نزدیک به قله اصلی می توانند keypoint اضافی بسازند. سپس patch به دستگاه محلی

$$x' = \frac{1}{\sigma} R(-\theta)(x - x_c) \quad (31.9)$$

منتقل می شود. این مرحله آشکارساز هم وردها را به region support نرمال تبدیل می کند.

خطای رایج

جهت گذاری در ساختارهای متقارن ناپایدار است. یک دایره یا بافت isotropic جهت یگانه ندارد. تولید چند orientation پوشش را افزایش می دهد، اما تعداد descriptor و تطابق کاذب را نیز زیاد می کند. ambiguity باید در طراحی matcher لحاظ شود.

۶.۹ توصیفگرهای محلی: چه چیزی از وصله باقی بماند؟

توصیفگر تابعی از patch نرمال شده است:

$$d = \Psi(\mathcal{W}(I; p, \sigma, \theta, A)) \in \mathbb{R}^D \quad \text{یا} \quad \{0, 1\}^D. \quad (32.9)$$

سه trade-off بنیادی اند: localization در برابر pooling، ناوردایی در برابر تمایز بخشی، و ابعاد در برابر سرعت جست و جو.

۱۰۶.۰۹ وصله خام، whitening و NCC

ساده ترین descriptor بردار پیکسل های وصله است. پس از حذف میانگین و نرمال سازی ℓ_2 ، فاصله اقلیدسی و correlation به هم مرتبط اند:

$$\|\hat{p} - \hat{q}\|_2^2 = 2 - 2\hat{p}^T \hat{q}. \quad (33.9)$$

whitening با کوواریانس داده

$$z = \Sigma^{-1/2}(p - \mu) \quad (34.9)$$

جهت های پرتکرار و پرهیبتگی را متعادل می کند، اما نسبت به misalignment حساس است.

۲۰۶.۰۹ histogram SIFT: جهت با pooling مکانی

SIFT یک پنجره معمولاً 16×16 را به 4×4 سلول تقسیم و در هر سلول histogram هشت جهتی می سازد؛ در نتیجه $4 \times 4 \times 8 = 128$ بعد دارد. رأی هر gradient به صورت trilinear میان دو سلول مکانی و دو bin جهت پخش می شود تا تغییر کوچک مکان یا جهت descriptor را ناگهانی عوض نکند. بردار سپس:


۰۱. با نرم ℓ_2 نرمال می شود؛

۰۲. مؤلفه ها در حدی مانند ۰٫۲ clip می شوند؛

۰۳. دوباره نرمال می شود.

clip اثر های gradient بسیار غالب و تغییر illumination موضعی را کاهش می دهد.

توجه دبس ۸ و لولس ۴×۴ SIFT: رگفی صوت



شکل ۳۰۹: نمای آموزشی SIFT. descriptor pooling جهت در سلول‌های مکانی، کمی خطای localization را تحمل می‌کند و در عین حال آرایش محلی را نگه می‌دارد.

مسیر اثبات: چرا histogram نسبت به جابه‌جایی کوچک پایدارتر از پیکسل خام است؟

اگر gradient از مختصات x به $x + \Delta x$ جابه‌جا شود، رأی trilinear به‌طور پیوسته میان سلول‌ها بازتوزیع می‌شود. در patch خام، همان جابه‌جایی می‌تواند مؤلفه‌ای را از یک index به index دیگر منتقل کند و فاصله بزرگی بسازد. pooling یک low-pass در فضای مکان-جهت است؛ پایداری می‌خرد، اما جزئیات فرکانس بالا را حذف می‌کند.

۳۰۶۰۹ RootSIFT و هندسه Hellinger

اگر histogram غیرمنفی h باشد، RootSIFT ابتدا ℓ_1 نرمال و سپس ریشه مؤلفه‌ای می‌گیرد:

$$r_i = \sqrt{\frac{h_i}{\sum_j h_j + \varepsilon}}. \quad (35.9)$$

فاصله اقلیدسی میان r ها معادل فاصله Hellinger میان histogramهاست. این تغییر ساده اغلب matching و retrieval را بهبود می‌دهد [۱۵].

۴.۶.۰۹ HOG: توصیف dense برای بازشناسی

HOG همان ایده histogram جهت را به شبکه dense سلول‌ها و normalization block گسترش می‌دهد. برای block بردار v ، نرمال‌سازی $2L$ -Hys:

$$v \leftarrow \frac{v}{\sqrt{\|v\|_2^2 + \varepsilon^2}}, \quad v_i \leftarrow \min(v_i, c), \quad v \leftarrow \frac{v}{\sqrt{\|v\|_2^2 + \varepsilon^2}}. \quad (36.9)$$

SVM HOG+linear نمونه کلاسیک تبدیل gradient محلی به detector شیء است [۱۶].

۵.۶.۰۹ Context Shape و descriptor شکل

برای نقطه مرزی p_i ، توزیع نسبی سایر نقاط در های bin-log-polar ثبت می‌شود:

$$h_i(k) = \#\{q \neq p_i : q - p_i \in \text{bin}(k)\}. \quad (37.9)$$

هزینه تطبیق دو histogram با χ^2 :

$$C_{ij} = \frac{1}{2} \sum_k \frac{(h_i(k) - h_j(k))^2}{h_i(k) + h_j(k) + \varepsilon}. \quad (38.9)$$

سپس assignment و spline تغییر شکل را برآورد می‌کند. این روش برای contour و بازشناسی شکل کلاسیک مهم است [۱۷].

۶.۶.۰۹ توصیفگرهای دودویی

BRIEF مجموعه آزمون‌های شدت است:


$$\tau(p; a_i, b_i) = \begin{cases} 1, & I(p + a_i) < I(p + b_i), \\ 0, & \text{otherwise.} \end{cases} \quad (39.9)$$

رشته D بیتی با XOR و popcount بسیار سریع مقایسه می‌شود:

$$d_H(b, c) = \sum_{i=1}^D b_i \oplus c_i. \quad (40.9)$$

BRIEF ذاتاً invariant rotation نیست. ORB جهت را با centroid intensity و الگوی آزمون را می‌چرخاند؛ همچنین زوج آزمون‌های پرواریانس و کم‌همبستگی را انتخاب می‌کند [۱۱، ۱۲]. BRISK از pattern sampling حلقوی و FREAK از الگوی شبیه شبکه استفاده می‌کنند. descriptor AKAZE دودویی M-LDB را روی فضای مقیاس غیرخطی می‌سازد.

طابقن جزو تدرش هسی اقم: BRIEF/ORB یی و دود یاهن و مژآ



شکل ۴۰۹: نمای شماتیک آزمون‌های زوجی شدت در توصیفگر دودویی. سرعت بالا نتیجه تبدیل descriptor به رشته بیت و فاصله به popcount است.

توصیفگر	نوع	فاصله معمول	نقطه قوت	محدودیت اصلی
SIFT/RootSIFT HOG	حقیقی، ۱۲۸ بعد حقیقی، dense	ℓ_2 /Hellinger خطی/SVM	robust و متمایز شکل و gradient	هزینه و حافظه بیشتر ناوردایی محدود دیدگاه
BRIEF	دودویی	Hamming	بسیار سریع	بدون جهت/مقیاس ذاتی
ORB	دودویی	Hamming	real-time، آزاد و در دسترس	در تغییر دید شدید ضعیف تر از SIFT
BRISK/FREAK	دودویی	Hamming	الگوی نمونه برداری کارا	blur حساس به photometric و shfit
AKAZE	دودویی/حقیقی	ℓ_2 Hamming/	scale-space لبه نگه دار	تنظیمات و هزینه dffusion

con-	Shape	histogram	χ^2	و شکل	de-	نیاز به	con-
tour/assign-	text			formable	match-		
ment				ing			

۷.۰۹ تطبیق توصیفگر: از فاصله تا correspondence

برای های query descriptor $\{d_i\}$ و database $\{e_j\}$ ، تطبیق خام

$$\pi(i) = \arg \min_j d(d_i, e_j) \quad (۴۱.۰۹)$$

است. اما «نزدیک ترین» الزاماً «درست» نیست؛ در هر پایگاه داده یک نزدیک ترین همسایه وجود دارد، حتی اگر هیچ correspondence واقعی نباشد.

۱.۷.۰۹ انتخاب معیار فاصله

$$d_p(x, y) = \|x - y\|_p, \quad (۴۲.۰۹)$$

$$d_{\cos}(x, y) = 1 - \frac{x^T y}{\|x\| \|y\|}, \quad (۴۳.۰۹)$$

$$d_M(x, y) = \sqrt{(x - y)^T M (x - y)}, \quad (۴۴.۰۹)$$

$$d_H(b, c) = \sum_i b_i \oplus c_i. \quad (۴۵.۰۹)$$


برای های descriptor ℓ_p -نرمال، فاصله اقلیدسی و cosine ranking یکسان می دهند. Mahalanobis correlation و اهمیت ابعاد را مدل می کند، اما نیازمند برآورد یا یادگیری $M \succeq 0$ است. استفاده Hamming برای float descriptor یا ℓ_p برای بیت ها خطای مفهومی است.

۲.۷.۰۹ آزمون نسبت Lowe

اگر d_1 و d_2 فاصله نخستین و دومین همسایه باشند، تطابق پذیرفته می شود اگر

$$\frac{d_1}{d_2} < \rho. \quad (۴۶.۰۹)$$

شود: تطابق درست باید نه فقط نزدیک، بلکه نسبت به گزینه جایگزین متمایز باشد. threshold ثابت مثل ۰.۷ یا ۰.۸، قانون جهان شمول نیست؛ به descriptor دامن، تعداد ویژگی و recall مورد نیاز وابسته است. مقاله SIFT این آزمون را برای کاهش clutter background به کار برد [۶].



شکل ۵.۹: آزمون نسبت. تطابق درست معمولاً فاصله اول کوچک و فاصله دوم به‌وضوح بزرگ‌تری دارد؛ بافت تکراری دو همسایه تقریباً برابر می‌سازد.

۳.۷.۹ uniqueness و neighbor nearest mutual cross-check

تطابق mutual اگر

$$\pi_{A \rightarrow B}(i) = j, \quad \pi_{B \rightarrow A}(j) = i \quad (47.9)$$

باشد. این آزمون precision را افزایش و recall را کاهش می‌دهد. در rectified stereo می‌توان علاوه بر mutuality، محدودیت disparity و ordering را وارد کرد. در retrieval یک database descriptor ممکن است به چند query پاسخ دهد؛ assignment یک‌به‌یک را می‌توان با الگوریتم Hungarian روی ماتریس هزینه حل کرد، اما $O(n^3)$ و حساس به points unmatched است. formulation با dummy node یا unbalanced transport optimal انعطاف بیشتری دارد.

۴.۷.۹ جست‌وجوی دقیق و تقریبی

brute-force برای $N_q N_d D$ عملیات ساده و برای مجموعه کوچک قابل اعتماد است. برای مقیاس بزرگ:

- kd-tree در ابعاد پایین مفید، اما در ابعاد زیاد دچار dimensionality of curse می‌شود؛
- kd-trees randomized و k-means hierarchical در trade-off FLANN جست‌وجو/دقت می‌دهند؛
- LSH برای رشته‌های دودویی یا فضاهای metric خاص مناسب است؛
- quantization product بردار را به زیربردار تقسیم و فاصله تقریبی را با table lookup محاسبه می‌کند؛
- file inverted ابتدا cell coarse را انتخاب و سپس PQ را در همان cell اجرا می‌کند.

مستندات OpenCV نیز ۲L را برای SIFT/SURF و Hamming را برای descriptor دودویی تفکیک می‌کند [۴۴].

الگوریتم ۳۰۹ - تطبیق مقاوم اولیه

۱. نوع descriptor و metric سازگار را تعیین کنید.
۲. برای هر query دو همسایه نزدیک را پیدا کنید.
۳. test ratio با p از پیش اعلام شده اعمال کنید.
۴. در صورت نیاز cross-check mutual را اجرا کنید.
۵. های duplicate مکانی یا چند orientation یک keypoint را ادغام کنید.
۶. score، index، مختصات، scale و orientation هر match را نگه دارید؛ فقط تصویر ترسیمی کافی نیست.
۷. تطابق‌ها را به مرحله هندسی تحویل دهید؛ پیش از هندسه نتیجه detection object اعلام نکنید.

کارگاه کد و آزمایش: SIFT/ORB و انتخاب matcher

```

1 import cv2 as cv
2
3 def detect_and_match(img1, img2, method="sift", ratio=0.75):
4     if method == "sift":
5         detector = cv.SIFT_create(nfeatures=3000)
6         norm = cv.NORM_L2
7     elif method == "orb":
8         detector = cv.ORB_create(nfeatures=3000, scaleFactor
9         =1.2, nlevels=8)
10        norm = cv.NORM_HAMMING
11    else:
12        raise ValueError("method must be 'sift' or 'orb'")
13
14    k1, d1 = detector.detectAndCompute(img1, None)
15    k2, d2 = detector.detectAndCompute(img2, None)
16    if d1 is None or d2 is None:
17        return k1, k2, []
18
19    matcher = cv.BFMatcher(normType=norm, crossCheck=False)
20    pairs = matcher.knnMatch(d1, d2, k=2)
21    good = [m for m, n in pairs if m.distance < ratio * n.
22            distance]
23    return k1, k2, good

```


برای گزارش علی، علاوه بر تعداد good، match، تعداد inlier پس از مدل هندسی، reprojection error، زمان detect/describe/match و حافظه descriptor را ذخیره کنید.

۸.۰۹ راستی آزمایی هندسی: شباهت توصیفگر کافی نیست

تطابق‌های اولیه مجموعه‌ای از زوج نقاط $\{(x_i, x'_i)\}$ است. مدل هندسی θ residual

$$r_i(\theta) = d_g(x'_i, f(x_i; \theta)) \quad (۴۸.۰۹)$$

می‌سازد. برای homography از خطای symmetric، transfer، برای matrix fundamental از Sampson و برای PnP از reprojection استفاده می‌شود.



شکل ۶.۰۹: وجود های match descriptor تنها فرضیه می‌سازد. مدل هندسی باید سازگاری جمعی -correspondence را بررسی کند.

۱۰.۸.۰۹ RANSAC و احتمال موفقیت


اگر سهم inlier برابر w و اندازه sample minimal برابر s باشد، احتمال اینکه یک sample کاملاً inlier باشد w^s است. پس احتمال شکست پس از N iteration:

$$P_{\text{fail}} = (1 - w^s)^N. \quad (۴۹.۰۹)$$

برای احتمال موفقیت p :

$$N \geq \frac{\log(1 - p)}{\log(1 - w^s)}. \quad (۵۰.۰۹)$$

مثلاً با $w = ۰.۵$ ، homography با $s = ۴$ و $p = ۰.۹۹$ حدود ۷۲ iteration می‌خواهد؛ با $w = ۰.۲$ این عدد به حدود ۲۸۷۶ می‌رسد. بنابراین کیفیت matching اولیه مستقیماً هزینه هندسه را تعیین می‌کند [۱۸].



شکل ۷.۹: RANSAC مدل را از subset حداقلی پیشنهاد و با consensus ارزیابی می‌کند. threshold residual تعریف عملی inlier است.

الگوریتم ۴.۹ - RANSAC تطبیقی

۱. $N = N_{\max}$ ، بهترین score و mask خالی را مقداردهی کنید.
۲. یک sample minimal غیرتباہ انتخاب و مدل را برازش کنید.
۳. residual همه داده‌ها را حساب و های inlier $r_i < \tau$ را مشخص کنید.
۴. مدل را با score، robust، نه فقط شمارش خام، رتبه‌بندی کنید.
۵. اگر بهتر بود، مدل را روی های inlier پالایش و $\hat{w}$ را به‌روزرسانی کنید.
۶. N را با معادله (۵.۹) و $\hat{w}$ کاهش دهید.
۷. پس از توقف، refinement nonlinear روی های inlier اجرا و covariance تقریبی گزارش کنید.

۲.۸.۹ threshold و مدل نويز

آستانه پیکسلی ثابت با تغییر resolution و keypoint uncertainty عادلانه نیست. اگر resid-covariance ual برابر Σ_i باشد، فاصله Mahalanobis

$$r_i^2 = e_i^T \Sigma_i^{-1} e_i \quad (۵.۱۰۹)$$

را با quantile توزیع χ^2 مقایسه می‌کنیم. calibra- camera و detector localization keypoint، scale tion باید در uncertainty وارد شوند.

۳۰۸۰۹ پیشرفت‌های RANSAC

- **PROSAC:** sample را از های match با score بهتر آغاز و دامنه را تدریجی گسترش می‌دهد؛
- **LO-RANSAC:** هر مدل خوب را با optimization local روی های inlier بهبود می‌دهد؛
- **USAC:** sampler، degeneracy verification و polishing را در چارچوب واحد ترکیب می‌کند؛
- **MAGSAC++:** به جای threshold نویز ثابت، کیفیت و وزن‌ها را با marginalization روی noise scale و IRLS می‌سازد [۲۱].

۴۰۸۰۹ تباهی و انتخاب مدل

چهار نقطه تقریباً هم خط برای homography تباه‌اند؛ نقاط روی صفحه خاص ممکن است fundamental matrix را با homography اشتباه‌پذیر کنند؛ حرکت دورین و geometry scene نیز configu- critical ration می‌سازد. pipeline حرفه‌ای باید:

۱. sample minimal را پیش از solve از نظر rank/area آزمون کند؛
۲. چند مدل محتمل مانند H و F را مقایسه کند؛
۳. penalty complexity یا prior geometric داشته باشد؛
۴. cheirality و محدودیت‌های دورین را پس از بازیابی pose بررسی کند.

معیار تصمیم برای کاربرد

برای panorama صفحه‌ای یا دوران خالص، homography مناسب است؛ برای دو دید عمومی صحنه سه‌بعدی، fundamental/essential برای localization با نقاط سه‌بعدی، PnP و برای جسم non-rigid یک مدل سراسری واحد کافی نیست. انتخاب مدل پیش از RANSAC بخشی از فرض مسئله است.

۹۰۹ از match به بازشناسی: سه خانواده کلاسیک

بازشناسی را می‌توان به سه صورت دید:

۱. **recognition: instance** آیا همین شیء/نما قبلاً دیده شده است؟
۲. **recognition: category** آیا تصویر به کلاس مفهومی تعلق دارد؟
۳. **retrieval:** تصاویر مشابه را با ranking برگردان.

ویژگی محلی برای instance و geometry بسیار طبیعی است؛ recognition category به تجميع و classifier نیاز دارد.

۱۰.۹.۰۹ تطبیق مستقیم قالب، chamfer و Hough generalized

برای edge های T template map و تصویر، distance chamfer با D_I transform distance:

$$E_{\text{chamfer}}(T, I) = \frac{1}{|T|} \sum_{x \in T} D_I(x) \quad (52.9)$$

است. نسخه جهت دار اختلاف tangent را نیز جریمه می کند. Hough Generalized برای هر نقطه مرزی، بردار به مرکز مرجع را در R-table ذخیره و در تصویر جدید در فضای وضعیت رأی گیری می کند. این روش برای silhouette مشخص و تعداد کلاس کم تفسیرپذیر است، اما فضای رأی با scale/rotation بزرگ می شود.

۲۰.۹.۰۹ ویژگی های کلی شکل و ممان

ممان های هندسی

$$m_{pq} = \sum_x \sum_y x^p y^q I(x, y) \quad (53.9)$$

و ممان مرکزی

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x, y) \quad (54.9)$$

برای مرکز، جهت و invariants استفاده می شوند. Hu هفت ترکیب ناورد نسبت به انتقال، scale و rotation ساخت. این توصیفگرها compact و مناسب شکل تمیزند، ولی به error segmentation و clutter حساس اند.

۳۰.۹.۰۹ PCA و Eigenfaces

بردار تصویر $x \in \mathbb{R}^D$ حول میانگین مرکز می شود. PCA جهت های بیشینه واریانس را از eigenvectors کوواریانس

$$S_T = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T \quad (55.9)$$

می یابد:

$$W_{\text{PCA}} = \arg \max_{W^T W = I} \text{tr}(W^T S_T W). \quad (56.9)$$

Eigenfaces تصویر را در subspace کم‌بعد بازنمایی و neighbor nearest را ممکن می‌کند [۲۲]. PCA label را نمی‌بیند؛ تغییر نور ممکن است از تفاوت هویت واریانس بیشتری داشته باشد.

۴.۹.۹ Fisherfaces و LDA

با میانگین کلاس μ_c :


$$S_W = \sum_c \sum_{i: y_i=c} (x_i - \mu_c)(x_i - \mu_c)^T, \quad (57.9)$$

$$S_B = \sum_c N_c (\mu_c - \mu)(\mu_c - \mu)^T. \quad (58.9)$$

LDA نسبت جدایی بین کلاس به درون کلاس را بیشینه می‌کند:

$$W_{LDA} = \arg \max_w \frac{|W^T S_B W|}{|W^T S_W W|}. \quad (59.9)$$

راه‌حل از مسئله eigenvalue generalized $S_B w = \lambda S_W w$ می‌آید. در $D \gg N$ ، S_W تکین است و ابتدا PCA یا regularization لازم است [۲۳].



شکل ۸.۹: PCA جهت واریانس کل را می‌گیرد؛ LDA جهت جدایی برچسب‌دار را. هر دو خطی و وابسته به preprocessing و split صحیح‌اند.

۱۰.۹ طبقه‌بندهای کلاسیک روی ویژگی

۱۰۱۰۰۹ kNN و هندسه فضای ویژگی

قاعده نزدیک‌ترین همسایه برای نمونه x :

$$\hat{y} = \text{mode}\{y_i : i \in \mathcal{N}_k(x)\} \quad (۶۰.۹)$$

است. ساده و بدون آموزش پارامتری است، اما هزینه inference با اندازه داده رشد می‌کند و به scaling ابعاد و dimensionality of curse حساس است. نسخه وزن‌دار از $w_i = (d_i + \varepsilon)^{-p}$ استفاده می‌کند. انتخاب k باید داخل validation و پس از تمام مراحل normalization feature انجام شود.

۲۰۱۰۰۹ مدل مولد گاوسی: LDA و QDA به‌عنوان classifier

اگر

$$p(x | y = c) = \mathcal{N}(x; \mu_c, \Sigma_c), \quad (۶۱.۹)$$

آنگاه log-posterior تا ثابت برابر

$$\delta_c(x) = -\frac{1}{2} \log |\Sigma_c| - \frac{1}{2} (x - \mu_c)^T \Sigma_c^{-1} (x - \mu_c) + \log \pi_c. \quad (۶۲.۹)$$

است. covariance مشترک مرز خطی LDA و covariance مستقل مرز درجه دوم QDA می‌دهد. shrinkage

$$\hat{\Sigma}_\alpha = (1 - \alpha) \hat{\Sigma} + \alpha \frac{\text{tr}(\hat{\Sigma})}{D} \mathbf{I} \quad (۶۳.۹)$$

برای داده کم و feature پربعد ضروری است.

۳۰۱۰۰۹ ماشین بردار پشتیبان

برای داده دودویی (x_i, y_i) ، SVM: soft-margin


$$\min_{w, b, \xi} \frac{1}{2} \|w\|_2^2 + C \sum_i \xi_i \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \quad (۶۴.۹)$$

فاصله مرز تا نزدیک‌ترین نمونه‌ها $\|w\|/2$ است؛ کمینه‌کردن نرم، حاشیه را بیشینه می‌کند. دوگان:

$$\max_\alpha \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j), \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0. \quad (۶۵.۹)$$

تنها نمونه‌های $\alpha_i > 0$ بردار پشتیبان‌اند. برای هاستوگرام‌های kernel χ^2 یا intersection می‌توانند مناسب‌تر از RBF باشند، اما SVM linear روی HOG VLAD و FV پس از نرمال‌سازی اغلب baseline

قوی و سریع است [۲۴، ۱۶].



شکل ۹.۰۹: SVM خطی. بردارهای پشتیبان مرز را تعیین می‌کنند؛ نقاط دورتر در جواب primal اثر مستقیم ندارند.

۴.۱۰.۹ چند کلاسه و calibration

راهبردهای one-vs-one و one-vs-rest چند classifier دودویی می‌سازند. score حاشیه احتمال نیست. logistic مدل scaling Platt

$$P(y = 1 | f) = \frac{1}{1 + \exp(Af + B)} \quad (۶۶.۹)$$

را روی validation جدا برازش می‌کند؛ regression isotonic انعطاف‌پذیرتر اما پرریسک‌تر است. cali- set bration نباید با test یکی باشد.

۵.۱۰.۹ AdaBoost و cascade

برای weak های learner $h_t(x) \in \{-1, +1\}$ classifier AdaBoost

$$F_T(x) = \sum_{t=1}^T \alpha_t h_t(x) \quad (۶۷.۹)$$

و زیان نمایی

$$\sum_i \exp(-y_i F_T(x_i)) \quad (۶۸.۹)$$

را به صورت stagewise کاهش می دهد. وزن نمونه ها

$$w_i^{(t+1)} \propto w_i^{(t)} \exp(-\alpha_t y_i h_t(x_i)) \quad (۶۹.۹)$$

نمونه های اشتباه را تقویت می کند. Viola-Jones از Haar-like های feature سریع با image integral و cascade استفاده کرد: های stage نخست تقریباً همه پنجره های منفی آسان را با هزینه کم رد می کنند، های stage بعدی دقیق ترند [۲۵].

منطق cascade

اگر stage s نرخ d_s detection و f_s positive false داشته باشد، برای S stage:

$$D = \prod_{s=1}^S d_s, \quad F = \prod_{s=1}^S f_s.$$

کاهش شدید positive false نیازمند حفظ detection بسیار بالا در هر stage است. cascade یک طراحی آماری هزینه محور است، نه صرفاً چند classifier پشت سرهم.

۱۱.۰۹ بازنمایی کلمات بصری: از ویژگی محلی به بردار تصویر

ویژگی های محلی تعداد متغیر و ترتیب نامشخص دارند. Words Visual of Bag آن ها را به histogram با طول ثابت تبدیل می کند.

۱۰.۱۱.۰۹ ساخت واژگان

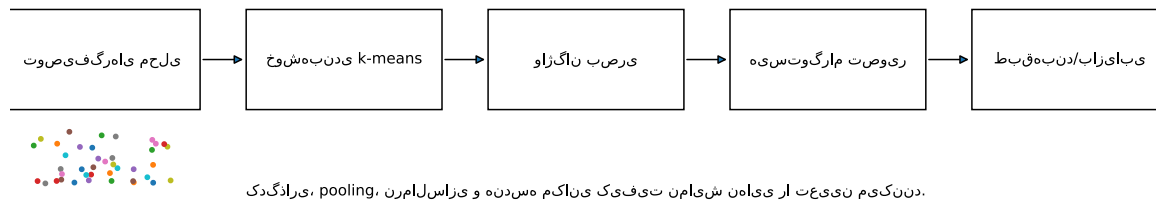
از های descriptor مجموعه، train نمونه برداری و k-means حل می شود:

$$\min_{\{c_k\}, \{a_i\}} \sum_i \|d_i - c_{a_i}\|_2^2. \quad (۷۰.۹)$$

ها centroid و واژه بصری اند. هر descriptor به نزدیک ترین واژه quantize و histogram

$$h_k(I) = \sum_{i \in I} \mathbb{1}[a_i = k] \quad (۷۱.۹)$$

ساخته می شود. واژگان باید فقط روی train ساخته شود؛ ساخت codebook روی کل leakage dataset است.



شکل ۱۰۰۹: خط لوله BoVW انتخاب، descriptor، codebook، weighting assignment و pooling همگی بخشی از مدل اند.

۲۰۱۱.۹ assignment multiple و soft hard

Hard discontinuous assignment است. در soft assignment:

$$w_{ik} = \frac{\exp(-\beta \|d_i - c_k\|^2)}{\sum_{\ell} \exp(-\beta \|d_i - c_{\ell}\|^2)}, \quad h_k = \sum_i w_{ik}. \quad (۷۲.۹)$$

assignment multiple فقط چند centroid نزدیک را فعال می کند. quantization assignment soft error را کم، اما sparsity و سرعت index inverted را کاهش می دهد.

۳۰۱۱.۹ TF-IDF و فهرست معکوس

برای تصویر j و واژه k :

$$\text{tf}_{kj} = \frac{n_{kj}}{\sum_{\ell} n_{\ell j}}, \quad \text{idf}_k = \log \frac{N+1}{N_k+1}, \quad v_{kj} = \text{tf}_{kj} \text{idf}_k. \quad (۷۳.۹)$$

واژه ای که در همه تصاویر است قدرت تشخیص کمی دارد. index inverted برای هر واژه list posting تصاویر دارای آن را ذخیره و جست و جو را به اشتراک واژه ها محدود می کند؛ این ایده Google video و retrieval image کلاسیک را مقیاس پذیر کرد [۲۷، ۲۸].

سوگرم تسرهف و TF-IDF اب ریزپسایقم یبایزاب

w1	i1: tf=2	i3: tf=3	
w2	i1: tf=4	i2: tf=1	i4: tf=5
w3	i2: tf=5		
w4	i1: tf=4	i3: tf=5	i4: tf=3
w5	i3: tf=5	i4: tf=4	

دنکیم تیوقت ار ردان یاههزاو IDF؛ دنکیم یبایزاب ار کرتشم هزاو یاراد ریواصت طقف سوگرم تسرهف

شکل ۱۱.۹: فهرست معکوس. واژه‌های query به posting list می‌روند؛ TF-IDF و normalization score تصویر را می‌سازند.

۴.۱۱.۹ words stop و burstiness

بافت تکراری ممکن است یک واژه را ده‌ها بار در یک تصویر تکرار کند و score را مصنوعی بالا ببرد. راهکارها:

• normalization power $h_i \leftarrow \text{sign}(h_i)|h_i|^\alpha$ با $0 < \alpha < 1$ ؛

• frequency، term capped

• حذف stop های word بسیار رایج؛


• verification geometric پس از retrieval اولیه.

۵.۱۱.۹ Matching Pyramid Spatial

BoVW ترتیب مکانی را حذف می‌کند. Pyramid Spatial تصویر را در سطح ℓ به $2^\ell \times 2^\ell$ سلول تقسیم و های histogram سلولی را concat می‌کند:

$$\Phi(I) = [\sqrt{w_1}h^{(1)}, \sqrt{w_2}h^{(2)}, \dots, \sqrt{w_L}h^{(L)}]. \quad (۷۴.۹)$$

weighted، intersection histogram kernel تطابق ریزتر را بیشتر وزن می‌دهد [۲۹].



شکل ۱۲۰۹: هرم مکانی. نمایش به تدریج از orderless به حفظ آرایش تقریبی می‌رود، اما ابعاد با تعداد سلول‌ها رشد می‌کند.

الگوریتم ۵۰۹ - آموزش BoVW بدون leakage

۱. split را در سطح شیء/ویدئو/فرد/صحنه انجام دهید.
۲. descriptorها را فقط از train و با سقف نمونه در هر تصویر جمع کنید.
۳. preprocessing مانند RootSIFT/PCA را فقط روی train برآزش کنید.
۴. k-means را با چند initialization آموزش و distortion را ثبت کنید.
۵. train/validation/test را با codebook ثابت encode کنید.
۶. weighting و normalization را داخل pipeline اعمال کنید.
۷. classifier و hyperparameterها را روی validation انتخاب کنید.
۸. test را یک بار ارزیابی و hash codebook و seed را ذخیره کنید.

۶۰۱۱۰۹ VLAD: تجميع residual

BoVW فقط count را نگه می‌دارد. VLAD برای هر residual centroid های descriptor تخصیص یافته را جمع می‌کند:

$$v_k = \sum_{i:a_i=k} (d_i - c_k), \quad v = [v_1; \dots; v_K]. \quad (۷۵۰۹)$$

intra-normalization هر block و سپس ℓ_2 power+ burstiness normalization را کنترل می‌کند. VLAD اطلاعات مرتبه اول نسبت به codeword را حفظ می‌کند و برای retrieval/recognition قوی‌تر از count خام است [۳۰].

۷.۱۱.۰۹ Vector: Fisher گرادیان log-likelihood

فرض کنید descriptorها از GMM با پارامتر $\lambda = \{\pi_k, \mu_k, \sigma_k\}$ آمده‌اند. Vector Fisher گرادیان log-likelihood داده نسبت به پارامتر مدل است:

$$\mathcal{G}_\lambda(I) = \frac{1}{N} \nabla_\lambda \log p(\{\mathbf{d}_i\} | \lambda). \quad (۷۶.۰۹)$$

برای covariance قطری و responsibility $\gamma_i(k)$ ، مؤلفه میانگین:

$$\mathbf{u}_k = \frac{1}{N \sqrt{\pi_k}} \sum_i \gamma_i(k) \frac{\mathbf{d}_i - \boldsymbol{\mu}_k}{\sigma_k}, \quad (۷۷.۰۹)$$

و مؤلفه واریانس:

$$\mathbf{v}_k = \frac{1}{N \sqrt{2\pi_k}} \sum_i \gamma_i(k) \left[\frac{(\mathbf{d}_i - \boldsymbol{\mu}_k)^2}{\sigma_k^2} - 1 \right]. \quad (۷۸.۰۹)$$

FV آمار مرتبه اول و دوم را نسبت به مدل مولد ثبت می‌کند. SVM linear و normalization power بخش جدایی‌ناپذیر اند pipeline [۳۱، ۳۲].

نمایش	اطلاعات نگه‌داشته	بعد تقریبی	مزیت	محدودیت
BoVW	count واژه	K	inverted sparse، index	quantization و حذف geometry
SPM	count در سلول	$K \sum \mathcal{F}^\ell$	ساختار مکانی	بعد زیاد، grid سخت
VLAD	residual مرتبه اول	KD	compact و قوی	dense و حساس به normalization
FV	آمار مرتبه ۱ و ۲ GMM	$2KD$	پایان غنی، linear classifier	حافظه و پیچیدگی بیشتر

۱۲.۰۹ بازشناسی کلاسیک شیء و چهره: خط لوله کامل

۱۰.۱۲.۰۹ SVM + HOG برای آشکارسازی شیء

در detector لغزان، برای هر window بردار HOG ساخته و score خطی

$$s(\mathbf{x}) = \mathbf{w}^T \Phi_{\text{HOG}}(\mathbf{x}) + b \quad (۷۹.۰۹)$$

محاسبه می‌شود. pyramid تصویرهای scale شیء را پوشش می‌دهد. پنجره‌های هم‌پوشان با non-maximum suppression ادغام می‌شوند. در NMS کلاسیک، box با score بالاتر انتخاب و های box با

$$\text{IoU}(B_i, B_j) = \frac{|B_i \cap B_j|}{|B_i \cup B_j|} > \tau_{\text{nms}} \quad (۸۰.۰۹)$$

حذف می‌شوند. mining hard-negative نقش مهمی دارد: پس از آموزش اولیه، false های positive واقعی detector از تصاویر منفی جمع و مدل دوباره آموزش داده می‌شود.

الگوریتم ۶.۰۹ - HOG-SVM با mining hard-negative

۱. نمونه‌های مثبت را هم‌تراز و window استاندارد تعریف کنید.
۲. از تصاویر منفی های window تصادفی اولیه بگیرید.
۳. HOG را با cell، bin block و normalization ثابت استخراج کنید.
۴. SVM linear را آموزش دهید.
۵. detector را روی تصاویر منفی کامل اجرا و false های positive پرامتیاز را جمع کنید.
۶. مجموعه منفی را با hard negative ها گسترش و SVM را بازآموزی کنید.
۷. روی score threshold validation و NMS را انتخاب کنید؛ test را دست‌نخورده نگه دارید.

۲۰.۱۲.۰۹ Model Part Deformable

DPM شیء را با filter root و part های filter جابه‌جاشونده مدل می‌کند:

$$S(x, z) = \sum_i w_i^T \Phi(I, z_i) - \sum_i d_i^T \psi(\Delta z_i) + b. \quad (۸۱.۰۹)$$

جمله deformation معمولاً شامل $[dx, dy, dx^2, dy^2]$ است. inference با distance transform سریع و آموزش با SVM latent انجام می‌شود. اهمیت تاریخی DPM در appearance formalization + latent + geometry «parts» است؛ ایده‌ای که در مدل‌های مدرن نیز بازمی‌گردد [۲۶].

۳۰.۱۲.۰۹ Fisherfaces Eigenfaces، و زیرفضاهای چهره

برای چهره، alignment از خود classifier مهم‌تر است. crop، landmark scale و نور باید قرارداد ثابت داشته باشند. pipeline کلاسیک:

detect $\rightarrow$ align $\rightarrow$ normalize photometric $\rightarrow$ PCA/LDA $\rightarrow$ distance/classifier.

در closed-set accuracy، threshold recognition، open-set برای رد هویت ناشناخته لازم است. بدون گزارش reject accept/false false برای کاربرد امنیتی کافی نیست.

۴.۱۲.۰۹ Histogram Pattern Binary Local

LBP برای پیکسل مرکز g_c و همسایه‌ها g_p :

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p, \quad s(z) = 1[z \geq 0]. \quad (۸۲.۰۹)$$

LBP Histogram در grid مکانی برای texture و چهره استفاده می‌شود. چون فقط ترتیب intensity را می‌گیرد، نسبت به تغییر monotonic روشنایی مقاوم است؛ اما نویز نزدیک threshold بیت‌ها را ناپایدار می‌کند. الگوهای uniform تعداد transition‌های ۱/۰ کم دارند و ابعاد را کاهش می‌دهند.

۱۳.۰۹ یادگیری متریک و بازشناسی مبتنی بر فاصله

گاهی classifier ثابت کافی نیست و می‌خواهیم فاصله، شباهت معنایی یا هویتی را بازتاب دهد. Mahalanobis metric

$$d_M^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j), \quad \mathbf{M} \succeq 0. \quad (۸۳.۰۹)$$

با $\mathbf{M} = \mathbf{L}^T \mathbf{L}$ معادل Euclidean بعد از projection است. یک objective ساده pairwise:

$$\min_{\mathbf{M} \succeq 0} \sum_{(i,j) \in \mathcal{S}} d_M^2(\mathbf{x}_i, \mathbf{x}_j) + \lambda \sum_{(i,j) \in \mathcal{D}} [m - d_M^2(\mathbf{x}_i, \mathbf{x}_j)]_+. \quad (۸۴.۰۹)$$

LMNN همسایه‌های هدف را نزدیک و impostor را بیرون حاشیه نگه می‌دارد. این بخش پل مفهومی به loss contrastive/triplet است، اما در خط لوله کلاسیک می‌توان $\mathbf{M}$ را با optimization محدب آموخت.

۱۴.۰۹ تطبیق چندتصویری، مسیر و مکان

ویژگی و تطبیق تنها برای دو تصویر نیستند. در SLAM SfM، panorama، graph localization، visual مشاهده ساخته می‌شود:

$$\mathcal{G} = (\mathcal{V}_{\text{images}} \cup \mathcal{V}_{\text{tracks}}, \mathcal{E}_{\text{obs}}). \quad (۸۵.۰۹)$$

یک track مجموعه‌ای keypoint است که یک نقطه سه‌بعدی را در چند تصویر می‌بینند. union کور pairwise match می‌تواند inconsistency بسازد؛ consistency cycle باید بررسی شود. اگر $i \leftrightarrow j$ و

$j \leftrightarrow k$ correspondence، $i \leftrightarrow k$ باید با geometry سازگار باشد.

۱۰۱۴.۹ retrieval سپس localization

برای پایگاه بزرگ، ابتدا descriptor global یا BoVW چند تصویر نامزد را بازیابی می کند؛ سپس local matching و PnP روی هر نامزد اجرا می شود. این طراحی coarse-to-fine هزینه را کاهش می دهد:

retrieval global $\rightarrow$ matching local $\rightarrow$ PnP D $\times$ D-۲ $\rightarrow$ refinement pose.

در سیستم حرفه ای، retrieval recall@K و accuracy pose جدا گزارش می شوند تا معلوم شود شکست از بازیابی است یا هندسه.

۱۵.۰۹ روش های آموختنی: ادامه یا جایگزین خط لوله کلاسیک؟

روش های آموختنی سه الگو دارند:

۱. descriptor و detector را می آموزند، اما matching و RANSAC کلاسیک می ماند؛
۲. context matcher و assignment را می آموزد، ولی keypoint خارجی می گیرد؛
۳. detector-free یا dense matching correspondence را مستقیماً از دو تصویر می سازد.

۱۰۱۵.۰۹ SuperPoint: آشکارسازی و توصیف sefl-supervised

SuperPoint یک encoder مشترک و دو detector/descriptor head دارد. ابتدا detector مصنوعی روی شکل های هندسی آموزش و با Adaptation Homographic روی تصاویر واقعی sefl-label تولید می شود. descriptor با های correspondence ناشی از homography آموزش می بیند [۳۳]. مزیت آن detector co-design و descriptor است؛ محدودیت آن وابستگی به distribution آموزش و مدل sefl-supervision transformation است.

۲۰۱۵.۰۹ SuperGlue و LightGlue


SuperGlue مجموعه keypoint ها و descriptor را با sefl/cross-attention و assign-ment را با differentiable transport optimal حل می کند [۳۶]. LightGlue طراحی سبک تر با stopping early confidence و pruning point ارائه می کند؛ برای های pair آسان عمق کمتری مصرف می کند و sparse matching را کارا تر می سازد [۳۸].

۳۰۱۵.۹ LoFTR و matching detector-free

LoFTR به جای آشکارسازی مستقل، feature های map دو تصویر را با transformer مرتبط و coarse-to-fine match می کند. این روش در ناحیه کم بافت یا تکرارپذیری ضعیف keypoint مزیت دارد، اما های correspondence متراکم تر، حافظه و filtering متفاوت می طلبند [۳۷]. LoFTR Efficient در ۲۰۲۴ هدف کاهش هزینه و نزدیک شدن سرعت به روش sparse را دنبال کرد [۳۹].

۴۰۱۵.۹ matching Dense و ویژگی های بنیادی

RoMa از feature های pretrained DINOv2 برای robust matching dense بهره می گیرد و -confi dence/warp را پیش بینی می کند [۴۰]. OmniGlue ترکیب های feature foundation با keypoint matcher را برای generalization مطرح می کند [۴۱]. RDD در CVPR ۲۰۲۵ descriptor و detector tor مبتنی بر transformer deformable را برای تغییر دید و مقیاس شدید ارائه کرد [۴۲]. در CVPR ۲۰۲۶ نیز تطبیق گرهای مبتنی بر state-space و correlation sparse به مقیاس پذیری های pair بزرگ تر پرداخته اند [۴۳].



شکل ۱۳.۰۹: نمای آموزشی طیف کلاسیک تا آموختنی. نقاط شکل benchmark رسمی نیستند؛ هدف نمایش trade-off میان سرعت، robustness و complexity است.

پل به دهه آینده

دهه آینده احتمالاً «یک matcher واحد برای همه» نخواهد داشت. سیستم های واقعی از ترکیب زیر سود می برند:

• descriptor کلاسیک برای latency کم، CPU و explainability

- feature آموختنی برای تغییر، illumination viewpoint، texture-poor و
- هندسه کلاسیک برای تضمین سازگاری فیزیکی؛
- uncertainty و detection failure برای جلوگیری از اعتماد کور؛
- foundation-based retrieval و local verification برای مقیاس بزرگ.

خواندن مقاله و استاندارد: مقایسه منصفانه کلاسیک و آموختنی

تعداد match خام را مقایسه نکنید. برای هر روش، detector، budget، resolution، preprocess-، residual threshold model، geometric matcher، ing، device compute و را ثبت کنید. معیارها باید شامل precision، recall match، correspondence، تعداد pose inlier، AUC، fail-، latency rate، memory و باشند. استفاده RANSAC متفاوت می‌تواند نتیجه feature را وارونه کند.

۱۶.۹ ارزیابی آشکارساز و تطبیق گر

۱۰۱۶.۹ repeatability

اگر N_1, N_2 تعداد نواحی قابل مشاهده و N_{rep} زوج تکرار شده باشد:

$$\text{repeatability} = \frac{N_{rep}}{\min(N_1, N_2)}. \quad (۸۶.۹)$$


تعریف، threshold overlap visibility و correspondence یک‌به‌یک باید صریح باشد. repeatability بالا بدون matching discriminative descriptor خوب را تضمین نمی‌کند.

۲۰۱۶.۹ score و recall precision، matching

اگر M match پذیرفته، C صحیح و G correspondence قابل مشاهده باشد:

$$\text{precision} = \frac{C}{M}, \quad \text{recall} = \frac{C}{G}. \quad (۸۷.۹)$$

آستانه ratio یا confidence منحنی PR می‌سازد. area AP زیر PR است و در imbalance class مناسب‌تر از ROC می‌تواند باشد.



شکل ۱۴.۰۹: آستانه matcher نقطه operating را روی PR/ROC انتخاب می کند. یک عدد accuracy رفتار threshold را پنهان می کند.

۳.۱۶.۰۹ خطای هندسی و AUC pose

برای corner homography، reprojection برای relative pose، خطای دوران و جهت انتقال:

$$e_R = \arccos \left(\frac{\text{tr}(\mathbf{R}_{\text{gt}} \mathbf{R}_{\text{est}}^T) - 1}{2} \right), \quad (۸۸.۰۹)$$

$$e_t = \arccos \left(\frac{\mathbf{t}_{\text{gt}}^T \mathbf{t}_{\text{est}}}{\|\mathbf{t}_{\text{gt}}\| \|\mathbf{t}_{\text{est}}\|} \right). \quad (۸۹.۰۹)$$

معمولاً $e = \max(e_R, e_t)$ و AUC تا هایی threshold مانند ۵، ۱۰ و ۲۰ درجه گزارش می شود. median فقط شکست های کامل را پنهان می کند؛ rate failure نیز لازم است.

۴.۱۶.۰۹ ارزیابی بازشناسی

برای matrix confusion C_{ij} ، average macro به هر کلاس وزن برابر و average micro به هر نمونه وزن برابر می دهد. در عدم توازن، accuracy ممکن است گمراه کننده باشد. برای retrieval:

$$\text{AP}(q) = \frac{1}{N_q^+} \sum_{k=1}^N P_q(k) \text{rel}_q(k), \quad \text{mAP} = \frac{1}{Q} \sum_q \text{AP}(q). \quad (۹۰.۰۹)$$

در retrieval instance باید، ها، query distractor، multi-scale crop و re-ranking geometric تعریف شوند.

۵.۱۶.۰۹ پروتکل robustness

تغییرات را جدا و ترکیبی بسنجید:

• exposure، gamma JPEG، noise، blur،

- perspective، viewpoint affine scale، rotation،
 - medical یا underwater RGB-IR، modality seasonal/day-night،
 - texture، repetitive و objects dynamic occlusion،
 - blur، motion و shutter rolling
 - saturation، texture کمبود و
- گزارش average روی همه ها corruption کافی نیست؛ taxonomy failure و بدترین گروه کاربردی مهم اند.

نکته گزارش	معیار	لایه ارزیابی
visibility و budget ثابت	localization، repeatability، coverage	آشکارسازی
threshold ratio و metric ثابت	score matching AP، PR، reprojection، ratio، inlier AUC pose	توصیف/تطبیق هندسه
mem- index و scale distractor	query mAP، Recall@K، time	بازیابی
calibration و گروهی و split	accu- balanced، macro-F ROC/PR racy،	بازشناسی
warm- و batch= CPU/GPU، mem- throughput، latency، up energy ory،		مهندسی
گروه بندی و فاصله اطمینان	corruption/OOD/failure rate	پایداری

۱۷.۰۹ آزمایشگاه کدنویسی فصل

۱۰۱۷.۰۹ Harris از صفر با قرارداد نوع داده

```

1 from __future__ import annotations
2 import numpy as np
3 from scipy.ndimage import gaussian_filter, maximum_filter
4
5 def harris_response(
6     image: np.ndarray,
7     sigma_d: float = 1.0,
8     sigma_i: float = 2.0,
9     k: float = 0.04,
10 ) -> np.ndarray:
11     """Compute Harris response on a 2-D image scaled to [0, 1]."""

```

```

12     if image.ndim != 2:
13         raise ValueError("image must be grayscale")
14     x = image.astype(np.float64)
15     if not np.isfinite(x).all():
16         raise ValueError("image contains NaN/Inf")
17     x = (x - x.min()) / (x.max() - x.min() + 1e-12)
18     smooth = gaussian_filter(x, sigma_d)
19     iy, ix = np.gradient(smooth)
20     sxx = gaussian_filter(ix * ix, sigma_i)
21     syy = gaussian_filter(iy * iy, sigma_i)
22     sxy = gaussian_filter(ix * iy, sigma_i)
23     det = sxx * syy - sxy * sxy
24     trace = sxx + syy
25     return det - k * trace * trace
26
27 def select_keypoints(response: np.ndarray, n: int = 1000, radius: int
28     = 4):
29     local_max = response == maximum_filter(response, size=2 * radius
30     + 1)
31     values = response[local_max]
32     coords = np.argwhere(local_max)
33     keep = np.argsort(values)[::-1][:n]
34     return coords[keep], values[keep]

```

آزمایش property-based با افزودن ثابت روشنایی پاسخ gradient تغییر نکند؛ با ضرب intensity پاسخ Harris به توان چهار scale شود؛ مختصات تحت translation داخلی همان translation را دنبال کند.

۲۰۱۷۰۹ RANSAC خط و تعمیم به homography

```

1 from dataclasses import dataclass
2 import numpy as np
3
4 @dataclass
5 class RansacResult:
6     model: tuple[float, float]
7     inliers: np.ndarray
8     residuals: np.ndarray
9
10 def ransac_line(xy: np.ndarray, threshold: float, max_trials: int =
11     2000,
12     confidence: float = 0.999, seed: int = 0) ->
13     RansacResult:

```

```

12 rng = np.random.default_rng(seed)
13 n = len(xy)
14 if n < 2:
15     raise ValueError("at least two points are required")
16 best_mask = np.zeros(n, dtype=bool)
17 best_model = (0.0, 0.0)
18 trials = 0
19 target_trials = max_trials
20 while trials < min(max_trials, target_trials):
21     i, j = rng.choice(n, size=2, replace=False)
22     dx = xy[j, 0] - xy[i, 0]
23     if abs(dx) < 1e-12:
24         trials += 1
25         continue
26     a = (xy[j, 1] - xy[i, 1]) / dx
27     b = xy[i, 1] - a * xy[i, 0]
28     residuals = np.abs(a * xy[:, 0] - xy[:, 1] + b) / np.sqrt(a*a
29 + 1)
29     mask = residuals < threshold
30     if mask.sum() > best_mask.sum():
31         best_mask = mask
32         best_model = (a, b)
33         w = max(mask.mean(), 1e-12)
34         p_good = max(1.0 - w**2, 1e-12)
35         target_trials = int(np.ceil(np.log(1-confidence) / np.log
36 (p_good)))
36         trials += 1
37     a, b = np.polyfit(xy[best_mask, 0], xy[best_mask, 1], 1)
38     residuals = np.abs(a * xy[:, 0] - xy[:, 1] + b) / np.sqrt(a*a +
39 1)
39     return RansacResult((float(a), float(b)), residuals < threshold,
40 residuals)

```

برای solver minimal homography، چهار correspondence نرمال شده DLT است؛ residual را transfer symmetric بگیرید و های sample با مساحت کم را پیش از solve رد کنید.

۳۰۱۷۰۹ SVM + BoVW در pipeline امن

```

1 from sklearn.cluster import MiniBatchKMeans
2 from sklearn.preprocessing import normalize
3 from sklearn.svm import LinearSVC
4 import numpy as np

```

```

5
6 def fit_codebook(train_descriptors: list[np.ndarray], k: int, seed:
  int = 0):
7     pool = np.concatenate([d for d in train_descriptors if d is not
  None], axis=0)
8     km = MiniBatchKMeans(n_clusters=k, batch_size=4096, random_state=
  seed,
9                           n_init=10, reassignment_ratio=0.01)
10    km.fit(pool)
11    return km
12
13 def encode_bovw(descriptors: list[np.ndarray], codebook) -> np.
  ndarray:
14     features = np.zeros((len(descriptors), codebook.n_clusters),
  dtype=np.float64)
15     for i, d in enumerate(descriptors):
16         if d is None or len(d) == 0:
17             continue
18         words = codebook.predict(d)
19         features[i] = np.bincount(words, minlength=codebook.
  n_clusters)
20     features = np.sqrt(features) # power normalization for counts
21     return normalize(features, norm="l2")
22
23 # IMPORTANT: descriptors_test never participate in codebook fitting.
24 codebook = fit_codebook(descriptors_train, k=512, seed=42)
25 Xtr = encode_bovw(descriptors_train, codebook)
26 Xva = encode_bovw(descriptors_val, codebook)
27 model = LinearSVC(C=1.0, class_weight="balanced").fit(Xtr, y_train)

```

قرارداد میان ریاضیات و کد

هر آزمایش باید چهار جدول جدا بسازد: statistics, descriptor/matching statistics, detector و statistics geometry. task و statistics ادغام همه چیز در accuracy نهایی، محل شکست را پنهان می‌کند. همه، ها، arrayها threshold و random ها seed باید ذخیره شوند.

۱۸۰۹ طراحی آزمایش‌های عمیق و بازتولیدپذیر

۱۰۱۸۰۹ آزمایش ۱: ناوردایی کنترل شده

یک تصویر مرجع و grid transformation بسازید:

$$\theta \in [-90^\circ, 90^\circ], \quad s \in [0.5, 2], \quad \text{blur} \in [0, 4], \quad \gamma \in [0.5, 2], \quad \text{noise} \in [0, 0.1].$$

برای homography و precision match repeatability، AKAZE و ORB SIFT، Harris+patch، error را رسم کنید. هر transformation را تنها و سپس دوبه دو اعمال کنید تا interaction دیده شود.

۲۰۱۸۰۹ آزمایش ۲: trade-off و threshold

برای ρ ratio از ۵۰ تا ۱، curve PR و runtime RANSAC را ثبت کنید. ratio سخت precision را بالا می برد، اما ممکن است inlier کافی برای model minimal باقی نگذارد. point operating باید با success pose، نه فقط descriptor، precision انتخاب شود.

۳۰۱۸۰۹ آزمایش ۳: budget descriptor

تعداد keypoint را ۲۵۰، ۵۰۰، ۱۰۰۰، ۲۰۰۰، ۴۰۰۰ تغییر دهید. زمان، match describe، detect و memory RANSAC، AUC pose و گزارش کنید. saturation curve نشان می دهد نقطه بیشتر چه زمانی فقط هزینه و ambiguity می افزاید.

۴۰۱۸۰۹ آزمایش ۴: FV و VLAD BoVW

با descriptor ثابت، size codebook و PCA dimension را تغییر دهید. برای هر representation، feature time، codebook train، classifier ثابت را مقایسه کنید. ℓ_2 normalization، power، inference size، disk dimension و mAP\macro-F / گزارش شود.

۵۰۱۸۰۹ آزمایش ۵: کلاسیک در برابر آموختنی

LoFTR Efficient SuperPoint+LightGlue، SIFT+ratio+MAGSAC++، matcher dense و یک resolution و geometric viewpoint، subset های illumination و texture-poor اجرا کنید. averager بدترین decile و rate failure را گزارش کنید.

۶۰۱۸۰۹ آزمایش ۶: shfit domain

مدل یا threshold را روی indoor/day تنظیم و روی RGB-IR outdoor/night یا تصاویر صنعتی آزمون کنید. روش کلاسیک نیز hyperparameter دارد؛ ادعای «بدون آموزش» به معنی «بدون تنظیم» نیست.

۱۹.۰۹ خطاهای رایج در مقاله و پروژه

۱. نمایش چند خط match رنگی و نتیجه‌گیری کیفی بدون truth, ground
۲. گزارش تعداد match خام به جای inlier هندسی و accuracy, pose
۳. استفاده matcher یا metric ناسازگار با descriptor.
۴. تنظیم ratio/RANSAC روی test.
۵. ساخت PCA codebook یا statistics normalization روی کل داده.
۶. split تصادفی‌های frame یک ویدئو در train و test.
۷. مقایسه SIFT در resolution کامل با مدل عمیق در resolution کوچک یا بالعکس.
۸. نادیده گرفتن extraction feature latency و فقط گزارش matcher.
۹. استفاده homography برای صحنه سه‌بعدی عمومی و تفسیر inlier زیاد به عنوان درستی, pose.
۱۰. حذف‌های pair شکست خورده از میانگین.
۱۱. گزارش تنها accuracy در open-set, recognition.
۱۲. استفاده تصویر نمونه مشهور و عدم ارزیابی روی dataset واقعی دامنه هدف.

۲۰.۰۹ پرسش‌های تصمیم مهندسی

پرسش	پاسخ طراحی
CPU و latency سخت؟	geome- و coverage grid Hamming, ORB/AKAZE, try کلاسیک را baseline کنید.
تغییر دید و نور شدید؟	affine/dense یا SIFT/RootSIFT feature آموختنی, matcher robust, verifier
بافت کم؟	feature, line/region یا matching detector-free/dense keypoint صرف ممکن است پوشش ندهد.
پایگاه میلیون تصویری؟	index/PQ, inverted retrieval, global/coarse verification, local
نیاز به توضیح و certification؟	fall- و uncertainty geometry, mask, inlier residual, back کلاسیک حفظ شود.
دامنه خاص و داده کم؟	fine- adaptation + baseline strong classical tune بزرگ بدون validation پرهیز.
چهره/هویت؟ open-set	ROC/FAR/FRR rejection, threshold metric, split, group-aware

قطعه صنعتی ثابت؟
 template/edge/chamfer ممکن است از شبکه پیچیده
 مناسب تر و قابل تمیزی تر باشد.

۲۱.۹ تمرین‌های نظری و اثباتی

۱. ناوردایی ZNCC نسبت به $I' = aI + b$ برای $a > 0$ را اثبات کنید و حالت $a < 0$ را تحلیل کنید.
۲. معادله تانسور ساختار (۱۴۰۹) را از تیلور استخراج کنید.
۳. نواحی تصمیم Harris را در صفحه (λ_1, λ_2) برای چند k رسم کنید.
۴. نشان دهید مقیاس پاسخ Harris با ضرب intensity چگونه تغییر می کند.
۵. رابطه DoG و LoG را با بسط تیلور نسبت به σ استخراج کنید.
۶. برای blob Gaussian دوبعدی، مقیاس اکستریم $\sigma^2 \nabla^2 L$ را محاسبه کنید.
۷. معادله offset زیرپیکسلی (۲۵۰۹) را از شرط ایستایی به دست آورید.
۸. رابطه rejection edge در SIFT را برحسب نسبت eigenvalue اثبات کنید.
۹. نشان دهید برای بردارهای واحد، ranking فاصله Euclidean و cosine یکسان است.
۱۰. یک distribution بسازید که test ratio بهتر از threshold مطلق عمل کند و یک مثال عکس آن ارائه دهید.
۱۱. فرمول RANSAC iteration را استخراج و برای $w = 0.3$ و مدل‌های ۲، ۴، ۵ و ۸ نقطه‌ای محاسبه کنید.
۱۲. اثر overestimated و underestimated RANSAC threshold را بر bias و variance تحلیل کنید.
۱۳. شرط تباهی چهار نقطه homography DLT را با matrix rank بیان کنید.
۱۴. دوگان SVM را از primal Lagrangian استخراج کنید.
۱۵. نشان دهید label-invariant PCA است و مثال دوکلاسی بسازید که مؤلفه اول برای طبقه‌بندی نامناسب باشد.
۱۶. LDA eigenproblem generalized را از quotient Rayleigh استخراج کنید.
۱۷. نشان دهید TF-IDF چگونه واژه موجود در همه تصاویر را کم وزن می کند.
۱۸. ابعاد VLAD SPM و FV را برای $K = 256, D = 64, L = 2$ محاسبه کنید.
۱۹. GMM log-likelihood gradient نسبت به μ_k را استخراج و فرمول mean FV را توجیه کنید.
۲۰. رابطه matcher precision/recall و RANSAC probability success را به صورت تحلیلی بحث کنید.

۲۲.۰۹ پروژه‌های پایان فصل

۱۰.۲۲.۰۹ پروژه A: آزمایشگاه ویژگی کلاسیک

localiza- repeatability، runtime و coverage tion، transformation های کنترل شده مقایسه کنید.

۲۰.۲۲.۰۹ پروژه B: موتور تطبیق و panorama

blending و homography RANSAC/MAGSAC++، mutual، ratio، SIFT/ORB/AKAZE، پیاده سازی کنید. failure ناشی از motion parallax و repetition texture را طبقه بندی کنید.

۳۰.۲۲.۰۹ پروژه C: بازشناسی کلاسیک کامل

روی یک dataset چند کلاسه، BoVW، LBP+SVM، HOG+SVM، VFLAD SPM و FV را با split گروهی مقایسه کنید. ابعاد، زمان، حافظه، macro-F و calibration را گزارش کنید.

۴۰.۲۲.۰۹ پروژه D: بازیابی تصویر مقیاس پذیر

Re- ranking geometric و burstiness stop-word، index، inverted TF-IDF، latency query mAP، call@K، size index و در اندازه پایگاه افزاینده اندازه گیری کنید.

۵۰.۲۲.۰۹ پروژه E: کلاسیک در برابر LightGlue/LoFTR

روی HPatches یا یک مجموعه دامنه خاص، SIFT+MAGSAC++ و SuperPoint+LightGlue LoFTR را در پروتکل ثابت مقایسه کنید. نتیجه را به illumination viewpoint و texture تقسیم کنید.

۶۰.۲۲.۰۹ پروژه F: open-set چهره یا شیء

PCA/LDA/metric را با gallery/probe مستقل بسازید. CMC، FAR/FRR ROC و rejection ناشناخته را گزارش و leakage هویت را کنترل کنید.

۲۳.۰۹ پرامپت پیشنهادی برای Codex

- 1 Build a fully reproducible Python research package for Chapter 9,
- 2 "Local Features, Matching, and Classical Recognition".
- 3
- 4 Implement from scratch where educationally useful:

- ZNCC and FFT phase correlation;
- Harris/Shi-Tomasi with subpixel localization and ANMS;
- Gaussian/DoG scale space, 3-D extrema, contrast and edge rejection;
- a compact educational SIFT-like descriptor with trilinear voting;
- BRIEF-style binary tests and Hamming matching;
- brute-force 2-NN, ratio test, mutual check and assignment diagnostics;
- adaptive RANSAC for line, homography and fundamental matrix, including degeneracy tests, normalized solvers and nonlinear refinement;
- detector repeatability, overlap error, matching PR/AP, reprojection error, relative-pose AUC and failure rate;
- BoVW, TF-IDF, inverted index, spatial pyramid, VLAD and Fisher Vector;
- PCA, LDA, kNN, linear/RBF SVM, calibrated scores and AdaBoost;
- HOG + sliding-window detection with hard-negative mining and NMS.

Use trusted library wrappers for SIFT, ORB, AKAZE, MAGSAC++, SuperPoint, LightGlue, Efficient LoFTR, RoMa or other learned methods when licenses and weights are available. Never silently download weights. Record checkpoint, commit, license, image resolution, device and preprocessing.

Research protocol:

1. Use analytic synthetic transformations plus public benchmarks and one domain-specific dataset.
2. Split by object/scene/person/video before any PCA, codebook, whitening or hyperparameter fitting.
3. Compare methods at fixed keypoint budgets and fixed geometric verification.
4. Sweep ratio/confidence and RANSAC thresholds; produce PR and pose-success curves, not one cherry-picked operating point.
5. Log detect, describe, match, verify and end-to-end latency separately.
6. Save keypoints, descriptors metadata, matches, inlier masks, model matrices,

34 residuals, seeds, configs, environment and data hashes.

35 7. Add robustness tests for scale, rotation, affine viewpoint, blur,
noise,

36 exposure, gamma, JPEG, occlusion, repeated texture and low texture

37 8. Report paired bootstrap confidence intervals over independent
image pairs

38 or queries and preserve all failed pairs in the denominator.

39 9. Add unit/property tests for coordinate order, dtype/range, empty
descriptors,

40 Hamming vs L2 selection, normalized DLT, RANSAC degeneracy,
deterministic

41 sampling, label leakage and metric edge cases.

42 10. Provide a single command that regenerates every figure, CSV and
table used

43 by the chapter, plus an automatic failure gallery sorted by
declared error.

۲۴۰۹ تقسیم پیشنهادی ویدئوهای ۱۵ دقیقه‌ای

بخش	موضوع
۱	مسئله ویژگی، تطبیق و بازشناسی
۲	هم‌وردایی و ناوردایی با گروه تبدیل
۳	معیارهای coverage و localization repeatability،
۴	SSD و مدل نویز گاوسی
۵	NCC SAD، و ZNCC
۶	تصویر انتگرالی و تطبیق سریع
۷	correlation phase و قضیه شیفیت فوریه
۸	انرژی تغییر وصله و Moravec
۹	استخراج تانسور ساختار
۱۰	Harris و صفحه مقادیر ویژه
۱۱	Shi-Tomasi و ANMS
۱۲	AGAST FAST، و درخت تصمیم
۱۳	ضرورت فضای مقیاس
۱۴	axioms فضای مقیاس گاوسی
۱۵	مشتق نرمال شده و LoG
۱۶	استخراج DoG از معادله گرما

اکسترمم سه بعدی مکان-مقیاس	۱۷
مکان یابی زیرپیکسلی	۱۸
حذف کنتراست پایین و پاسخ لبه	۱۹
blob و SURF Hessian،	۲۰
KAZE/AKAZE و diffusion غیرخطی	۲۱
MSER و ناحیه stable maximally	۲۲
region covariant affine	۲۳
جهت گذاری canonical	۲۴
descriptor و وصله خام و whitening	۲۵
ساخت SIFT مرحله به مرحله	۲۶
interpolation و نرمال سازی SIFT	۲۷
RootSIFT و فاصله Hellinger	۲۸
HOG و normalization block	۲۹
Context Shape و تطبیق contour	۳۰
BRIEF و آزمون های دودویی	۳۱
AKAZE و FREAK BRISK، ORB،	۳۲
فاصله L_2 ، Mahalanobis cosine و Hamming	۳۳
dimensionality of curse و neighbor nearest	۳۴
test ratio و تحلیل آماری آن	۳۵
assignment و check mutual	۳۶
quantization product و LSH FLANN،	۳۷
residual هندسی و انتخاب مدل	۳۸
RANSAC iteration استخراج احتمال	۳۹
uncertainty threshold و فاصله Mahalanobis	۴۰
MAGSAC++ و USAC LO-RANSAC، PROSAC،	۴۱
selection model و degeneracy	۴۲
Hough template/chamfer/generalized	۴۳
ممان ها و های descriptor کلی شکل	۴۴
Eigenfaces و PCA	۴۵
Fisherfaces و LDA	۴۶
classifier LDA/QDA kNN،	۴۷
dual و margin primal، SVM	۴۸
kernel، چند کلاسه و calibration	۴۹
cascade و Haar AdaBoost،	۵۰
HOG+SVM و mining hard-negative	۵۱
parts latent و DPM	۵۲
k-means و Words Visual of Bag	۵۳
quantization و assignment hard/soft	۵۴
TF-IDF و فهرست معکوس	۵۵

words stop و burstiness	۵۶
Matching Pyramid Spatial	۵۷
aggregation residual و VLAD	۵۸
GMM gradient و Vector Fisher	۵۹
verification geometric سپس retrieval	۶۰
consistency cycle track، و چندتصویری	۶۱
sefl-supervision و SuperPoint هندسی	۶۲
assignment و SuperGlue آموختنی	۶۳
LightGlue و تطبیق تطبیقی سریع	۶۴
matching detector-free و LoFTR	۶۵
OmniGlue و RoMa LoFTR، Efficient	۶۶
RDD و مسیر پژوهش ۲۰۲۵-۲۰۲۶	۶۷
PR matching و repeatability پروتکل	۶۸
AUC error، pose و rate failure	۶۹
open-set و macro/micro confusion، mAP،	۷۰
shfit domain و robustness	۷۱
scale-space و Harris کارگاه	۷۲
RANSAC و SIFT/ORB کارگاه	۷۳
SVM و BoVW/VLAD/FV کارگاه	۷۴
leakage طراحی مقاله و جلوگیری از	۷۵
پروژه‌های پایان فصل و جمع‌بندی	۷۶

۲۵۰۹ جمع‌بندی و پل به فصل دهم

جمع‌بندی فصل

۱. ویژگی خوب باید مکان را هم‌وردا، توصیف را نسبت به تغییرات مجاز پایدار و میان ساختارهای متفاوت متمایز کند.
۲. matching template یک baseline آماری شفاف است؛ ZNCC تغییر آفین شدت و phase correlation انتقال را مدیریت می‌کند.
۳. Harris از انرژی تغییر وصله و های eigenvalue تانسور ساختار به دست می‌آید؛ FAST سرعت را با آزمون دایره و درخت تصمیم می‌خرد.
۴. فضای مقیاس مسئله اندازه ویژگی را حل می‌کند؛ DoG تقریب محاسباتی LoG و SIFT نمونه کلاسیک انتخاب مکان-مقیاس-جهت است.
۵. SIFT با pooling جهت و مکان به پایداری می‌رسد؛ RootSIFT histogram metric را

- اصلاح و های descriptor دودویی سرعت و حافظه را کاهش می دهند.
۶. neighbor nearest بدون، mutuality ratio و geometry تنها فرضیه خام است.
۷. RANSAC و جانشین های آن matching را به استدلال هندسی فیزیکی متصل می کنند؛ thresh- old و degeneracy جزء مدل اند.
۸. PCA، LDA، SVM، boosting و HOG نشان می دهند بازشناسی کلاسیک ترکیب نمایش و تصمیم است، نه یک الگوریتم منفرد.
۹. BoVW ترتیب را حذف، Pyramid Spatial بخشی از آن را بازمی گرداند و VLAD/FV آمار غنی تری از ها residual می سازند.
۱۰. روش های آموختنی detector/descriptor/matcher را بهینه می کنند، اما ارزیابی منصفانه همچنان به، uncertainty geometry و accounting failure نیاز دارد.
۱۱. سامانه آینده غالباً هیبرید است: retrieval آموختنی، feature local قوی، verifier هندسی و fallback قابل ممیزی.
۱۲. فصل بعد می تواند از ویژگی های منفرد به حرکت، ویدئو، ردیابی و برآورد correspondence زمانی گسترش یابد.

منابع منتخب فصل

- [1] C. Harris and M. Stephens, "A combined corner and edge detector," Alvey Vision Conference, 1988.
- [2] J. Shi and C. Tomasi, "Good features to track," IEEE Conference on Computer Vision and Pattern Recognition, 1994.
- [3] E. Rosten and T. Drummond, "Machine learning for high-speed corner detection," European Conference on Computer Vision, 2006.
- [4] K. Mikolajczyk and C. Schmid, "A performance evaluation of local descriptors," IEEE Transactions on Pattern Analysis and Machine Intelligence, 2005.
- [5] K. Mikolajczyk et al., "A comparison of affine region detectors," International Journal of Computer Vision, 2006.
- [6] D. G. Lowe, "Distinctive image features from scale-invariant keypoints," International Journal of Computer Vision, 2004.
- [7] H. Bay, A. Ess, T. Tuytelaars, and L. Van Gool, "Speeded-Up Robust Features (SURF)," Computer Vision and Image Understanding, 2008.
- [8] J. Matas, O. Chum, M. Urban, and T. Pajdla, "Robust wide-baseline stereo from maximally stable extremal regions," Image and Vision Computing, 2004.
- [9] P. F. Alcantarilla, A. Bartoli, and A. J. Davison, "KAZE features," European Conference on Computer Vision, 2012.
- [10] P. F. Alcantarilla, J. Nuevo, and A. Bartoli, "Fast Explicit Diffusion for Accelerated Features in Nonlinear Scale Spaces," British Machine Vision Conference, 2013.
- [11] M. Calonder, V. Lepetit, C. Strecha, and P. Fua, "BRIEF: Binary Robust Independent Elementary Features," European Conference on Computer Vision, 2010.

- [12] E. Rublee, V. Rabaud, K. Konolige, and G. Bradski, "ORB: An efficient alternative to SIFT or SURF," IEEE International Conference on Computer Vision, 2011.
- [13] S. Leutenegger, M. Chli, and R. Siegwart, "BRISK: Binary Robust Invariant Scalable Keypoints," IEEE International Conference on Computer Vision, 2011.
- [14] A. Alahi, R. Ortiz, and P. Vandergheynst, "FREAK: Fast Retina Keypoint," IEEE Conference on Computer Vision and Pattern Recognition, 2012.
- [15] R. Arandjelovic and A. Zisserman, "Three things everyone should know to improve object retrieval," IEEE Conference on Computer Vision and Pattern Recognition, 2012.
- [16] N. Dalal and B. Triggs, "Histograms of Oriented Gradients for Human Detection," IEEE Conference on Computer Vision and Pattern Recognition, 2005.
- [17] S. Belongie, J. Malik, and J. Puzicha, "Shape matching and object recognition using shape contexts," IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002.
- [18] M. A. Fischler and R. C. Bolles, "Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography," Communications of the ACM, 1981.
- [19] O. Chum and J. Matas, "Matching with PROSAC—Progressive Sample Consensus," IEEE Conference on Computer Vision and Pattern Recognition, 2005.
- [20] O. Chum, J. Matas, and J. Kittler, "Locally optimized RANSAC," DAGM Symposium, 2003.
- [21] D. Barath, J. Noskova, M. Ivashechkin, and J. Matas, "MAGSAC++, a fast, reliable and accurate robust estimator," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.
- [22] M. Turk and A. Pentland, "Eigenfaces for recognition," Journal of Cognitive Neuroscience, 1991.
- [23] P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman, "Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection," IEEE Transactions on Pattern Analysis and Machine Intelligence, 1997.

- [24] C. Cortes and V. Vapnik, "Support-vector networks," Machine Learning, 1995.
- [25] P. Viola and M. Jones, "Rapid object detection using a boosted cascade of simple features," IEEE Conference on Computer Vision and Pattern Recognition, 2001.
- [26] P. F. Felzenszwalb, R. B. Girshick, D. McAllester, and D. Ramanan, "Object detection with discriminatively trained part-based models," IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010.
- [27] J. Sivic and A. Zisserman, "Video Google: A text retrieval approach to object matching in videos," IEEE International Conference on Computer Vision, 2003.
- [28] D. Nister and H. Stewenius, "Scalable recognition with a vocabulary tree," IEEE Conference on Computer Vision and Pattern Recognition, 2006.
- [29] S. Lazebnik, C. Schmid, and J. Ponce, "Beyond bags of features: Spatial pyramid matching for recognizing natural scene categories," IEEE Conference on Computer Vision and Pattern Recognition, 2006.
- [30] H. Jegou, M. Douze, C. Schmid, and P. Perez, "Aggregating local descriptors into a compact image representation," IEEE Conference on Computer Vision and Pattern Recognition, 2010.
- [31] F. Perronnin, J. Sanchez, and T. Mensink, "Improving the Fisher kernel for large-scale image classification," European Conference on Computer Vision, 2010.
- [32] J. Sanchez, F. Perronnin, T. Mensink, and J. Verbeek, "Image classification with the Fisher vector: Theory and practice," International Journal of Computer Vision, 2013.
- [33] D. DeTone, T. Malisiewicz, and A. Rabinovich, "SuperPoint: Self-supervised interest point detection and description," CVPR Workshops, 2018.
- [34] M. Dusmanu et al., "D2-Net: A trainable CNN for joint detection and description of local features," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019.
- [35] J. Revaud et al., "R2D2: Repeatable and reliable detector and descriptor," NeurIPS, 2019.

- [36] P.-E. Sarlin, D. DeTone, T. Malisiewicz, and A. Rabinovich, "SuperGlue: Learning feature matching with graph neural networks," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2020.
- [37] J. Sun, Z. Shen, Y. Wang, H. Bao, and X. Zhou, "LoFTR: Detector-free local feature matching with Transformers," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.
- [38] P. Lindenberger, P.-E. Sarlin, and M. Pollefeys, "LightGlue: Local feature matching at light speed," IEEE/CVF International Conference on Computer Vision, 2023.
- [39] Y. Wang, X. He, S. Peng, D. Tan, and X. Zhou, "Efficient LoFTR: Semi-dense local feature matching with sparse-like speed," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024.
- [40] J. Edstedt et al., "RoMa: Robust dense feature matching," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024.
- [41] H. Jiang et al., "OmniGlue: Generalizable feature matching with foundation model guidance," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024.
- [42] G. Chen et al., "RDD: Robust feature detector and descriptor using deformable Transformer," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025.
- [43] S. W. Choo et al., "Scalable feature matching via state space modeling and sparse correlation," IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026.
- [44] OpenCV Development Team, "Feature detection, description, matching, homography and stitching documentation," accessed July 2026.

راهنمای کامپایل، فونت و اجرای آزمایش‌ها

فایل با XeLaTeX کامپایل می‌شود. فونت اصلی Amiri، فونت لاتین DejaVu Serif و فونت کد DejaVu Sans Mono است و جایگزین خودکار تعریف شده است. هیچ فایل فونتی در بسته توزیع نمی‌شود.

```
1 python -m venv .venv
2 # Windows: .venv\Scripts\activate
3 # Linux/macOS: source .venv/bin/activate
4 pip install -r requirements.txt
5 python generate_figures.py
6 python chapter09_experiments.py --output outputs
7 xelatex image_processing_next_decade_ch09_fa.tex
8 xelatex image_processing_next_decade_ch09_fa.tex
```